TUGAS AKHIR - SM234801

RAIN CONVOLUTIONAL DICTIONARY NETWORK (RCDNET) DENGAN FREQUENCY HINT UNTUK MENGHILANGKAN NOISE HUJAN PADA CITRA DIGITAL

MERISA ANGGI ANGGRAINI

NRP 5002221152

Dosen Pembimbing

Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T.

NIP 19690405 199403 2 003

Program Studi Sarjana

Departemen Matematika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2026

TUGAS AKHIR - SM234801

RAIN CONVOLUTIONAL DICTIONARY NETWORK (RCDNET) DENGAN FREQUENCY HINT UNTUK MENGHILANGKAN NOISE HUJAN PADA CITRA DIGITAL

MERISA ANGGI ANGGRAINI

NRP 5002221152

Dosen Pembimbing

Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T.

NIP 19690405 199403 2 003

Program Sarjana

Departemen Matematika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2026

FINAL PROJECT - SM234801

RAIN CONVOLUTIONAL DICTIONARY NETWORK (RCDNET) WITH FREQUENCY HINT FOR RAIN NOISE REMOVAL IN DIGITAL IMAGES

MERISA ANGGI ANGGRAINI

NRP 5002221152

Supervisors

Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T.

NIP 19690405 199403 2 003

Bachelor Program

Departement of Mathematics

Faculty of Science and Data Analytics

Institut Teknologi Sepuluh Nopember

Surabaya

2026

LEMBAR PENGESAHAN

RAIN CONVOLUTIONAL DICTIONARY NETWORK (RCDNET) DENGAN FREQUENCY HINT UNTUK MENGHILANGKAN NOISE HUJAN PADA CITRA DIGITAL

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Matematika pada
Program Studi S-1 Matematika
Departemen Matematika
Fakultas Sains dan Analitika Data
Institut Teknologi Sepuluh Nopember

Oleh: **MERISA ANGGI ANGGRAINI**
NRP. 5002221152

Surabaya, Juli 2026
Disetujui oleh Tim Penguji Tugas Akhir:

Pembimbing

1. Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T. (.....)
   NIP. 19690405 199403 2 003

Penguji

1. Prof. Dr. Mahmud Yunus, M.Si (.....)
   NIP. 19620407 198703 1 005

2. Dr. Budi Setiyono, S.Si, MT (.....)
   NIP. 19720207 199702 1 001

3. Muhammad Yusuf Hakim Widianto, S.Si., M. Si., M.Sc., Ph.D (.....)
   NIP. 19910620 202406 1 001

Mengetahui
Kepala Departemen Matematika
Fakultas Sains dan Analitika Data

Dr. Didik Khusnul Arif, S.Si., M.Si.
NIP. 19730930 199702 1 001

APPROVAL SHEET

RAIN CONVOLUTIONAL DICTIONARY NETWORK (RCDNET) WITH FREQUENCY HINT FOR RAIN NOISE REMOVAL IN DIGITAL IMAGES

FINAL PROJECT

Submitted to fulfill one of the requirements
for obtaining a degree Bachelor of Mathematics at
Bachelor Program of Mathematics
Department of Mathematics
Faculty of Science and Data Analytics
Institut Teknologi Sepuluh Nopember

By: **MERISA ANGGI ANGGRAINI**
NRP 5002221152

Surabaya, July 2026
Approved By:

Advisor:

1. Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T. (.....)
   NIP 19690405 199403 2 003

Examiners:

1. Prof. Dr. Mahmud Yunus, M.Si (.....)
   NIP 19620407 198703 1 005
2. Dr. Budi Setiyono, S.Si, MT (.....)
   NIP 19720207 199702 1 001
3. Muhammad Yusuf Hakim Widianto, S.Si., M. Si., M.Sc., Ph.D (.....)
   NIP 19910620 202406 1 001

Acknowledged by
Head of Mathematics Department
Faculty of Science and Data Analytics

Dr. Didik Khusnul Arif, S.Si., M.Si.
NIP 19730930 199702 1 001

PERNYATAAN ORISINALITAS

Yang bertanda tangan disini:

Nama Mahasiswa / NRP	:	Merisa Anggi Anggraini / 5002221152
Departemen	:	Matematika
Dosen Pembimbing / NIP	:	Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T. / 19690405 199403 2 003

dengan ini menyatakan bahwa Tugas Akhir dengan judul "**RAIN CONVOLUTIONAL DICTIONARY NETWORK (RCDNET) DENGAN FREQUENCY HINT UNTUK MENGHILANGKAN NOISE HUJAN PADA CITRA DIGITAL**" adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Surabaya, 29 Juli 2026

Mengetahui
Dosen Pembimbing

Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T.
NIP. 19690405 199403 2 003

Mahasiswa



Merisa Anggi Anggraini
NRP. 5002221152

STATEMENT OF ORIGINALITY

The undersigned below:

Student's Name / NRP	:	Merisa Anggi Anggraini / 5002221152
Department	:	Mathematics
Advisor / NIP	:	Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T. / 19690405 199403 2 003

Hereby declare that the Final Project entitled "**RAIN CONVOLUTIONAL DICTIONARY NETWORK (RCDNET) WITH FREQUENCY HINT FOR RAIN NOISE REMOVAL IN DIGITAL IMAGES**" is the result of my own work, is original, and is written by following the rules of scientific writing.

If in the future there is a discrepancy with this statement, then I am willing to accept sanctions in accordance with the provisions that apply at Institut Teknologi Sepuluh Nopember.

Surabaya, 29 July 2026

Acknowledged,
Advisor

Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T.
NIP. 19690405 199403 2 003

Student

Merisa Anggi Anggraini
NRP. 5002221152

ABSTRAK

RAIN CONVOLUTIONAL DICTIONARY NETWORK (RCDNET) DENGAN FREQUENCY HINT UNTUK MENGHILANGKAN NOISE HUJAN PADA CITRA DIGITAL

Nama Mahasiswa / NRP	:	Merisa Anggi Anggraini / 5002221152
Departemen	:	Matematika FSAD -ITS
Dosen Pembimbing	:	Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T.

Abstrak

Citra digital yang diambil pada kondisi hujan sering mengalami penurunan kualitas visual akibat kemunculan *rain streaks* yang mengaburkan informasi visual dan menurunkan kinerja sistem pengenalan objek. Salah satu metode *Single Image Deraining* yang banyak digunakan untuk mengatasi permasalahan tersebut adalah *Rain Convolutional Dictionary Network* (RCDNet). Namun, RCDNet masih memiliki keterbatasan karena hanya memanfaatkan informasi lokal pada domain spasial sehingga kurang efektif dalam membedakan pola hujan dan tekstur asli latar belakang. Penelitian ini modifikasi arsitektur RCDNet pada bagian M-Net dengan mengintegrasi modul *FrequencyHint*. Modul ini memanfaatkan transformasi Fourier untuk mengekstraksi informasi pada domain frekuensi dan memberikan petunjuk frekuensi global yang membantu proses pemisahan karakteristik hujan dari objek asli. Selain itu, modul *FrequencyHint* menerapkan mekanisme *spectral gate bottleneck* untuk menyaring komponen frekuensi secara adaptif dengan tetap menjaga efisiensi model. Hasil eksperimen menunjukkan bahwa model RCDNet yang diintegrasikan dengan modul *FrequencyHint* berhasil melampaui performa model *baseline*. Secara spesifik, pada pengujian menggunakan benchmark dataset sekunder dengan model RCDNet yang diintegrasikan dengan *FrequencyHint*, model ini memberikan peningkatan PSNR sebesar 0,85% dB dan SSIM sebesar 0,08% pada dataset Rain100L (hujan ringan), serta peningkatan PSNR sebesar 1,89% dB dan SSIM sebesar 0,76% pada dataset Rain100H (hujan lebat). Pengujian pada dataset primer sebanyak 487 citra hujan nyata menunjukkan penurunan skor BRISQUE sebesar 13,82% tanpa mengurangi ketajaman detail gambar.

Kata kunci: *Single Image Deraining, Rain Convolutional Dictionary Network* (RCDNet)*, FrequencyHint,* transformasi Fourier*, rain streak removal*

ABSTRACT

RAIN CONVOLUTIONAL DICTIONARY NETWORK (RCDNET) WITH FREQUENCY HINT FOR RAIN NOISE REMOVAL IN DIGITAL IMAGES

Student Name / NRP	:	Merisa Anggi Anggraini / 5002221152
Departement	:	Mathematics SCIENTICS - ITS
Advisor	:	Dr. Dwi Ratna Sulistyaningrum, S.Si, M.T.

Abstract

Digital images captured under rainy conditions often suffer from degraded visual quality due to the presence of rain streaks, which obscure visual information and reduce the performance of object recognition systems. One of the widely adopted methods for addressing this problem is the Rain Convolutional Dictionary Network (RCDNet). However, RCDNet still has limitations because it primarily exploits local information in the spatial domain, making it less effective at distinguishing rain patterns from the original background textures. This study modifies the M-Net architecture of RCDNet by integrating a FrequencyHint module. The proposed module utilizes the Fourier Transform to extract frequency-domain information and provides global frequency cues that facilitate the separation of rain characteristics from the underlying scene content. Furthermore, the FrequencyHint module employs a spectral gate bottleneck mechanism to adaptively filter frequency components while maintaining computational efficiency. Experimental results demonstrate that the RCDNet model integrated with the FrequencyHint module consistently outperforms the baseline model. Specifically, on benchmark datasets, the proposed model achieves PSNR improvements of 0,85% and SSIM improvements of 0,08% on the Rain100L dataset (Light Rain Dataset), as well as PSNR improvements of 1,89% and SSIM improvements of 0,76% on the Rain100H dataset (Heavy Rain Dataset). Moreover, evaluation on a primary dataset consisting of 487 real-world rainy images shows a 13,82% reduction in the BRISQUE score without compromising image detail preservation.

Keywords: *Single Image Deraining, Rain Convolutional Dictionary Network* (RCDNet)*, FrequencyHint, Fourier Transform, Rain Streak Removal*

KATA PENGANTAR

Puji syukur kehadirat Allah SWT karena atas berkah, rahmat dan Ridho-Nya sehingga penulis dapat menyelesaikan tugas akhir dengan judul :

"RAIN CONVOLUTIONAL DICTIONARY NETWORK (RCDNET) DENGAN *FREQUENCY HINT* UNTUK MENGHILANGKAN NOISE HUJAN PADA CITRA DIGITAL"

sebagai salah satu persyaratan akademis dalam menyelesaikan Program Sarjana Departemen Matematika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember Surabaya. Tugas Akhir ini dapat diselesaikan dengan baik berkat kerja sama, bantuan, dan dukungan dari banyak pihak. Sehubungan dengan hal itu, penulis ingin mengucapkan terima kasih dan penghargaan kepada :

1. Kedua orang tua penulis yang senantiasa memberikan doa, kasih sayang, dukungan moral dan material yang tiada henti selama menempuh pendidikan.

2. Kepala Departemen Matematika, Fakultas Sains dan Analitika Data ITS, atas dukungan sarana prasarana dan kemudahan yang diberikan kepada penulis.

3. Ibu Dr. Dwi Ratna Sulistyaningrum, S.Si., M.T., selaku dosen pembimbing yang telah dengan sabar memberikan arahan, bimbingan, motivasi, dan masukan yang sangat berharga selama penyusunan Tugas Akhir.

4. Bapak Prof. Dr. Mahmud Yunus, M.Si., Bapak Dr. Budi Setiyono, S.Si., MT., dan Bapak Muhammad Yusuf Hakim Widianto, S.Si., M.Si., M.Sc., Ph.D., selaku dosen penguji yang telah memberikan masukan dan saran yang konstruktif demi penyempurnaan penelitian ini.

5. Seluruh dosen dan staf pengajar Departemen Matematika, Fakultas Sains dan Analitika Data ITS, atas ilmu, bimbingan, dan inspirasi yang telah diberikan selama masa perkuliahan.

Penulis menyadari bahwa tugas akhir ini masih jauh dari kesempurnaan. Oleh karena itu, penulis mengharapkan saran dan kritik dari pembaca. Akhir kata, semoga Tugas Akhir ini bermanfaat bagi semua pihak yang berkepentingan.

Surabaya, 29 Juli 2026

Merisa Anggi Anggraini

DAFTAR ISI

LEMBAR PENGESAHAN i

APPROVAL SHEET iv

PERNYATAAN ORISINALITAS v

STATEMENT OF ORIGINALITY vii

ABSTRAK ix

ABSTRACT xi

KATA PENGANTAR xiii

DAFTAR ISI xv

DAFTAR GAMBAR xvii

DAFTAR TABEL xix

DAFTAR SIMBOL xxi

BAB I PENDAHULUAN 1
- 1.1 Latar Belakang . . . 1
- 1.2 Rumusan Masalah . . . 3
- 1.3 Batasan Masalah . . . 3
- 1.4 Tujuan . . . 4
- 1.5 Manfaat . . . 4

BAB II TINJAUAN PUSTAKA 5
- 2.1 Penelitian Terdahulu . . . 5
- 2.2 *Computer vision* . . . 7
- 2.3 Citra Digital . . . 8
- 2.4 Noise pada Citra Digital . . . 10
- 2.5 Noise Hujan (*Rain Noise*) pada Citra Digital . . . 13
  - 2.5.1 Karakteristik Spektral Noise Hujan . . . 14
- 2.6 Metode Penghilangan Noise Hujan pada Citra Tunggal . . . 15
  - 2.6.1 Metode Konvensional Berbasis Filter dan Prior pada Citra Tunggal 16
  - 2.6.2 Metode deep learning *End-to-End* untuk *Single Image* deraining . 17
- 2.7 Pendekatan *Model-Driven* untuk deraining (Penghilangan Noise Hujan) 17
  - 2.7.1 Sparse Representation dan Dictionary Learning . . . 17
  - 2.7.2 Proximal Gradient dan Optimisasi Iteratif . . . 18
  - 2.7.3 *Deep unfolding* sebagai Jembatan Optimisasi dan *deep learning* . . 19
- 2.8 *Rain Convolutional Dictionary Network* (RCDNet) . . . 19
  - 2.8.1 Model Degradasi Citra Hujan Berbasis Convolutional Dictionary . 20
  - 2.8.2 Representasi Rain Streaks sebagai Konvolusi Kernel dan Rain Map 20
  - 2.8.3 Formulasi Optimisasi dan *deep unfolding* pada RCDNet . . . 21
  - 2.8.4 Arsitektur *deep unfolding*: M-net dan B-net . . . 22
- 2.9 Evaluasi Metrik . . . 23

2.9.1 Peak Signal-to-Noise Ratio (PSNR) 24
2.9.2 Structural Similarity Index Measure (SSIM) 24
2.9.3 *Blind/Referenceless Image Spatial Quality Evaluator* (BRISQUE) 24
BAB III METODOLOGI 29
3.1 Tahapan Penelitian 29
BAB IV PERANCANGAN DAN IMPLEMENTASI 35
4.1 Perancangan 35
4.1.1 Pengambilan Data 35
4.1.2 Pra-pemrosesan Data 38
4.1.3 Pembentukan Model 40
4.1.4 Perancangan Pelatihan Model 46
4.1.5 Perancangan Evaluasi 49
4.1.6 Perancangan Pengujian 52
4.2 Implementasi 52
4.2.1 Ruang Lingkup Perangkat Lunak 53
4.2.2 Implementasi Arsitektur Model 54
4.2.3 Implementasi Pelatihan 55
4.2.4 Implementasi Evaluasi Dataset Sintetik 56
4.2.5 Implementasi Evaluasi Dataset Primer 57
BAB V HASIL DAN PEMBAHASAN 59
5.1 Hasil Pelatihan dan Evaluasi Model 59
5.1.1 Hasil Pelatihan Skenario 1: RCDNet-FH v1 59
5.1.2 Hasil Pelatihan Skenario 2: RCDNet-FH v2 60
5.2 Analisis Model Terbaik 64
5.3 Hasil Pengujian 64
5.3.1 Hasil Pengujian Skenario 1 64
5.3.2 Hasil Pengujian Skenario 2 68
5.4 Pembahasan 71
BAB VI KESIMPULAN DAN SARAN 75
6.1 Kesimpulan 75
6.2 Saran 75
DAFTAR PUSTAKA 77
UCAPAN TERIMA KASIH 81
BIODATA PENULIS 83

DAFTAR GAMBAR

Gambar 2.1 Sistem koordinat dan representasi piksel pada citra digital. Sumber gambar: Gonzalez and Woods (2020) 9
Gambar 2.2 Representasi citra digital sebagai (a) fungsi dua dimensi, (b) tampilan visual citra, dan (c) matriks nilai intensitas. Sumber gambar: Gonzalez and Woods (2020) 10
Gambar 2.3 *Gaussian noise* Sumber gambar: Akbar and Verma (2024) 11
Gambar 2.4 *Salt and pepper noise* Sumber gambar: Akbar and Verma (2024) . . . 11
Gambar 2.5 *Speckle noise* Sumber gambar: Akbar and Verma (2024) 12
Gambar 2.6 *Rain noise* Sumber gambar: Dokumentasi penulis (2026) 12
Gambar 2.7 *Rain noise* Sumber gambar: Dokumentasi penulis (2026) 13
Gambar 2.8 Model RCDNet untuk *rain layer* Sumber gambar: H. Wang, Xie, and Zhao (2020) 21
Gambar 2.9 Arsitektur model RCDNet Sumber gambar: H. Wang, Xie, and Zhao (2020) 23

Gambar 3.1 Tahapan Penelitian 30

Gambar 4.1 Contoh dataset sekunder (Rain100L dan Rain100H) 36
Gambar 4.2 Contoh dataset sintetik 37
Gambar 4.3 Contoh dataset primer 37
Gambar 4.4 Arsitektur Mnet dengan *FrequencyHint* 43

Gambar 5.1 Kurva *train loss* per-*epoch* model RCDNet *Baseline* pada dataset Rain100L. 60
Gambar 5.2 Kurva *train loss* per-*epoch* model RCDNet *Baseline* pada dataset Rain100H. 60
Gambar 5.3 Perbandingan nilai PSNR. 61
Gambar 5.4 Perbandingan nilai SSIM. 62
Gambar 5.5 Perbandingan hasil *deraining* pada sampel Rain100H (*norain-40*). 62
Gambar 5.6 Perbandingan performa *Baseline*, model spesialis, dan model generalis RCDNet-FH v2 Mixed pada Rain100L dan Rain100H. . . 65
Gambar 5.7 Perbandingan PSNR model spesialis dan model generalis (*Mixed*) pada Rain100L dan Rain100H. Garis putus-putus menunjukkan nilai PSNR *Baseline*. 66
Gambar 5.8 Grid sampel hasil *deraining* model RCDNet-FH v2 Mixed pada Rain100H. 67
Gambar 5.9 Grid sampel hasil *deraining* model RCDNet-FH v2 Mixed pada Rain100L. 67
Gambar 5.10 Perbandingan PSNR per kategori intensitas hujan pada dataset sintetik tambahan untuk model yang dilatih pada Rain100L, Rain100H, dan Mixed. 69

Gambar 5.11 Evaluasi *no-reference* pada dataset primer (487 foto). Kiri: skor BRISQUE sebelum dan sesudah *deraining*. Kanan: Laplacian Variance sebagai indikator ketajaman. 70
Gambar 5.12 Contoh hasil *deraining* pada beberapa sampel foto data primer. Kiri: citra masukan berhujan; kanan: citra keluaran setelah *deraining*. 71

DAFTAR TABEL

Tabel 2.1 Ringkasan Penelitian Terdahulu 5
Tabel 2.2 Ringkasan Fitur yang Diekstrak dalam BRISQUE 27

Tabel 4.1 Ringkasan Dataset Penelitian 35
Tabel 4.2 Rincian Dataset Sekunder 36
Tabel 4.3 Perbandingan Arsitektur Mnet dan Bnet 45
Tabel 4.4 Varian Model yang Dilatih 47
Tabel 4.5 Dataset Pelatihan Seluruh Eksperimen 47
Tabel 4.6 Konfigurasi *Hyperparameter* Pelatihan 48
Tabel 4.7 Rancangan Skenario 1: Pelatihan RCDNet-FH v1 48
Tabel 4.8 Rancangan Skenario 2: Pelatihan RCDNet-FH v2 49
Tabel 4.9 Ringkasan Penggunaan Dataset 49
Tabel 4.10 Spesifikasi Perangkat yang Digunakan 53
Tabel 4.11 Kebutuhan *Library* Python yang Digunakan 53

Tabel 5.1 Hasil Evaluasi Model RCDNet *Baseline* (channel Y, YCbCr) 59
Tabel 5.2 Eksperimen Utama ($S = 17$) 61
Tabel 5.3 Hasil *Ablation Study* terhadap Jumlah *Stage* (S) pada RCDNet-FH v2 63
Tabel 5.4 Evaluasi Model pada Dataset Campuran dan Generalisasi 63
Tabel 5.5 Perbandingan Model Spesialis dan Model Generalis *Mixed* (channel Y, YCbCr) 64
Tabel 5.6 Hasil Pengujian pada Dataset Sintetik Tambahan (1.500 Gambar) . . 68
Tabel 5.7 Hasil Evaluasi *No-Reference* pada Data Primer (487 Foto) 69

DAFTAR SIMBOL

Variabel Citra dan Model RCD

B^*	:	*Ground truth* latar belakang
$B^{(s)}$	:	Estimasi latar belakang pada *stage* ke-s
$B^{(0)}$	:	Estimasi latar belakang inisialisasi (Bnet_0)
B_{mid}	:	Estimasi latar belakang sementara sebelum Bnet
$M^{(s)}$	:	Estimasi *rain map* pada *stage* ke-s
$R^{(s)}$	:	Estimasi *rain layer* pada *stage* ke-s ($R^{(s)} = C * M^{(s)}$)
R^*	:	*Ground truth rain layer* ($R^* = O - B^*$)
$\hat{R}^{(s)}$	:	Estimasi hujan sementara ($= O - B^{(s-1)}$)
C	:	*Rain kernel* / kamus konvolusional hujan
$Z^{(s)}$	:	Variabel dual pada *stage* ke-s

Parameter Arsitektur dan PGD

n_M	:	Jumlah *channel rain map* (default 32)
n_Z	:	Jumlah *channel* variabel dual (default 32)
η_M	:	*Step size* pembaruan *rain map* (dapat dipelajari)
η_B	:	*Step size* pembaruan *background* (dapat dipelajari)
τ	:	Parameter *threshold soft-thresholding*
ε	:	Gradien *rain map*: $\varepsilon = \eta_M \cdot C^T * (R^{(s-1)} - \hat{R}^{(s)})$

FrequencyHintBlock (FHB)

$\mathcal{F}$	:	Operator rFFT2 (transformasi Fourier diskret 2D riil)
$\mathcal{F}^{-1}$	:	Operator irFFT2 (transformasi Fourier invers)
$g(\cdot)$	:	Fungsi *spectral gate bottleneck*
$\mathbf{x}$, $\mathbf{x}_{\text{out}}$	:	Fitur masukan dan keluaran FHB
proj	:	Proyeksi 1×1 (bobot diinisialisasi nol)

Fungsi *Loss*

$\mathcal{L}$	:	Fungsi *loss* total (*multi-stage supervision*)
$\mathcal{L}_{B_0}$	:	*Loss* background inisialisasi (bobot 0,1)
$\mathcal{L}_{B_s}$	:	*Loss* background *stage* ke-s (bobot 0,1)
$\mathcal{L}_B$	:	*Loss* background keluaran akhir (bobot 1,0)
$\mathcal{L}_{R_s}$	:	*Loss rain layer stage* ke-s (bobot 0,1)
$\mathcal{L}_R$	:	*Loss rain layer* keluaran akhir (bobot 0,9)
$\|\cdot\|_F$	:	Norma Frobenius

Metrik Evaluasi

MAX	:	Nilai piksel maksimum (255 untuk citra 8-*bit*)
MSE	:	*Mean Squared Error* antara citra hasil dan *ground truth*
μ_x, μ_y	:	Rata-rata luminansi citra $\mathbf{x}$ dan $\mathbf{y}$
σ_x^2, σ_y^2	:	Variansi citra $\mathbf{x}$ dan $\mathbf{y}$
σ_{xy}	:	Kovarians antara citra $\mathbf{x}$ dan $\mathbf{y}$
c_1, c_2	:	Konstanta stabilisasi pada persamaan SSIM

Notasi Umum

lr	:	*Learning rate* awal optimizer Adam
γ	:	Faktor penurunan *learning rate*
$*$	:	Operasi konvolusi

BAB I
PENDAHULUAN

1.1 Latar Belakang

Citra digital merupakan salah satu bentuk data visual yang paling banyak digunakan dalam berbagai bidang seperti sistem pengawasan (*surveillance system*), sistem transportasi cerdas, pengenalan objek, hingga pemetaan lingkungan. Citra digital sendiri juga memiliki peranan penting dalam berbagai bidang aplikasi, seperti pengawasan berbasis video, sistem kendaraan otonom, penginderaan jauh, dan analisis citra lingkungan. Salah satu permasalahan utama dalam akuisisi citra di lingkungan nyata adalah adanya *noise* atau derau. *Noise* pada citra dapat berasal dari berbagai sumber, baik dari sensor itu sendiri maupun faktor eksternal seperti cuaca yang buruk. Pada salah satu faktor eksternal seperti hujan menyebabkan munculnya *Noise* hujan (*rain noise*) pada citra yang dihasilkan oleh kamera outdoor berupa video yang menyebabkan munculnya garis-garis tipis (*rain streaks*) yang mengganggu informasi visual penting, sehingga mengurangi akurasi sistem visi komputer dalam proses deteksi dan pengenalan objek (Mao, Sun, Chen, & Yu, 2025). Namun secara komputasi video dapat dipandang sebagai rangkaian frame, di mana setiap frame merupakan *single image*. Dilihat dari adanya permasalahan noise hujan yang mempengaruhi informasi visual maka dibutuhkan proses *deraining* agar citra yang tepengaruhi oleh garis-garis tipis (*rain streks*) dapat menjadi citra bersih. Walaupun proses *deraining* berbasis video dapat memanfaatkan informasi antar-frame, pada banyak skenario nyata pemrosesan sering dilakukan pada *snapshot/keyframe* atau ketika informasi temporal tidak stabil sehingga pendekatan yang bekerja hanya dari satu frame tetap sangat relevan. Oleh karena itu penelitian ini diarahkan pada *Single Image Deraining* (SID), yaitu pemulihan citra bersih yang dilakukan hanya dari satu citra hujan sebagai input. Pendekatan ini krusial karena pada kondisi operasional di dunia nyata tidak selalu tersedia informasi tambahan seperti video atau beberapa frame, sehingga dibutuhkan metode yang mampu meningkatkan kualitas citra agar sistem visi tetap *robust* di lingkungan nyata (Swaminathan & Korupolu, 2023).

Evolusi metode SID telah mengalami pergeseran paradigma dari pendekatan berbasis filter dan optimasi tradisional menuju metode berbasis *Deep Learning* (DL). Pendekatan tradisional, seperti *Sparse Coding* dan *Gaussian Mixture Models* (GMM), mengandalkan prior statistik buatan tangan yang sering kali terbatas kemampuannya dalam menangani variabilitas pola hujan yang kompleks. Sebaliknya, metode *Deep Learning* (DL) murni menawarkan kinerja superior melalui pembelajaran *end-to-end* pada dataset skala besar, namun sering dikritik sebagai "*blackbox*" yang kurang memiliki landasan teoretis yang jelas (H. Wang, Xie, & Zhao, 2020). Untuk mengatasi keterbatasan masing-masing pendekatan, muncul penelitian yang menggabungkan keunggulan metode tradisional yang lebih terstruktur dan interpretabel dengan kemampuan representasi kuat dari *Deep Learning*. Dalam penelitian ini, *Rain Convolutional Dictionary Network* (RCDNet) diperkenalkan sebagai solusi model-driven mutakhir yang membangun arsitektur jaringan saraf dengan membuka (*unfolding*) algoritma optimasi untuk model *convolutional dictionary learning* (H. Wang, Xie, & Zhao, 2020). Pendekatan ini memberikan transparansi dan interpretabilitas yang tinggi, di mana setiap lapisan jaringan memiliki

korespondensi fisik dengan proses pembentukan hujan.

Meskipun RCDNet menunjukkan kinerja yang unggul dibandingkan metode sebelumnya, arsitekturnya masih memiliki keterbatasan fundamental dalam pemanfaatan informasi global. Sub-jaringan M-Net dalam RCDNet, yang bertugas mengestimasi lokasi peta hujan (*rain maps*), sangat bergantung pada operasi konvolusi spasial yang memiliki *receptive field* lokal (H. Wang & Patel, 2022). Keterbatasan ini menyebabkan ambiguitas dalam membedakan antara *rain streaks* dan tekstur latar belakang yang memiliki karakteristik frekuensi tinggi serupa, seperti pola garis pada bangunan atau pagar. Akibatnya, RCDNet sering kali melakukan kesalahan lokalisasi, baik berupa penghapusan detail tekstur yang keliru dianggap sebagai hujan (*over-smoothing*) atau kegagalan mendeteksi hujan yang berbaur dengan latar belakang kompleks, terutama karena absennya mekanisme yang mengeksploitasi pola spektral global yang inheren pada struktur hujan (Zheng, Yao, Ying, & Wu, 2025).

Untuk mengatasi keterbatasan tersebut, diperlukan mekanisme yang mampu melengkapi informasi spasial lokal dengan informasi global sehingga proses identifikasi *rain streaks* menjadi lebih akurat. Salah satu representasi yang mampu menyediakan informasi global adalah domain frekuensi. Berbeda dengan domain spasial yang hanya mengamati hubungan antar-piksel pada wilayah lokal, transformasi Fourier merepresentasikan citra ke dalam komponen frekuensi sehingga pola struktural yang tersebar pada seluruh citra dapat diamati secara bersamaan. Karakteristik ini menjadikan domain frekuensi lebih efektif dalam menangkap pola hujan yang memiliki sifat berulang (*repetitive*), berorientasi pada arah tertentu (*directional*), serta memiliki distribusi energi spektral yang berbeda dibandingkan tekstur alami pada latar belakang (Gao, Jiang, Zhang, & Deng, 2025).

Beberapa penelitian terbaru menunjukkan bahwa pemanfaatan informasi frekuensi mampu meningkatkan berbagai tugas restorasi citra, seperti *image denoising*, *deblurring*, *super-resolution*, maupun *image deraining*. Informasi frekuensi dapat memisahkan komponen berfrekuensi tinggi yang didominasi oleh pola degradasi dari struktur utama citra sehingga jaringan memperoleh petunjuk tambahan yang tidak dapat diperoleh hanya melalui konvolusi spasial. Pada kasus hujan, *rain streaks* umumnya menghasilkan distribusi energi yang lebih terarah pada spektrum frekuensi, sedangkan tekstur latar belakang memiliki distribusi yang lebih kompleks dan menyebar. Perbedaan karakteristik spektral tersebut dapat dimanfaatkan sebagai informasi pendukung untuk membantu jaringan membedakan pola hujan dari detail objek sebenarnya (Zheng et al., 2025).

Meskipun demikian, pemanfaatan domain frekuensi secara langsung belum tentu memberikan peningkatan kinerja yang optimal. Transformasi Fourier menghasilkan representasi global yang sangat kaya, namun tidak seluruh komponen frekuensi berkaitan dengan keberadaan hujan. Apabila seluruh informasi frekuensi dimanfaatkan secara langsung, jaringan berpotensi mempelajari komponen yang tidak relevan sehingga proses estimasi menjadi kurang efektif. Oleh karena itu, diperlukan suatu mekanisme yang mampu memilih informasi frekuensi yang benar-benar berkaitan dengan karakteristik hujan sekaligus mengintegrasikannya secara adaptif ke dalam fitur spasial.

Salah satu pendekatan yang memenuhi kebutuhan tersebut adalah *Frequency Hint*. Berbeda dengan pendekatan yang hanya menambahkan transformasi Fourier sebagai cabang pemrosesan tambahan, *Frequency Hint* memanfaatkan representasi frekuensi sebagai informasi pembimbing (*guidance*) untuk memodulasi fitur spasial. Informasi global yang diperoleh dari domain frekuensi digunakan untuk memperkuat respons

jaringan terhadap pola yang menyerupai *rain streaks* dan secara bersamaan menekan aktivasi pada tekstur latar belakang yang memiliki karakteristik spasial serupa. Dengan demikian, fitur spasial yang dihasilkan menjadi lebih diskriminatif tanpa menghilangkan kemampuan RCDNet dalam melakukan estimasi berbasis model.

Pemilihan *Frequency Hint* juga didasarkan pada kesesuaiannya dengan arsitektur RCDNet. RCDNet merupakan jaringan *model-driven* yang mempertahankan interpretabilitas melalui proses *algorithm unfolding*. Oleh karena itu, modifikasi yang dilakukan harus tetap mempertahankan struktur utama jaringan tanpa mengubah mekanisme optimasi yang telah dimiliki. Integrasi *Frequency Hint* pada M-Net dipilih karena modul ini bertanggung jawab mengestimasi peta hujan (*rain maps*), sehingga informasi frekuensi dapat dimanfaatkan secara langsung untuk meningkatkan kualitas lokalisasi hujan tanpa mengganggu interpretabilitas keseluruhan model. Pendekatan ini diharapkan mampu mengatasi keterbatasan receptive field lokal pada konvolusi sekaligus mempertahankan keunggulan RCDNet sebagai metode *model-driven* yang memiliki landasan teoritis yang kuat (D. Li, Liu, Fu, Xu, & Zha, 2024).

Berdasarkan analisis permasalahan yang telah dilakukan, penelitian ini telah mengembangkan model RCDNet yang ditingkatkan dengan menyisipkan fitur *FrequencyHint* pada modul M-Net. Pengembangan tersebut dilakukan dengan menambahkan blok Transformasi Fourier serta mekanisme *gating* berbasis spektral pada jalur estimasi peta hujan. Fitur *FrequencyHint* berfungsi untuk memodulasi fitur spasial menggunakan informasi global dari domain frekuensi, sehingga mampu memperkuat respons jaringan terhadap pola hujan yang valid dan menekan respons terhadap tekstur latar belakang yang tidak relevan. Melalui pendekatan ini, model yang dikembangkan menghasilkan lokalisasi hujan yang lebih akurat, mempertahankan detail citra (*detail preservation*), serta meningkatkan performa pemulihan citra yang ditunjukkan melalui peningkatan metrik PSNR dan SSIM dibandingkan dengan RCDNet standar, sehingga memberikan kontribusi terhadap pengembangan sistem visi komputer yang lebih andal pada kondisi cuaca buruk (D. Li et al., 2024).

1.2 Rumusan Masalah

Rumusan masalah yang diangkat dalam penelitian ini adalah sebagai berikut:

1. Bagaimana menerapkan RCDNet berbasis Frequency Hint untuk menghilangkan noise hujan pada citra digital?

2. Bagaimana kinerja RCDNet berbasis Frequency Hint untuk menghilangkan noise hujan pada citra digital?

1.3 Batasan Masalah

Fokus Tugas Akhir ini dibatasi pada masalah berikut:

1. Penelitian dibatasi pada *Single Image Deraining*, yaitu mengestimasi citra bersih dari satu citra yang terpengaruh hujan tanpa menggunakan informasi temporal atau video.

2. Fokus gangguan yang menjadi fokus penelitian ini adalah *rain streaks* (garis-garis hujan) pada citra.

3. Model dasar yang dijadikan acuan adalah RCDNet dengan implementasi dari repositori RCDNet_simple (github.com/hongwang01/RCDNet_simple). Modifikasi

utama hanya dilakukan pada M-Net melalui penyisipan *FrequencyHint* dan komponen lain dipertahankan.

4. Dataset yang digunakan dalam penelitian ini adalah *single image* yang mengandung noise hujan yang merupakan data primer, data sekunder, serta data sintetik.

5. Evaluasi kuantitatif dengan ground-truth menggunakan PSNR dan SSIM pada channel Y YCbCr mengikuti penelitian wang2020single. Evaluasi dataset primer menggunakan BRISQUE (*no-reference metric*).

1.4 Tujuan

Tujuan dari penelitian Tugas Akhir ini antara lain:

1. Menerapkan RCDNet berbasis Frequency Hint untuk menghilangkan noise hujan pada citra digital.

2. Menganalisis kinerja RCDNet berbasis Frequency Hint untuk menghilangkan noise hujan pada citra digital.

1.5 Manfaat

Manfaat yang diharapkan dari penelitian Tugas Akhir ini antara lain:

1. Memberikan kontribusi pada pengembangan metode *single image deraining* berbasis RCDNet dengan integrasi *Frequency Hint* pada M-Net untuk meningkatkan kemampuan pemisahan *rain streaks* dan tekstur latar belakang, serta memperkaya kajian restorasi citra yang lebih robust terhadap cuaca buruk.

2. Mendukung peningkatan kualitas visual pada kamera outdoor seperti, CCTV atau pemantauan lalu lintas saat hujan sehingga membantu sistem pengawasan dan layanan publik bekerja lebih andal dalam kondisi cuaca buruk.

BAB II
TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Penelitian terdahulu menjadi landasan penting dalam perumusan penelitian ini. Kajian difokuskan pada studi *single image deraining*, khususnya pendekatan *deep learning* model-driven seperti RCDNet, serta pemanfaatan informasi domain frekuensi untuk meningkatkan pemisahan *rain streaks* dari latar belakang. Ringkasan penelitian terdahulu disajikan pada Tabel 2.1.

Tabel 2.1 Ringkasan Penelitian Terdahulu

Penulis	**Judul**	**Metode**	**Dataset**	**Hasil**
(H. Wang, Xie, & Zhao, 2020)	*A Model-driven Deep Neural Network for Single Image Rain Removal* (RCDNet)	Model-driven deep unfolding dari model *Rain Convolutional Dictionary* (RCD) dengan skema iteratif proximal gradient descent; arsitektur terdiri dari M-Net (estimasi rain map) dan B-Net (rekonstruksi latar belakang).	SPA-Data (pasangan rainy/clean) dan Internet-Data (real-world tanpa ground-truth).	Mencapai performa unggul pada data nyata; pada SPA-Data, PSNR 41,47 dB dan SSIM 0,9834. Keterbatasan: komputasi relatif berat karena proses iteratif dan eksploitasi informasi frekuensi global belum optimal untuk hujan kompleks.
(Jiang, Jiang, Liu, Xu, & Ma, 2024)	*FMRNet: Image* deraining *via Frequency Mutual Revision*	Mengeksplorasi korelasi komponen *rain-free* dan *rain residue* pada domain frekuensi melalui mekanisme *mutual revision* (revisi silang) untuk mengurangi noise hujan sambil mempertahankan tekstur latar belakang.	Beberapa dataset sintetis & nyata (termasuk Rain100L).	Memberikan peningkatan signifikan; dilaporkan melampaui metode SOTA ELFormer sebesar +1,14 dB (PSNR) pada Rain100L dengan biaya komputasi yang sebanding.

Penulis	**Judul**	**Metode**	**Dataset**	**Hasil**
(Gao et al., 2025)	*Frequency-Aware* deraining *with Transformer* (FADformer)	Transformer hierarkis yang menyeimbangkan pemodelan global–lokal melalui *Fused Fourier Convolution Mixer* (FFCM) dan *Prior-Gated Feed-forward Network* (PGFN); ditambah *frequency-domain contrastive regularization* (FCR) untuk memperkuat pemisahan karakteristik hujan di domain frekuensi.	Rain200L/H, DDN-Data, DID-Data (sintetis); SPA-Data, Internet-Data, RE-RAIN (real-world).	Menunjukkan trade-off performa kompleksitas yang baik; pada SPA-Data PSNR dilaporkan >49 dB dan meningkat sekitar +0,67 dB dibanding metode SOTA sebelumnya.
(Sharma, Basavaraju, & Sur, 2021)	deep learning-*based image de-raining using discrete Fourier transformation*	*deraining* pada domain frekuensi dengan menjadikan koefisien DFT (komponen real dan imajiner) sebagai input CNN untuk memprediksi sinyal noise/rain streak, kemudian dilakukan rekonstruksi kembali ke domain spasial.	Dataset sintetis publik (mis. Fu et al., 2017; Yang et al., 2017; Yeh et al., 2015).	Hasil dilaporkan sebanding dengan metode SOTA pada domain spasial, serta menunjukkan potensi pemrosesan fitur global melalui representasi Fourier.
(D. Li et al., 2024)	*FourierMamba: Fourier Learning Integration with State Space Models for Image* deraining	Mengintegrasikan transformasi Fourier dengan arsitektur *State Space Model* (Mamba) melalui dua modul: *FourierSS* untuk pemrosesan amplitudo spektrum di sepanjang dimensi kanal, dan *FourierCS* untuk konversi representasi antara domain frekuensi dan spasial; dilatih dengan *frequency channel loss* untuk konsistensi spektral.	Rain100L, Rain100H, DID-Data, DDN-Data, dan dataset nyata (SPA-Data).	Mencapai performa kompetitif pada seluruh benchmark yang diuji; menunjukkan bahwa integrasi Fourier ke dalam SSM menghasilkan pemodelan dependensi global–frekuensi yang lebih efektif dibanding pendekatan CNN murni maupun transformer konvensional.

Berdasarkan literatur di atas, penelitian yang sedang dikerjakan penulis diarahkan untuk menutup celah yang belum ditangani secara optimal oleh metode terdahulu. Pada penelitian RCDNet (H. Wang, Xie, & Zhao, 2020) menonjol dari sisi model-driven dan interpretabilitas, tetapi masih cenderung berat secara komputasi serta belum kuat mengeksploitasi informasi frekuensi global. Penelitian FMRNet (Jiang et al., 2024) dan

penelitian FADformer (Gao et al., 2025) memang sudah membawa *deraining* ke domain frekuensi, namun keduanya tetap bergantung pada rancangan transformasi tertentu, misalnya *wavelet* atau arsitektur transformer yang relatif berat serta membutuhkan strategi pelatihan tambahan, seperti *contrastive regularization* dan pemilihan *negative samples*. Sementara itu, pendekatan DFT-based (Sharma et al., 2021) memanfaatkan representasi Fourier secara langsung, tetapi lebih berfokus pada pemodelan koefisien transformasi dan rekonstruksi, sehingga ruang pengembangan masih terbuka untuk merancang metode yang lebih adaptif, ringan, dan tetap mampu mempertahankan detail struktur citra. Oleh karena itu, pembeda utama penelitian ini adalah menekankan pengembangan metode *deraining* menggunakan RCDNet yang berbasis *frequencyhint* yang lebih sesuai dengan tujuan dan batasan penelitian seperti, hanya berfokus pada *rain streaks*, serta mengintegrasikan informasi frekuensi secara lebih terarah tanpa ketergantungan berlebih pada arsitektur berat, sehingga diharapkan dapat meningkatkan robustnes pada kondisi hujan kompleks dan lebih siap diterapkan pada skenario nyata dibanding pendekatan-pendekatan pada literatur tersebut.

2.2 *Computer vision*

Computer vision atau visi komputer merupakan cabang ilmu kecerdasan buatan yang memfokuskan diri pada pengembangan sistem komputasi yang mampu memperoleh, memproses, dan menginterpretasikan informasi visual dari dunia nyata secara otomatis (Szeliski, 2022). Secara fundamental, tujuan dari *computer vision* adalah memberikan kapabilitas kepada mesin untuk "melihat" dan "memahami" konten visual layaknya sistem penglihatan manusia, mencakup pengenalan objek, pemahaman adegan, hingga pengambilan keputusan berbasis citra (Voulodimos, Doulamis, Doulamis, & Protopapadakis, 2018). Perkembangan *computer vision* modern tidak dapat dilepaskan dari kemajuan dalam bidang deep learning, khususnya sejak diperkenalkannya arsitektur *Convolutional Neural Network* (CNN) oleh Krizhevsky, Sutskever, and Hinton (2012). Arsitektur ini memungkinkan ekstraksi fitur secara hierarkis dan otomatis langsung dari data piksel mentah, sehingga menjadi landasan dari sebagian besar sistem visi komputer mutakhir (LeCun, Bengio, & Hinton, 2015). Sistem *computer vision* secara umum beroperasi melalui tiga tahapan utama: (1) akuisisi citra digital dari sensor atau kamera, (2) ekstraksi dan pembelajaran representasi fitur visual, serta (3) interpretasi atau keputusan berbasis fitur tersebut (Voulodimos et al., 2018).

Cakupan aplikasi *computer vision* sangat luas dan terus berkembang. Beberapa domain aplikasi yang paling relevan meliputi deteksi dan pengenalan objek, segmentasi citra, pemantauan dan pengawasan (*video surveillance*), sistem kendaraan otonom, serta penginderaan jauh (*remote sensing*). Pada domain deteksi objek, sistem visi komputer telah berkembang dari pendekatan berbasis fitur tradisional seperti *Histograms of Oriented Gradients* (HOG) hingga arsitektur deep learning modern seperti YOLO, Faster R-CNN, dan DETR yang mampu mendeteksi berbagai kategori objek secara akurat dan *real-time* (Zou, Chen, Shi, Guo, & Ye, 2023). Salah satu tantangan utama sistem *computer vision* yang beroperasi di lingkungan nyata (*real-world*) adalah kerentanannya terhadap degradasi kualitas citra yang disebabkan oleh kondisi lingkungan tidak ideal. Faktor-faktor seperti pencahayaan rendah, kabut, salju, dan hujan dapat menyebabkan penurunan signifikan pada kualitas citra yang diperoleh dari kamera *outdoor* (B. Li et al., 2022). Degradasi ini berdampak langsung terhadap performa model-model visi komputer, karena fitur visual yang dibutuhkan untuk proses deteksi, klasifikasi, maupun segmentasi menjadi terganggu atau tersembunyi oleh artefak visual yang ditimbulkan oleh gangguan

cuaca tersebut.

Secara khusus, hujan merupakan salah satu bentuk gangguan cuaca yang paling umum dijumpai dan paling merusak kinerja sistem *computer vision*. Tetesan air hujan yang bergerak cepat di depan lensa kamera menghasilkan garis-garis tipis (*rain streaks*) pada citra yang bersifat semiopak, menutupi detail latar belakang, dan mempersulit proses analisis visual (Mao et al., 2025). Hal ini berimbas langsung pada penurunan akurasi deteksi objek, segmentasi, dan sistem klasifikasi yang diterapkan pada citra atau video dari lingkungan *outdoor* (H. Wang, Xie, Zhao, & Meng, 2020). Oleh karena itu, peningkatan kualitas citra melalui proses pemulihan (*image restoration*) khususnya penghilangan *noise* hujan atau deraining menjadi tahapan praproses (*preprocessing*) yang sangat penting agar sistem *computer vision* tetap dapat berfungsi secara andal dalam kondisi cuaca buruk. Dalam konteks penelitian ini, pengembangan metode *single image* deraining berbasis RCDNet dengan *frequency hint* ditujukan sebagai fondasi peningkatan robustisitas sistem visi komputer pada skenario pengawasan dan pemantauan lalu lintas di lingkungan nyata.

2.3 Citra Digital

Citra digital merupakan representasi suatu objek atau pemandangan dalam bentuk data diskrit yang tersusun atas sekumpulan piksel (*picture element*), di mana setiap piksel menyimpan informasi mengenai intensitas cahaya atau komponen warna tertentu (Mao et al., 2025). Berbeda dengan citra kontinu, citra digital diperoleh melalui proses *sampling* dan kuantisasi sehingga koordinat maupun nilai intensitasnya bersifat diskrit (Gonzalez & Woods, 2020).

Secara matematis, citra digital dinyatakan sebagai suatu fungsi dua dimensi yang memetakan setiap koordinat piksel ke suatu nilai intensitas. Fungsi tersebut didefinisikan sebagai

$$f : \{0, 1, \ldots, M-1\} \times \{0, 1, \ldots, N-1\} \to \mathbb{R}, \tag{2.1}$$

dengan M menyatakan jumlah baris citra dan N menyatakan jumlah kolom citra. Domain fungsi menunjukkan seluruh koordinat piksel pada citra, sedangkan kodomain menyatakan himpunan nilai intensitas yang dimiliki setiap piksel. Dengan demikian, untuk setiap koordinat (x, y) terdapat suatu nilai intensitas $f(x, y)$ yang merepresentasikan tingkat kecerahan atau informasi warna pada piksel tersebut.

Berdasarkan definisi fungsi pada Persamaan (2.1), citra digital dapat direpresentasikan dalam beberapa notasi yang ekuivalen sebagai

$$F = (f(i, j))_{M \times N}, \tag{2.2}$$

dengan

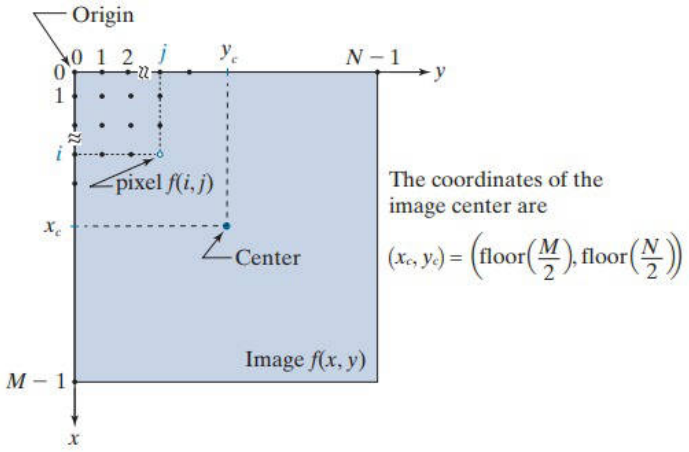
$$f_{ij} = f(i, j) = f(x, y), \tag{2.3}$$

dengan i dan j merupakan indeks baris dan kolom pada matriks citra. Persamaan (2.2) menunjukkan bahwa citra digital merupakan kumpulan nilai intensitas yang disusun ke dalam matriks berukuran $M \times N$. Oleh karena itu, representasi eksplisit citra digital dapat dituliskan sebagai

$$F = \begin{bmatrix} f(0,0) & f(0,1) & \cdots & f(0,N-1) \\ f(1,0) & f(1,1) & \cdots & f(1,N-1) \\ \vdots & \vdots & \ddots & \vdots \\ f(M-1,0) & f(M-1,1) & \cdots & f(M-1,N-1) \end{bmatrix}. \tag{2.4}$$

Setiap elemen matriks pada Persamaan (2.4) merepresentasikan nilai intensitas sebuah piksel pada koordinat tertentu. Dengan demikian, keseluruhan informasi visual suatu citra direpresentasikan sebagai kumpulan nilai numerik yang selanjutnya dapat diproses menggunakan berbagai operasi matematika maupun algoritma pengolahan citra digital.

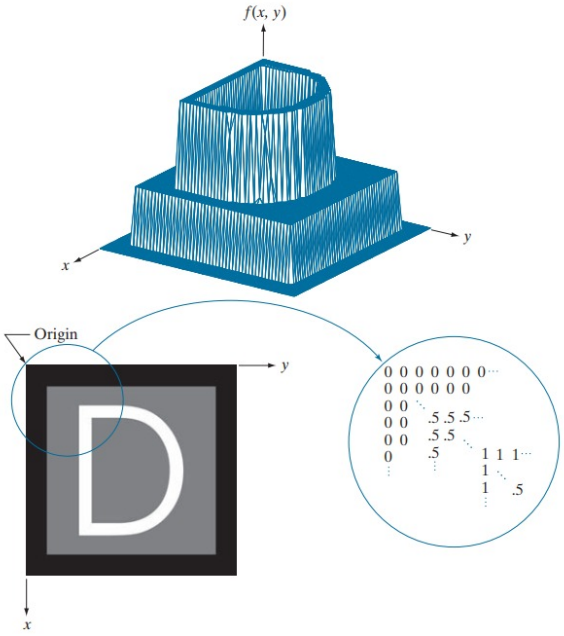
Hubungan antara koordinat spasial citra dengan posisi piksel pada matriks ditunjukkan pada Gambar 2.1. Titik asal (*origin*) berada pada sudut kiri atas citra sehingga indeks baris bertambah ke arah bawah dan indeks kolom bertambah ke arah kanan. Dengan demikian, setiap koordinat (x, y) memiliki korespondensi satu-ke-satu dengan elemen matriks $f(i, j)$ yang menyimpan nilai intensitas piksel (Gonzalez & Woods, 2020).



Gambar 2.1 Sistem koordinat dan representasi piksel pada citra digital.
Sumber gambar: Gonzalez and Woods (2020)

Pada Gambar 2.2 memperlihatkan tiga bentuk representasi citra digital, yaitu sebagai fungsi dua dimensi, sebagai tampilan visual, dan sebagai matriks nilai intensitas. Ketiga representasi tersebut bersifat ekuivalen karena menggambarkan citra yang sama dalam bentuk yang berbeda. Pada implementasi komputasi, representasi matriks merupakan bentuk yang paling umum digunakan karena setiap elemen matriks secara langsung merepresentasikan nilai intensitas suatu piksel.

Nilai intensitas setiap piksel bergantung pada jenis citra yang digunakan. Pada citra grayscale, setiap piksel hanya memiliki satu nilai intensitas yang umumnya berada pada rentang $[0, L-1]$, dengan L menyatakan jumlah tingkat keabuan. Untuk citra 8-bit, nilai intensitas berada pada rentang 0–255, di mana nilai 0 merepresentasikan warna hitam dan nilai 255 merepresentasikan warna putih. Sementara itu, pada citra berwarna, setiap piksel direpresentasikan oleh tiga komponen warna utama, yaitu merah (*Red*), hijau (*Green*), dan biru (*Blue*), sehingga satu piksel memiliki tiga nilai intensitas yang membentuk model warna RGB.



Gambar 2.2 Representasi citra digital sebagai (a) fungsi dua dimensi, (b) tampilan visual citra, dan (c) matriks nilai intensitas.
Sumber gambar: Gonzalez and Woods (2020)

Representasi matematis citra digital dalam bentuk fungsi dan matriks menjadi dasar bagi berbagai teknik pengolahan citra digital. Operasi seperti penyaringan (*filtering*), transformasi Fourier, segmentasi, ekstraksi fitur, maupun restorasi citra dilakukan dengan memodifikasi nilai intensitas piksel yang tersimpan pada matriks citra. Oleh karena itu, pemahaman terhadap representasi matematis citra digital merupakan landasan penting sebelum membahas metode pengolahan citra yang lebih lanjut.

Pada proses akuisisi di dunia nyata, citra digital umumnya tidak terlepas dari berbagai faktor yang menyebabkan degradasi kualitas citra, seperti keterbatasan sensor, gangguan transmisi, maupun kondisi lingkungan (Mao et al., 2025). Gangguan tersebut mengakibatkan perubahan nilai intensitas piksel sehingga informasi visual yang terkandung di dalam citra menjadi berkurang. Salah satu bentuk degradasi yang sering dijumpai adalah hujan, yang menimbulkan garis-garis hujan (*rain streak*) sehingga kualitas visual citra menurun dan mengganggu proses analisis lebih lanjut. Permasalahan tersebut menjadi dasar pengembangan berbagai metode restorasi citra, termasuk metode *single image deraining* yang dibahas pada penelitian ini.

2.4 Noise pada Citra Digital

Noise adalah titik-titik pada citra yang sebenarnya bukan merupakan bagian dari citra, melainkan ikut tercampur pada citra karena suatu sebab. Noise pada citra digital merujuk pada variasi intensitas piksel yang tidak diinginkan, yang muncul selama proses akuisisi, transmisi, atau pemrosesan citra (Joshi & Joshi, 2015). Noise ini mengurangi kualitas visual citra dan menyulitkan analisis informasi penting (Guo et al., 2019). Citra yang terkontaminasi noise dapat dimodelkan sebagai

$$f(x, y) = g(x, y) + n(x, y), \tag{2.5}$$

dengan $f(x, y)$ adalah citra ber-noise, $g(x, y)$ adalah citra asli, dan $n(x, y)$ adalah noise aditif (Joshi & Joshi, 2015). Berbagai model noise digunakan untuk memformalisasi karakteristik gangguan pada citra digital, antara lain *Gaussian noise*, *Salt and papper noise*, *Speckle noise*, dan *Rain noise* untuk sistem pencitraan berintensitas rendah (Rakesh et al., 2015). Setiap jenis noise berkaitan dengan mekanisme fisik tertentu, misalnya

1. *Gaussian noise*

   Gaussian noise yaitu noise dengan distribusi probabilitas normal yang sering muncul akibat gangguan termal pada sensor.



Gambar 2.3 *Gaussian noise*
Sumber gambar: Akbar and Verma (2024)

2. *Salt-and-pepper noise* (*impulse noise*)

   Pada noise ini ditandai dengan munculnya piksel sangat terang (*salt*) dan sangat gelap (*pepper*) secara acak, biasanya akibat kesalahan transmisi atau kerusakan sensor.



Gambar 2.4 *Salt and pepper noise*
Sumber gambar: Akbar and Verma (2024)

3. *Speckle noise*

   Noise ini muncul pada saat pengambilan citra tidak sempurna karena alasan cuaca, perangkat pengambilan citra dan sebagainya. Sifat noise ini *multiplikatif*, artinya semakin besar intensitas citra atau semakin cerah citra, semakin jelas juga noise yang terlihat.



Gambar 2.5 *Speckle noise*
Sumber gambar: Akbar and Verma (2024)

4. *Rain noise*

   Rain noise adalah gangguan pada citra yang muncul ketika proses pengambilan citra terjadi dalam kondisi hujan, misalnya karena adanya garis-garis hujan (*rain streak*), percikan air, atau tetesan air pada lensa, serta dipengaruhi juga oleh kualitas perangkat pengambilan citra dan kondisi pencahayaan.



Gambar 2.6 *Rain noise*
Sumber gambar: Dokumentasi penulis (2026)

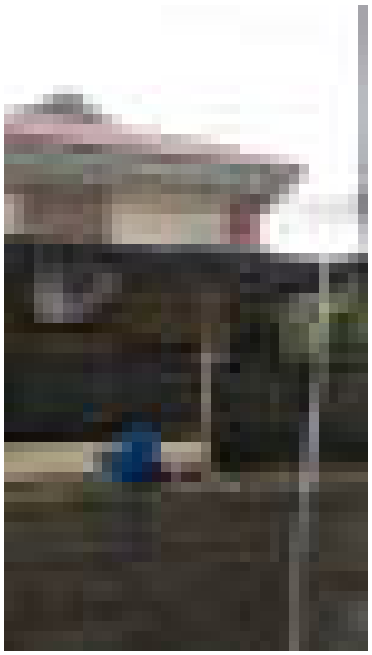
Keberagaman jenis noise ini membuat pemilihan metode *denoising* perlu disesuaikan dengan karakteristik gangguan yang terjadi pada citra.

Pada aplikasi dunia nyata seperti citra medis, penginderaan jauh, dan pengawasan, noise tidak hanya bersifat aditif dan tidak berkorelasi, tetapi sering kali bergantung pada sinyal (*signal-dependent*) dan menunjukkan korelasi spasial atau struktur baris atau kolom (H. Li et al., 2023). Beberapa studi juga menyoroti adanya noise terstruktur yang dipicu kondisi lingkungan, seperti kabut atau hujan pada citra *outdoor*, yang memadukan

komponen acak dengan artefak geometris seperti *streaks* sehingga lebih sulit dimodelkan secara sederhana (X. Li et al., 2024).

2.5 Noise Hujan (*Rain Noise*) pada Citra Digital

Noise hujan merupakan gangguan visual pada citra digital yang disebabkan oleh tetesan hujan yang tertangkap kamera. Noise hujan pada citra digital muncul sebagai garis-garis tipis (*rain streaks*) yang disebabkan oleh tetesan air hujan yang bergerak cepat di depan kamera (Qin et al., 2024). Sumber utama *rain noise* berasal dari efek lensa kamera terhadap tetesan air yang bergerak, ditambah penyebaran cahaya (*scattering*) akibat konsentrasi partikel air (Chen et al., 2014). Berbeda dengan noise aditif konvensional, *rain noise* bersifat anisotropik dengan orientasi dan ketebalan bervariasi, sering kali membentuk pola linier vertikal atau diagonal (Ma et al., 2020). Berbeda dari tekstur objek alami yang umumnya tersebar dengan arah acak (isotropik), distribusi goresan hujan cenderung terarah searah jatuhnya hujan, gaya gravitasi membuat arah dominan tetesan hujan jatuh secara vertikal, meskipun angin dapat menyebabkan sedikit kemiringan pada sudut jatuhnya (Yu, Chang, Li, Zhao, & Yan, 2022). Karakteristik spasial ini mengganggu visibilitas objek latar belakang dan menurunkan performa algoritma visi komputer (Chen et al., 2014).



Gambar 2.7 *Rain noise*
Sumber gambar: Dokumentasi penulis (2026)

Penghilangan noise hujan pada citra tunggal merupakan masalah yang menantang. Berbeda dengan kasus video yang dapat memanfaatkan informasi antar-*frame*, pada citra tunggal tidak tersedia informasi temporal tambahan sehingga deteksi dan pemisahan streak hujan dari latar belakang menjadi lebih sulit (H. Wang, Wu, Li, Zhao, & Meng, 2021). Algoritma deraining harus mengandalkan informasi dalam satu gambar saja untuk membedakan mana piksel yang termasuk objek atau latar belakang dan mana yang merupakan artefak hujan.

Secara matematis, citra hujan teramati $O \in \mathbb{R}^{M \times N}$ dapat dimodelkan sebagai superposisi linear antara citra latar belakang bersih $B \in \mathbb{R}^{M \times N}$ dan lapisan streak hujan

$R \in \mathbb{R}^{M \times N}$ (Y. Li, Tan, Guo, Lu, & Brown, 2016):

$$O = B + R. \tag{2.6}$$

Tujuan *single image* deraining adalah mengestimasi B (citra bebas hujan) dari input O dengan sekaligus memisahkan komponen hujan R. Masalah ini bersifat *ill-posed* karena jumlah variabel tak diketahui (B dan R) lebih banyak dibandingkan observasi (O), sehingga dibutuhkan *prior* atau regularisasi.

Salah satu cara umum adalah merumuskan estimasi (B, R) sebagai optimisasi ter-regularisasi. Secara umum, problem dapat dituliskan sebagai:

$$\min_{B,R} \quad \|O - B - R\|_F^2 \; + \; \Phi(B) \; + \; \Psi(R), \tag{2.7}$$

dengan $\|O - B - R\|_F$ menyatakan norma Frobenius, $\Phi(B)$ adalah regularisasi untuk menjaga struktur latar belakang, dan $\Psi(R)$ adalah regularisasi untuk memodelkan struktur streak hujan.

Mengikuti formulasi model-driven pada (Y. Li et al., 2016), regularisasi dapat memanfaatkan (i) sparsitas gradien background dan (ii) *patch prior* berbasis probabilitas seperti, GMM untuk background dan rain layer. Misalkan $P_i(\cdot)$ adalah operator ekstraksi patch ke-i, serta $p_B(\cdot)$ dan $p_R(\cdot)$ adalah model probabilitas patch untuk background dan rain. Salah satu bentuk energi yang merepresentasikan ide tersebut adalah:

$$\min_{B,R} \quad \|O - B - R\|_F^2 \; + \; \alpha\|\nabla B\|_1 \; - \; \gamma \sum_i \log p_B\Big(P_i(B)\Big) \; - \; \gamma \sum_i \log p_R\Big(P_i(R)\Big), \tag{2.8}$$

dengan ∇ operator gradien 2D, serta $\alpha, \gamma > 0$ adalah parameter bobot.

Selain itu, untuk menjaga solusi fisik pada intensitas citra, sering diberlakukan kendala non-negativitas (per-piksel) (Y. Li et al., 2016):

$$0 \le B(x, y) \le O(x, y), \qquad 0 \le R(x, y) \le O(x, y), \qquad \forall (x, y). \tag{2.9}$$

Salah satu tantangan utama adalah kesulitan membedakan goresan hujan dengan fitur objek pada citra. Bentuk dan orientasi streak hujan yang berupa garis tipis dapat menyerupai tepi atau tekstur objek di *background* (Fu et al., 2017). Apabila orientasi atau pola objek (misal tepi bangunan atau ranting pohon) sejajar dengan arah jatuh hujan, algoritma berisiko keliru: streak hujan dianggap sebagai bagian objek atau sebaliknya tepi objek dianggap sebagai noise. Hal ini menyulitkan penghilangan hujan tanpa turut menghilangkan detail objek yang sebenarnya. Tantangan lain adalah beragamnya intensitas dan kepadatan hujan; pada kondisi hujan lebat, banyak streak hujan yang tumpang-tindih dan menutupi bagian besar citra, bahkan membentuk semacam efek kabut tipis (H. Wang et al., 2021). Oleh karena itu, metode penghilangan *rain noise* dituntut mampu menyaring goresan hujan seteliti mungkin sembari mempertahankan struktur aslinya, agar citra hasil *deraining* bebas hujan tetap alami dan tajam.

2.5.1 Karakteristik Spektral Noise Hujan

Selain dianalisis pada domain spasial, noise hujan juga dapat dipahami melalui domain frekuensi. Secara umum, *rain streaks* memiliki kontribusi kuat pada komponen frekuensi tinggi, sedangkan gangguan lain seperti *rain haze* cenderung muncul pada frekuensi rendah sebagai perubahan pencahayaan global yang mereduksi kontras detail

(M. Zhang, Wang, & Yin, 2025). Oleh karena itu, keberadaan noise hujan dapat dianalisis dengan memisahkan komponen frekuensi tinggi dan rendah gambar.

Misalkan $O(x, y)$ adalah intensitas citra hujan pada koordinat (x, y) berukuran $M \times N$. Transformasi Fourier diskrit 2D (DFT) didefinisikan sebagai:

$$\widehat{O}(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} O(x, y)\, e^{-j2\pi\left(\frac{ux}{M} + \frac{vy}{N}\right)}, \tag{2.10}$$

dengan (u, v) adalah indeks frekuensi dan $j = \sqrt{-1}$.

Berdasarkan model superposisi pada Persamaan (2.6) dan linearitas transformasi Fourier, berlaku:

$$\widehat{O}(u, v) = \widehat{B}(u, v) + \widehat{R}(u, v). \tag{2.11}$$

Transformasi Fourier 2D dari citra hujan menunjukkan bahwa goresan-goresan hujan yang tersebar di domain spasial akan tampak sebagai komponen spektral terkonsentrasi pada orientasi tertentu di domain frekuensi (Yamashita & Ikehara, 2025). Artinya, pola garis sejajar yang dibentuk oleh banyak streak hujan menghasilkan pola energi pada spektrum yang selaras dengan arah goresan tersebut. Misalnya, apabila streak hujan dominan miring pada sudut tertentu, spektrum Fourier citra akan mengandung deretan koefisien beramplitudo tinggi sepanjang arah yang tegak lurus terhadap orientasi streak tersebut.

Karakteristik spektral ini telah dimanfaatkan dalam berbagai pendekatan *deraining* citra hujan. Dengan menganggap *rain streaks* sebagai sinyal berfrekuensi tinggi yang terstruktur, peneliti dapat menerapkan filter domain frekuensi yang selektif terhadap orientasi atau frekuensi tersebut untuk menghilangkan noise hujan tanpa mengganggu detail lain. Pendekatan berbasis frekuensi mampu memisahkan komponen hujan secara lebih efektif karena pola global yang ditimbulkan kumpulan streak menjadi lebih jelas di domain frekuensi (Yamashita & Ikehara, 2025). Sebagai contoh, (Barnum, Narasimhan, & Kanade, 2009) membangun model global di domain frekuensi untuk mendeteksi dan menghapus hujan dengan mencocokkan orientasi spektral streak hujan pada video. Demikian pula, metode *deraining* modern kerap melakukan dekomposisi citra ke komponen frekuensi, di mana komponen frekuensi tinggi diolah untuk menghapus jejak hujan sementara komponen frekuensi rendah dipertahankan agar detail tekstur asli tidak hilang (M. Zhang et al., 2025). Dapat dikatakan bahwa secara spektral noise hujan memiliki ciri berupa sinyal berfrekuensi tinggi yang terarah, yang dapat diidentifikasi dan dipisahkan dari informasi citra utama melalui analisis domain frekuensi.

2.6 Metode Penghilangan Noise Hujan pada Citra Tunggal

Penghilangan noise hujan pada citra tunggal (*single image* deraining) merupakan proses penting untuk meningkatkan kualitas citra yang terdegradasi oleh *rain streak* atau garis-garis tipis yang disebabkan oleh tetesan air hujan yang bergerak cepat di depan kamera. Tujuan utamanya adalah menghapus komponen hujan tanpa menghilangkan detail penting seperti tepi, tekstur, dan struktur objek, sehingga tampilan latar belakang dapat dipertahankan secara bersih dan alami. Berbeda dengan pendekatan berbasis video atau multi-citra, skenario citra tunggal bersifat lebih menantang karena tidak tersedia informasi temporal maupun referensi tambahan. Kondisi ini menjadikan permasalahan deraining sebagai masalah *ill-posed*, di mana satu citra hujan dapat dipetakan ke banyak kemungkinan citra bersih. Oleh karena itu, diperlukan pemodelan yang mampu

merepresentasikan karakteristik hujan sekaligus struktur latar belakang secara akurat.

Metode awal dalam *single image* deraining umumnya menggunakan pendekatan berbasis model dengan memanfaatkan fungsi biaya dan prior tertentu untuk memisahkan komponen hujan dari citra. Sejak tahun 2017, pendekatan berbasis data dengan deep learning mulai mendominasi, terutama melalui penggunaan arsitektur seperti *convolutional neural networks* (CNN), *recurrent neural networks* (RNN), dan *generative adversarial networks* (GAN) yang mampu mempelajari pola hujan secara end-to-end dan menunjukkan performa yang unggul (Yang, Tan, & Feng, 2019). Perkembangan terkini mengarah pada pemanfaatan mekanisme multi-skala dan *attention* untuk menangani variasi ukuran, kepadatan, dan orientasi *rain streak*. Selain itu, transformasi domain seperti wavelet digunakan untuk memisahkan fitur hujan dan latar belakang secara lebih efektif (Q. Wang et al., 2024). Beberapa penelitian juga mengintegrasikan struktur rekuren bilateral guna memodelkan interaksi antara lapisan hujan dan latar belakang secara simultan, sehingga proses pemulihan detail citra menjadi lebih akurat (Ren et al., 2020).

Meskipun demikian, tantangan seperti kemampuan generalisasi pada kondisi hujan nyata yang beragam serta efisiensi komputasi masih menjadi fokus penelitian. Untuk menjawab kebutuhan aplikasi praktis, sejumlah metode terbaru mengusulkan arsitektur yang lebih ringan dan adaptif, termasuk pendekatan semi-supervised berbasis GAN yang menargetkan pemrosesan citra pada sistem visi berbasis tugas, dengan tetap mempertahankan kinerja *deraining* yang kompetitif (Swaminathan & Korupolu, 2023). Secara umum, metode *single image* deraining saat ini dapat dikelompokkan ke dalam dua kategori besar, yaitu pendekatan konvensional berbasis filter dan prior, serta pendekatan modern berbasis deep learning *end-to-end* (H. Wang et al., 2021).

2.6.1 Metode Konvensional Berbasis Filter dan Prior pada Citra Tunggal

Pendekatan awal untuk *single image* deraining umumnya memanfaatkan filtrasi spasial dan/atau asumsi (*prior*) tertentu tentang karakteristik hujan. Pada tingkat dasar, filter rata-rata atau median dapat digunakan untuk mereduksi intensitas goresan hujan melalui proses penghalusan (Z. Wang, Luo, & Xie, 2018). Beberapa metode juga melakukan deteksi awal terhadap piksel yang dicurigai sebagai hujan, kemudian menerapkan penyaringan adaptif pada area tersebut agar kerusakan detail dapat diminimalkan. Teknik *guided image filter* pernah digunakan untuk mempertahankan struktur tepi sambil menekan garis-garis tipis pada citra tunggal (Z. Wang et al., 2018).

Selain filter sederhana, banyak metode konvensional memformulasikan citra hujan sebagai hasil superposisi antara latar belakang dan komponen hujan, lalu menyelesaikannya melalui model matematis atau optimisasi seperti, dekomposisi komponen, regularisasi, atau prior sparsitas/struktur. Namun, efektivitas pendekatan konvensional pada citra tunggal sering terbatas ketika pola hujan kompleks (variasi orientasi, ketebalan, kepadatan, serta interaksi dengan pencahayaan) (H. Wang, Yue, & Yin, 2020). Ketika struktur objek memiliki orientasi dan frekuensi yang mirip dengan jejak hujan, metode berbasis fitur tingkat rendah cenderung sulit membedakan keduanya secara akurat (Fu et al., 2017). Keterbatasan utama lain adalah degradasi detail citra yang merupakan penyaringan yang agresif dapat menimbulkan *over-smoothing* sehingga tekstur halus dan tepi objek ikut hilang (Z. Wang et al., 2018). Studi survei juga melaporkan bahwa metode konvensional kadang berhasil mengurangi hujan, tetapi berpotensi menurunkan kontras serta kejernihan detail pada hasil akhir (H. Wang, Wu, & Zhang, 2022).

2.6.2 Metode deep learning *End-to-End* untuk *Single Image* deraining

Perkembangan deep learning mendorong peningkatan signifikan dalam *single image* deraining karena jaringan saraf mampu mempelajari pemetaan non-linear dari citra hujan ke citra bersih secara langsung (Z. Zhang, Li, & Guo, 2023). Berbeda dari metode konvensional yang sangat bergantung pada asumsi hujan tertentu, pendekatan ini umumnya melatih jaringan, seperti *Convolutional Neural Network* (CNN) secara *end-to-end* menggunakan pasangan data citra hujan dan citra bersih.

Menurut paper Fu et al. (2017) memperkenalkan *Deep Detail Network* yang menekankan pemisahan komponen detail berfrekuensi tinggi agar jaringan dapat fokus mempelajari pola hujan tanpa terganggu informasi latar belakang berfrekuensi rendah. Pendekatan ini membantu jaringan membedakan *rain streak* dari struktur objek asli, sehingga penghilangan hujan pada citra tunggal menjadi lebih efektif. Selanjutnya, berbagai arsitektur dikembangkan untuk menangani hujan yang beragam, seperti model yang menggabungkan deteksi dan pemulihan hujan secara simultan, serta jaringan rekuren atau multi-tahap yang menghilangkan hujan secara bertahap agar pemulihan detail lebih stabil (Yang et al., 2019). Secara umum, metode deep learning menunjukkan performa yang lebih baik dibanding filter/prior konvensional pada *single image* deraining, baik dari sisi metrik kuantitatif seperti PSNR dan SSIM maupun kualitas visual, meskipun masih menghadapi tantangan generalisasi ketika distribusi hujan pada data uji berbeda dari data latih (H. Wang et al., 2022).

2.7 Pendekatan *Model-Driven* untuk deraining (Penghilangan Noise Hujan)

Pendekatan *model-driven* untuk deraining (penghilangan noise hujan) mengandalkan pengetahuan model fisik atau matematis tentang citra dan noise untuk memandu proses *deraining*. Pendekatan ini berbeda dengan pendekatan *data-driven* murni yang mengandalkan pembelajaran *end-to-end* menggunakan jaringan saraf. Dalam konteks penghilangan noise hujan pada citra digital, pendekatan model-driven memanfaatkan *prior* atau asumsi tertentu seperti sparsitas dan struktur layer hujan yang ditanamkan ke dalam model optimisasi (Luo, Xu, & Ji, 2015). Berbagai penelitian menunjukkan bahwa prior sparsitas, regularisasi, dan model fisik hujan dapat meningkatkan kualitas *deraining* citra hujan secara signifikan (Kang et al., 2010). Akan membahas tiga komponen utama pendekatan model-driven, yaitu:

2.7.1 Sparse Representation dan Dictionary Learning

Sparsity atau keterjarangan adalah asumsi bahwa sinyal citra dapat diwakili hanya dengan sejumlah kecil komponen basis. *Dictionary learning* adalah teknik untuk mempelajari basis-basis (disebut atom) secara adaptif dari data, sehingga citra dapat direkonstruksi sebagai kombinasi linear beberapa atom tersebut dengan koefisien yang jarang (banyak elemen nol). Secara matematis, untuk citra atau patch $\mathbf{y}$, dicari representasi

$$\mathbf{y} \approx D\mathbf{x}, \tag{2.12}$$

dengan D adalah dictionary (matriks atom) dan $\mathbf{x}$ adalah vektor koefisien sparse. Optimisasi umumnya meminimalkan error rekonstruksi dengan penalti sparsitas, misalnya:

$$\min_{\mathbf{x},D} \|\mathbf{y} - D\mathbf{x}\|_2^2 + \lambda\|\mathbf{x}\|_0, \tag{2.13}$$

dengan $\|\mathbf{x}\|_0$ melambangkan jumlah entri non-nol pada $\mathbf{x}$. Pendekatan ini telah sukses pada berbagai tugas pemulihan citra seperti denoising dan super-resolusi (Luo et al.,

2015).

Dalam kasus deraining citra yang terdegradasi oleh hujan, teknik *dictionary learning* digunakan untuk memisahkan komponen *citra latar bersih* dan *jejak hujan*. Luo et al. (Luo et al., 2015) mengusulkan model deraining dengan asumsi bahwa patch citra bersih dan patch hujan keduanya memiliki representasi sparse pada dictionary yang sama. Misalkan Y_1 adalah himpunan patch citra latar dan Y_2 patch jejak hujan, maka dipelajari dictionary D sehingga:

$$Y_1 \approx DC_1, \quad Y_2 \approx DC_2, \tag{2.14}$$

dengan C_1 dan C_2 merupakan koefisien sparse untuk layer citra dan layer hujan secara terpisah. Untuk memastikan D memiliki atom-atom yang terpisah antara hujan dan latar, diterapkan syarat diskriminatif berupa *mutual exclusivity*, yaitu atom yang dipakai untuk merekonstruksi patch hujan tidak akan dipakai untuk patch citra latar. Konsep ini membuat dictionary belajar dua subruang terpisah, satu untuk fitur hujan dan satu untuk fitur citra utama.

Teknik representasi jarang dengan dictionary biasanya diselesaikan lewat algoritma iteratif. Pada penelitihan Luo et al. (2015), optimisasi dilakukan dengan iterasi bergantian, yakni pembaruan koefisien C_1 dan C_2, pembaruan citra latar I dan hujan R, serta pembaruan dictionary D secara bergilir. Meskipun konvergen, metode iteratif multi-tahap ini cenderung lambat dan sensitif terhadap pemilihan parameter.

2.7.2 Proximal Gradient dan Optimisasi Iteratif

Banyak masalah *deraining* citra dirumuskan sebagai minimisasi fungsi objektif yang terdiri dari data *fidelity term* dan *regularization term*. Secara umum dapat ditulis:

$$\min_{\mathbf{x}} F(\mathbf{x}) + \lambda G(\mathbf{x}), \tag{2.15}$$

dengan $F(\mathbf{x})$ adalah error terhadap citra input rusak dan $G(\mathbf{x})$ adalah fungsi regulerisasi, dengan λ sebagai faktor penimbang.

Proximal Gradient Descent (PGD) adalah teknik iteratif populer untuk menyelesaikan optimisasi semacam ini. Pada setiap iterasi k, dilakukan langkah gradien untuk F yang diikuti oleh operasi proximal untuk G:

$$\mathbf{x}_{k+1} = \text{prox}_{\tau G}\Big(\mathbf{x}_k - \tau \nabla F(\mathbf{x}_k)\Big), \tag{2.16}$$

dengan τ adalah ukuran langkah. Operator proximal didefinisikan sebagai:

$$\text{prox}_{\alpha G}(\mathbf{z}) = \arg\min_{\mathbf{x}} \left(\frac{1}{2}\|\mathbf{x} - \mathbf{z}\|_2^2 + \alpha G(\mathbf{x}) \right). \tag{2.17}$$

Jika $G(\mathbf{x}) = \|\mathbf{x}\|_1$, maka operator proximal menjadi operasi *soft-thresholding*. Prosedur ini dikenal sebagai *Iterative Shrinkage-Thresholding Algorithm* (ISTA). Terdapat varian yang dipercepat seperti FISTA yang menambahkan momentum inertial untuk mempercepat konvergensi (Lv et al., 2022).

Dalam konteks *deraining* citra hujan, metode ini digunakan pada berbagai model terdahulu dengan memformulasikan penghilangan hujan sebagai masalah dekomposisi citra berlapis, yang diselesaikan dengan iterasi dua tahap. Demikian pula, pendekatan oleh Luo et al. (2015) melibatkan iterasi proksimal untuk memperbarui dictionary dan koefisien sparse.

2.7.3 *Deep unfolding* sebagai Jembatan Optimisasi dan *deep learning*

deep unfolding (atau *algorithm unrolling*) adalah paradigma yang menjembatani metode optimisasi iteratif dengan model *deep learning*. Ide utamanya adalah mengurai langkah-langkah algoritma iteratif menjadi serangkaian layer dalam jaringan saraf, di mana parameter-parameternya dapat dipelajari secara end-to-end (Gregor & LeCun, 2010; Monga, Li, & Eldar, 2021). Dalam *deraining* citra hujan, penelitian H. Wang, Xie, and Zhao (2020) memperkenalkan RCDNet sebagai contoh nyata model-driven deep network. Model ini merumuskan *deraining* berbasis convolutional dictionary learning, menurunkan algoritma proximal gradient, lalu meng-unroll algoritma tersebut menjadi arsitektur jaringan dalam. Setiap modul jaringan bersesuaian langsung dengan operasi algoritmik, menjadikan jaringan sepenuhnya interpretable. Keberhasilan RCDNet menunjukkan potensi besar *deep unfolding* sebagai jembatan antara prior model matematis dan fleksibilitas pembelajaran mendalam, terutama pada kondisi data terbatas, serta menawarkan kecepatan inferensi tinggi dengan jumlah iterasi yang jauh lebih sedikit.

2.8 *Rain Convolutional Dictionary Network* (RCDNet)

Rain Convolutional Dictionary Network (RCDNet) merupakan metode *single image* deraining berbasis deep unfolding yang memodelkan lapisan hujan menggunakan kerangka *Convolutional Dictionary Learning* (CDL) (H. Wang, Xie, & Zhao, 2020). CDL sendiri adalah pendekatan pembelajaran representasi yang memperluas konsep *dictionary learning* klasik ke domain konvolusi. Dalam *dictionary learning* biasa, sebuah sinyal, misalnya citra direpresentasikan sebagai kombinasi linear dari atom-atom kamus (basis) yang dipilih secara *sparse*. CDL menggeneralisasi ide ini dengan merepresentasikan sinyal sebagai penjumlahan konvolusi antara sejumlah filter (kernel) kecil yang dipelajari dan peta koefisien (aktivasi) terkait (H. Wang, Xie, & Zhao, 2020).

Secara matematis, jika f_j menyatakan filter ke-j dalam kamus konvolusional dan w_j adalah peta koefisien yang menunjukkan di mana filter tersebut muncul pada citra, maka model CDL untuk sebuah citra x dapat ditulis sebagai:

$$x = \sum_{j=1}^{L} f_j \otimes w_j, \tag{2.18}$$

dengan $\otimes$ menyatakan operasi konvolusi 2D. Model ini menyatakan bahwa pola-pola lokal berulang dalam citra dapat dijelaskan oleh sekumpulan filter f_j yang *shift-invariant*, sementara w_j menandai lokasi kemunculan pola-pola tersebut (Son & Zhang, 2020). Keunggulan CDL adalah kemampuannya menangkap pola berulang dalam skala penuh citra (tidak hanya sebatas patch kecil), sehingga sangat sesuai untuk memodelkan struktur *rain streaks* yang muncul sebagai pola guratan serupa di berbagai lokasi.

Dalam konteks penghilangan noise hujan pada citra tunggal, filter-filter konvolusional (f_j) dapat dianggap sebagai *rain dictionary*, yaitu sekumpulan *rain kernels* yang mewakili bentuk-bentuk guratan hujan umum (H. Wang & Patel, 2022). Dengan sejumlah kecil kernel tersebut, berbagai variasi bentuk dan arah goresan hujan dapat diakomodasi, sementara peta koefisien (w_j) berperan sebagai *rain mask* yang menunjukkan posisi masing-masing pola hujan dalam citra.

2.8.1 Model Degradasi Citra Hujan Berbasis Convolutional Dictionary

Secara umum, citra hujan yang diamati O dapat dimodelkan sebagai superposisi linear antara citra latar belakang bersih B dan komponen jejak hujan R:

$$O = B + R. \tag{2.19}$$

Pada RCDNet, komponen R dimodelkan secara eksplisit menggunakan *rain convolutional dictionary*. Setiap kanal warna dari lapisan hujan direpresentasikan sebagai kombinasi konvolusi antara sejumlah kernel hujan C_n dan peta koefisien M_n:

$$R = \sum_{n=1}^{N} C_n \otimes M_n, \tag{2.20}$$

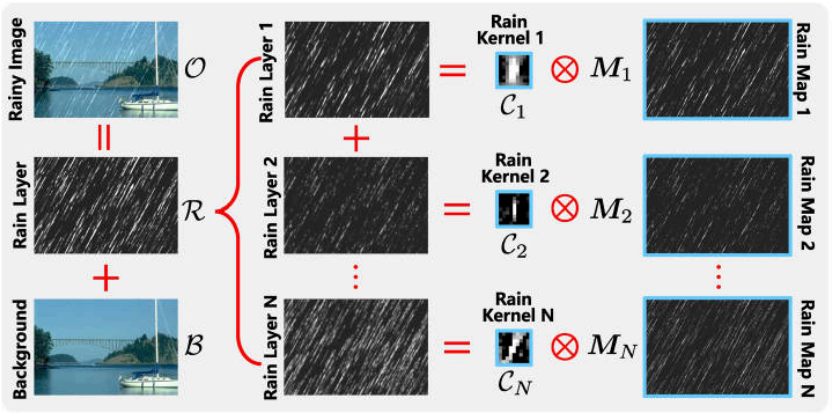
dengan C_n menyatakan kernel hujan ke-n dan M_n adalah *rain map* yang sesuai. Operator $\otimes$ menunjukkan konvolusi 2D, sehingga $C_n \otimes M_n$ menghasilkan komponen citra hujan yang mengikuti pola kernel C_n pada lokasi-lokasi yang ditentukan oleh M_n. Penjumlahan semua komponen ini membentuk lapisan hujan R secara keseluruhan, dan model degradasi menjadi:

$$O = B + \sum_{n=1}^{N} C_n \otimes M_n. \tag{2.21}$$

Dengan demikian, RCDNet memandang citra hujan sebagai kombinasi antara lapisan background B dan lapisan hujan R yang tersusun atas pola-pola guratan berulang yang ditangkap oleh kernel konvolusi. Representasi ini sejalan dengan gagasan *non-local self-similarity*, yaitu bahwa pola lokal serupa (dalam hal orientasi, ketebalan, dan bentuk guratan hujan) muncul berkali-kali di berbagai lokasi citra (He & Patel, 2017). Pendekatan *convolutional dictionary* sendiri telah digunakan secara luas pada pemodelan *rain streaks* dan menunjukkan kinerja yang kuat, baik untuk citra tunggal maupun video ketika informasi temporal tersedia (He & Patel, 2017; M. Li, Yang, & Tan, 2018).

2.8.2 Representasi Rain Streaks sebagai Konvolusi Kernel dan Rain Map

Mekanisme utama dalam RCDNet adalah representasi lapisan hujan R menggunakan kombinasi konvolusi kernel dan *rain map*. Setiap kernel hujan C_n merepresentasikan pola guratan hujan dasar (misalnya garis miring dengan ketebalan dan panjang tertentu), sedangkan *rain map* M_n menunjukkan posisi dan intensitas kemunculan pola tersebut di citra. Karena guratan hujan cenderung memiliki orientasi dan bentuk yang mirip, sejumlah kernel terbatas dapat digunakan secara berulang di seluruh citra untuk merekonstruksi lapisan hujan. Ilustrasi dapat dilihat pada Gambar 2.8.



Gambar 2.8 Model RCDNet untuk *rain layer*
Sumber gambar: H. Wang, Xie, and Zhao (2020)

Dalam kerangka *single image* deraining, M_n biasanya dipaksa bersifat *sparse*, artinya sebagian besar nilai M_n adalah nol dan hanya sedikit lokasi yang mengandung nilai non-nol. Hal ini mencerminkan fakta bahwa hujan tidak muncul merata di seluruh citra, melainkan hanya pada lokasi tertentu. Kombinasi antara sparsitas koefisien dan kamus kernel yang *shift-invariant* membuat representasi ini efisien dan informatif: kernel menyimpan informasi bentuk guratan, sedangkan *rain map* menentukan di mana pola tersebut muncul. Representasi ini sekaligus berperan sebagai prior struktural tentang lapisan hujan yang kemudian dimanfaatkan RCDNet dalam proses pemisahan B dan R (He & Patel, 2017).

2.8.3 Formulasi Optimisasi dan *deep unfolding* pada RCDNet

Berdasarkan model degradasi di atas, tugas *deraining* pada RCDNet diformulasikan sebagai masalah optimisasi untuk memulihkan M dan B dari citra teramati O:

$$\min_{M,B} \frac{1}{2} \left\| O - B - \sum_{n=1}^{N} C_n \otimes M_n \right\|_F^2 + \alpha g_1(M) + \beta g_2(B), \tag{2.22}$$

dengan $\| \cdot \|_F^2$ adalah norma Frobenius, $g_1(\cdot)$ dan $g_2(\cdot)$ adalah fungsi regularisasi (prior) untuk M dan B, serta α dan β mengontrol bobot regularisasi tersebut (H. Wang, Xie, & Zhao, 2020). Secara intuitif, $g_1(M)$ mendorong *rain map* menjadi *sparse* (karena hujan hanya muncul pada lokasi tertentu), sedangkan $g_2(B)$ mendorong B agar halus namun tetap mempertahankan tepi dan detail penting (misalnya melalui prior *edge-preserving*).

Masalah optimisasi ini bersifat tidak linier dan tidak terdiferensiasi halus karena keberadaan suku regularisasi. Untuk menyelesaikannya, digunakan pendekatan *proximal gradient* yang melakukan pembaruan bergantian pada variabel M dan B (R. Li, Tan, & Cheong, 2019). Pada iterasi ke-s, langkah pembaruan ideal dapat ditulis sebagai:

$$M^{(s)} = \text{prox}_{\alpha\eta_1} \left(M^{(s-1)} - \eta_1 \nabla_M f(M^{(s-1)}, B^{(s-1)}) \right), \tag{2.23}$$

$$B^{(s)} = \text{prox}_{\beta\eta_2} \left(B^{(s-1)} - \eta_2 \nabla_B f(M^{(s)}, B^{(s-1)}) \right), \tag{2.24}$$

dengan $f(\cdot)$ menyatakan term kesesuaian data dan η_1, η_2 adalah langkah-langkah *gradient*. Operator prox bergantung pada bentuk regularisasi g_1 dan g_2.

Alih-alih menetapkan bentuk regularisasi dan operator proximal secara eksplisit, RCDNet mengaproksimasi operator proximal tersebut secara *data-driven* menggunakan jaringan saraf (H. Wang, Xie, & Zhao, 2020). Inilah yang menjadi dasar arsitektur deep unfolding pada RCDNet.

2.8.4 Arsitektur *deep unfolding*: M-net dan B-net

Deep unfolding (*algorithm unrolling*) adalah pendekatan yang membangun arsitektur jaringan saraf dengan "membentangkan" langkah-langkah iteratif dari suatu algoritma optimisasi menjadi rangkaian *stage* pada jaringan. Setiap *stage* meniru satu iterasi algoritma, sehingga alur komputasi jaringan memiliki korespondensi langsung dengan operator dan variabel pada model matematis (Monga et al., 2021). Pendekatan ini banyak digunakan pada *inverse problem* (dekonvolusi, dehazing, *compressive sensing*, dan *deraining*), karena dapat menggabungkan model degradasi yang jelas dengan modul CNN yang dapat dilatih (Beck & Teboulle, 2009; Gregor & LeCun, 2010).

Dalam RCDNet (H. Wang, Xie, & Zhao, 2020), *deep unfolding* direalisasikan dengan mendesain jaringan sebagai rangkaian S *stage*, di mana setiap *stage* merepresentasikan satu iterasi pembaruan M dan B pada skema *proximal gradient*. Secara umum, setiap *stage* terdiri atas dua sub-jaringan, yaitu:

1. M-net, yang mengimplementasikan pembaruan *rain map* M (aproksimasi operator proximal untuk g_1).
2. B-net, yang mengimplementasikan pembaruan *background* B (aproksimasi operator proximal untuk g_2).

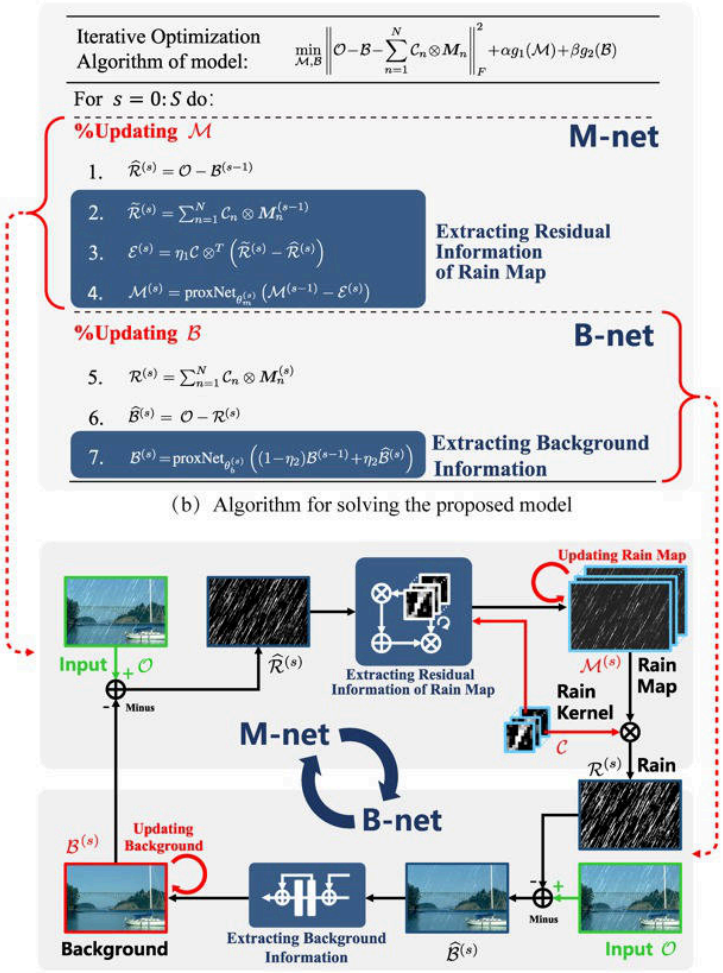
Misalkan O adalah citra hujan teramati, $M^{(s)}$ adalah estimasi *rain map* pada *stage* ke-s, dan $B^{(s)}$ adalah estimasi *background* pada *stage* ke-s. Pada *stage* ke-s, M-net menerima O serta estimasi sebelumnya $B^{(s-1)}$ dan $M^{(s-1)}$, kemudian menghasilkan $M^{(s)}$ dengan cara sebagai berikut:

1. Menghitung sinyal residu yang merepresentasikan ketidaksesuaian antara lapisan hujan yang diperkirakan dari estimasi background dan lapisan hujan yang dibentuk oleh model kamus konvolusional.
2. Memproyeksikan residu tersebut melalui modul *proxNet* (jaringan kecil bergaya ResNet) untuk memperbarui *rain map* $M^{(s)}$.

Setelah $M^{(s)}$ diperoleh, B-net menggunakan O dan $M^{(s)}$ untuk:

1. Membentuk estimasi awal background dengan mengurangi estimasi lapisan hujan dari citra teramati, misalnya $O - \sum_n C_n \otimes M_n^{(s)}$.
2. Menggabungkan estimasi ini dengan $B^{(s-1)}$ menggunakan bobot terpelajar dan modul *proxNet* lain yang bertindak sebagai operator proximal terlatih untuk g_2, menghasilkan background baru $B^{(s)}$.

Secara keseluruhan, dua jalur pembaruan ini membentuk struktur "dua langkah" pada setiap *stage* yang berkorespondensi satu-ke-satu dengan dua langkah pembaruan M dan B dalam algoritma optimisasi (H. Wang, Xie, & Zhao, 2020). Arsitektur RCDNet dapat dilihat pada Gambar 2.9.



Gambar 2.9 Arsitektur model RCDNet
Sumber gambar: H. Wang, Xie, and Zhao (2020)

Dengan desain ini, RCDNet memadukan kelebihan model matematis berbasis *convolutional dictionary* dan fleksibilitas jaringan deep learning *end-to-end*. Hasilnya, RCDNet menunjukkan performa yang kompetitif untuk tugas *single image* deraining, baik secara kuantitatif (PSNR/SSIM) maupun kualitatif (H. Wang, Xie, & Zhao, 2020; H. Wang et al., 2022).

2.9 Evaluasi Metrik

Evaluasi performa metode penghilangan noise (*denoising*) dilakukan untuk menilai sejauh mana algoritma mampu memulihkan citra yang bersih sekaligus mempertahankan detail visual penting. Pada banyak studi *deraining* citra, evaluasi kuantitatif umumnya memakai metrik objektif *full-reference*, yaitu membandingkan citra hasil *deraining* $\hat{I}$ terhadap citra acuan (ground-truth) I, namun ada juga evaluasi metrik untuk mengevaluasi hasil *deraining* yang menggunakan citra nyata tanpa *ground-truth*, seperti BRISQUE. Dalam penelitian ini digunakan dua metrik yang paling umum pada tugas denoising, yakni *Peak Signal-to-Noise Ratio* (PSNR) dan *Structural Similarity Index Measure* (SSIM). PSNR menilai kualitas berdasarkan besarnya galat piksel (berbasis MSE), sedangkan SSIM menilai kemiripan struktur citra yang lebih dekat dengan persepsi visual manusia. Penggunaan keduanya secara bersamaan lazim dilakukan karena PSNR dan SSIM sering memberikan sudut pandang kualitas yang saling melengkapi.

2.9.1 Peak Signal-to-Noise Ratio (PSNR)

PSNR adalah metrik yang mengukur kesamaan citra hasil *deraining* dengan citra acuan melalui galat kuadrat rata-rata (*Mean Squared Error*/MSE). MSE didefinisikan sebagai:

$$\text{MSE} = \frac{1}{MN} \sum_{i=1}^{M} \sum_{j=1}^{N} \left(I(i,j) - \hat{I}(i,j) \right)^2, \tag{2.25}$$

dengan $M \times N$ adalah ukuran citra. Selanjutnya, PSNR dinyatakan dalam desibel (dB) sebagai:

$$\text{PSNR} = 10 \log_{10} \left(\frac{L^2}{\text{MSE}} \right), \tag{2.26}$$

dengan L adalah nilai intensitas maksimum (misalnya $L = 255$ untuk citra 8-bit, atau $L = 1$ bila citra dinormalisasi).

Nilai PSNR yang lebih tinggi mengindikasikan MSE yang lebih kecil, sehingga secara numerik citra hasil *deraining* semakin mendekati citra acuan. Namun, PSNR memiliki keterbatasan karena hanya merefleksikan besaran galat energi piksel dan tidak selalu sejalan dengan penilaian kualitas berdasarkan persepsi manusia; dua citra dapat memiliki PSNR yang mirip tetapi kualitas visual yang dirasakan berbeda, terutama ketika distorsi memengaruhi struktur/tekstur secara berbeda (Z. Wang, Bovik, Sheikh, & Simoncelli, 2004; Horé & Ziou, 2010).

2.9.2 Structural Similarity Index Measure (SSIM)

SSIM dikembangkan untuk melengkapi metrik berbasis galat, seperti MSE atau PSN dengan menilai degradasi berdasarkan perubahan informasi struktural. Secara umum, SSIM memodelkan kemiripan citra melalui tiga komponen: luminansi (*luminance*), kontras (*contrast*), dan struktur (*structure*). SSIM didefinisikan sebagai:

$$\text{SSIM}(x,y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}, \tag{2.27}$$

dengan μ_x dan μ_y adalah rata-rata intensitas, σ_x^2 dan σ_y^2 adalah variansi, serta σ_{xy} adalah kovariansi antara dua citra yang dibandingkan. Konstanta C_1 dan C_2 digunakan untuk menjaga stabilitas perhitungan ketika penyebut mendekati nol (umumnya diturunkan dari dinamika intensitas L). Nilai SSIM biasanya berada pada rentang mendekati 0 sampai 1, dan semakin mendekati 1 menunjukkan kemiripan struktur yang semakin tinggi (Z. Wang et al., 2004).

Dalam praktiknya, SSIM sering dihitung secara lokal menggunakan jendela geser, misalnya blok kecil pada citra lalu dirata-ratakan menjadi skor global yang sering disebut dengan MSSIM. Karena menilai pola struktur, SSIM cenderung lebih representatif terhadap kualitas visual dibanding PSNR pada beberapa jenis distorsi, meskipun tetap bergantung pada ketersediaan citra acuan dan masih dapat memiliki keterbatasan pada kasus-kasus artefak tertentu (Z. Wang et al., 2004; Ndajah, Kikuchi, Yukawa, Watanabe, & Muramatsu, 2011).

2.9.3 *Blind/Referenceless Image Spatial Quality Evaluator* (BRISQUE)

BRISQUE merupakan metrik evaluasi kualitas citra tanpa referensi (*no-reference image quality assessment*/NR-IQA) yang diperkenalkan oleh Mittal, Moorthy, and Bovik (2012). Berbeda dengan PSNR dan SSIM yang memerlukan citra acuan (*ground*

truth) untuk perhitungan, BRISQUE beroperasi hanya dari satu citra masukan dengan menganalisis statistik spasial pikselnya menggunakan kerangka teori *natural scene statistics* (NSS). Prinsip kerjanya didasarkan pada pengamatan bahwa citra alami yang tidak terdistorsi memiliki distribusi statistik tertentu pada domain spasial; penyimpangan dari distribusi tersebut mengindikasikan adanya distorsi atau penurunan kualitas.

Secara teknis, BRISQUE mengekstraksi fitur dari koefisien *Mean Subtracted Contrast Normalized* (MSCN) dan statistik pasangan piksel tetangga (horizontal, vertikal, diagonal), lalu memetakan fitur tersebut ke skor kualitas menggunakan *Support Vector Regression* (SVR) yang dilatih pada basis data citra beranotasi opini manusia (Mittal et al., 2012). Skor BRISQUE yang lebih rendah mengindikasikan kualitas citra yang lebih baik (lebih alami/natural), sedangkan skor lebih tinggi mencerminkan tingkat distorsi yang lebih besar. Dalam penelitian ini, BRISQUE digunakan sebagai satu-satunya metrik evaluasi kuantitatif untuk dataset primer (487 foto hujan nyata tanpa *ground truth*), karena kemampuannya menilai *naturalness* citra secara mandiri tanpa membutuhkan pasangan citra bersih sebagai acuan.

1. Koefisien *Mean Subtracted Contrast Normalized* (MSCN)

   Tahap awal dalam algoritma BRISQUE adalah pembentukan koefisien MSCN dari citra masukan $I(i,j)$ melalui operasi pengurangan rata-rata lokal diikuti dengan normalisasi kontras secara divisif (Mittal et al., 2012):

   $$\hat{I}(i,j) = \frac{I(i,j) - \mu(i,j)}{\sigma(i,j) + C}, \tag{2.28}$$

   dengan $i = 1, \ldots, M$ dan $j = 1, \ldots, N$ merupakan indeks posisi spasial; M dan N berturut-turut menyatakan dimensi tinggi dan lebar citra; $C = 1$ merupakan konstanta penstabil yang mencegah pembagian oleh nol ketika penyebut bernilai sangat kecil; adapun $\mu(i,j)$ dan $\sigma(i,j)$ masing-masing merepresentasikan rata-rata lokal dan deviasi standar lokal yang dihitung sebagai berikut:

   $$\mu(i,j) = \sum_{k=-K}^{K} \sum_{l=-L}^{L} w_{k,l}\, I_{k,l}(i,j), \tag{2.29}$$

   $$\sigma(i,j) = \sqrt{\sum_{k=-K}^{K} \sum_{l=-L}^{L} w_{k,l} \Big(I_{k,l}(i,j) - \mu(i,j) \Big)^2}, \tag{2.30}$$

   dengan $w = \{w_{k,l} \mid k = -K, \ldots, K,\ l = -L, \ldots, L\}$ merupakan fungsi pembobot Gaussian dua dimensi yang bersifat simetris-melingkar, disampel hingga radius tiga standar deviasi dan dinormalisasi sehingga jumlah bobotnya sama dengan satu. Pada implementasi standar digunakan nilai $K = L = 3$ (Mittal et al., 2012).

   Ruderman (1994) menemukan bahwa pada citra alami yang tidak mengalami distorsi, koefisien MSCN yang dihasilkan umumnya terdistribusi mendekati distribusi Gaussian normal satuan. Kehadiran distorsi pada citra akan menggeser karakteristik distribusi tersebut secara khas bergantung pada jenis distorsinya; sebagai contoh, blur Gaussian cenderung mengubah distribusi menjadi lebih menyerupai distribusi Laplacian, sementara kebisingan putih justru mempersempit

ekor distribusi (Mittal et al., 2012). Pola perubahan statistik inilah yang dieksploitasi BRISQUE sebagai dasar penilaian kualitas citra.

2. Pemodelan Statistik dengan *Generalized Gaussian Distribution* (GGD)

   Guna menangkap ragam karakteristik statistik citra terdistorsi secara lebih menyeluruh, BRISQUE mengadopsi *Generalized Gaussian Distribution* (GGD) bermean nol sebagai model parametrik untuk mendekati distribusi empiris koefisien MSCN (Mittal et al., 2012):

$$f\left(x;\, \alpha, \sigma^2\right) = \frac{\alpha}{2\,\beta\,\Gamma(1/\alpha)} \exp\left(-\left(\frac{|x|}{\beta}\right)^{\alpha}\right), \tag{2.31}$$

   dengan

$$\beta = \sigma\sqrt{\frac{\Gamma(1/\alpha)}{\Gamma(3/\alpha)}}, \tag{2.32}$$

   serta $\Gamma(\cdot)$ merupakan fungsi gamma yang didefinisikan sebagai:

$$\Gamma(a) = \int_0^{\infty} t^{a-1}\, e^{-t}\, dt, \quad a > 0. \tag{2.33}$$

   Dalam model GGD ini, parameter α berperan mengatur "bentuk" kurva distribusi, sedangkan σ^2 menentukan besar variansinya. Nilai kedua parameter (α, σ^2) diperoleh melalui prosedur estimasi berbasis *moment-matching* (Sharifi & Leon-Garcia, 1995). Sepasang parameter inilah yang membentuk gugus fitur pertama yang diekstrak dari setiap citra.

3. Produk Berpasangan MSCN dan *Asymmetric Generalized Gaussian Distribution* (AGGD)

   Di samping analisis statistik setiap piksel secara tersendiri, BRISQUE juga memperhitungkan keterkaitan statistik antarpiksel yang berdekatan. Hal ini dilakukan dengan memodelkan distribusi empiris hasil kali berpasangan (*pairwise products*) koefisien MSCN di empat arah orientasi, yaitu horizontal (H), vertikal (V), diagonal utama (D1), dan diagonal sekunder (D2) (Mittal et al., 2012):

$$H(i,j) = \hat{I}(i,j)\,\hat{I}(i,j+1), \tag{2.34}$$
$$V(i,j) = \hat{I}(i,j)\,\hat{I}(i+1,j), \tag{2.35}$$
$$D_1(i,j) = \hat{I}(i,j)\,\hat{I}(i+1,j+1), \tag{2.36}$$
$$D_2(i,j) = \hat{I}(i,j)\,\hat{I}(i+1,j-1). \tag{2.37}$$

   Distribusi dari keempat produk berpasangan tersebut direpresentasikan menggunakan *Asymmetric Generalized Gaussian Distribution* (AGGD) bermodus nol (Mittal et al., 2012; Lasmar, Stitou, & Berthoumieu, 2009), yang memiliki bentuk:

$$f\left(x;\,\nu,\sigma_l^2,\sigma_r^2\right)=\begin{cases}\dfrac{\nu}{(\beta_l+\beta_r)\,\Gamma(1/\nu)}\exp\!\left(-\left(\dfrac{-x}{\beta_l}\right)^{\nu}\right), & x<0,\\[2ex] \dfrac{\nu}{(\beta_l+\beta_r)\,\Gamma(1/\nu)}\exp\!\left(-\left(\dfrac{x}{\beta_r}\right)^{\nu}\right), & x\geq 0,\end{cases} \tag{2.38}$$

dengan

$$\beta_l=\sigma_l\sqrt{\frac{\Gamma(1/\nu)}{\Gamma(3/\nu)}},\qquad \beta_r=\sigma_r\sqrt{\frac{\Gamma(1/\nu)}{\Gamma(3/\nu)}}. \tag{2.39}$$

Pada model AGGD, parameter ν menentukan bentuk distribusi, sementara σ_l^2 dan σ_r^2 adalah parameter skala yang masing-masing mengatur lebar sebaran di sisi kiri dan kanan modus. Adapun momen pertama distribusi AGGD, yakni nilai rata-ratanya η, dapat dinyatakan sebagai:

$$\eta=(\beta_r-\beta_l)\,\frac{\Gamma(2/\nu)}{\Gamma(1/\nu)}. \tag{2.40}$$

Karena setiap produk berpasangan dideskripsikan oleh empat parameter $(\eta,\nu,\sigma_l^2,\sigma_r^2)$, proses pencocokan AGGD pada keempat orientasi menghasilkan sejumlah $4\times 4=16$ fitur tambahan.

4. Vektor Fitur 36 Dimensi

   BRISQUE menerapkan ekstraksi fitur secara multiskala pada dua tingkatan resolusi: resolusi penuh dari citra asli dan resolusi yang telah diperkecil melalui *downsampling* dengan faktor 2. Pada tiap-tiap skala, proses pencocokan GGD terhadap koefisien MSCN menghasilkan 2 fitur, sedangkan pencocokan AGGD pada keempat produk berpasangan menghasilkan $4\times 4=16$ fitur, sehingga setiap skala memberikan $2+16=18$ fitur. Dengan dua skala, total dimensi vektor fitur yang diperoleh adalah $18\times 2=36$ (Mittal et al., 2012). Rincian dari setiap gugus fitur dirangkum pada Tabel 2.2.

Tabel 2.2 Ringkasan Fitur yang Diekstrak dalam BRISQUE

ID Fitur	**Deskripsi**	**Prosedur Komputasi**
f_1–f_2	Bentuk dan variansi	Pencocokan GGD pada koefisien MSCN
f_3–f_6	Bentuk, mean, variansi kiri-kanan	Pencocokan AGGD pada produk H
f_7–f_{10}	Bentuk, mean, variansi kiri-kanan	Pencocokan AGGD pada produk V
f_{11}–f_{14}	Bentuk, mean, variansi kiri-kanan	Pencocokan AGGD pada produk D1
f_{15}–f_{18}	Bentuk, mean, variansi kiri-kanan	Pencocokan AGGD pada produk D2

Fitur f_1–f_{18} diekstrak pada skala asli; fitur f_{19}–f_{36} diekstrak pada skala yang direduksi dengan prosedur yang sama.

5. Pemetaan ke Skor Kualitas menggunakan *Support Vector Machine*

   Vektor fitur berdimensi 36 yang telah diekstrak selanjutnya dipetakan ke dalam ruang skor kualitas menggunakan pendekatan *Support Vector Regression* (SVR),

yang merupakan varian regresi dari *Support Vector Machine* (SVM). Fungsi kernel yang digunakan dalam implementasi ini adalah *Radial Basis Function* (RBF):

$$K(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|^2}{2\sigma^2}\right). \tag{2.41}$$

Pelatihan model SVR dilakukan secara terawasi (*supervised*) menggunakan pasangan vektor fitur dan skor penilaian kualitas subyektif manusia berupa MOS atau DMOS yang diperoleh dari basis data kualitas citra publik, seperti LIVE IQA Database (Mittal et al., 2012). Seluruh proses pelatihan dan pengujian diimplementasikan menggunakan pustaka LIBSVM (Chang & Lin, 2011). Model SVR yang telah terlatih kemudian mampu memprediksi skor kualitas dari citra baru mana pun secara otomatis tanpa memerlukan citra acuan apapun (Mittal et al., 2012).

BAB III
METODOLOGI

Pada bab ini dijelaskan tahapan-tahapan yang dilakukan dalam pelaksanaan penelitian Tugas Akhir. Metodologi penelitian disusun secara sistematis sebagai pedoman pelaksanaan penelitian mulai dari studi literatur, pengumpulan data, pelatihan model, pengujian, hingga analisis hasil.

3.1 Tahapan Penelitian

Berdasarkan kerangka kerja penelitian, prosedur penelitian Tugas Akhir ini dibagi menjadi beberapa tahapan sebagaimana diilustrasikan pada Gambar Gambar 3.1.

1. **Studi Literatur**

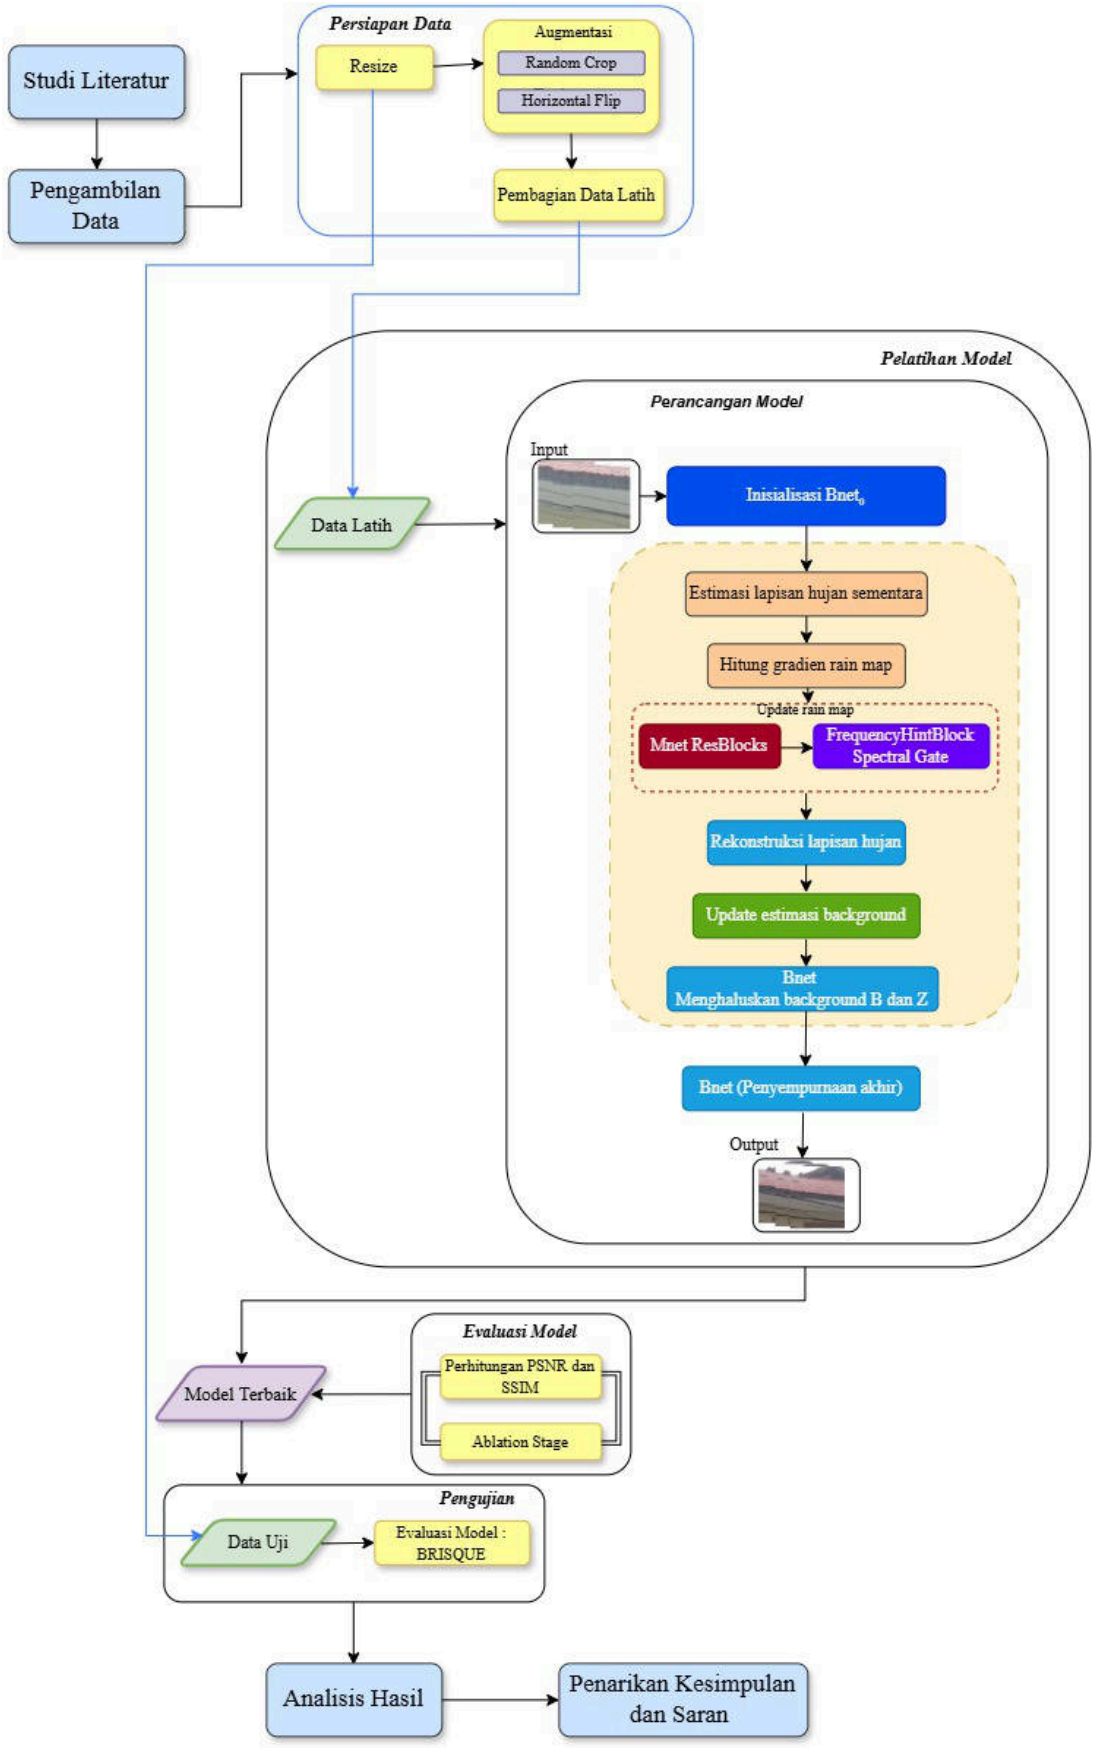
   Tahapan studi literatur dilakukan untuk memperkaya referensi dan memperdalam pemahaman mengenai teori, metode, serta penelitian terdahulu yang berkaitan dengan *Single Image Deraining*, RCDNet, *FrequencyHint*, transformasi Fourier, serta metode evaluasi kualitas citra. Referensi diperoleh dari jurnal ilmiah, buku, prosiding, tugas akhir, maupun sumber ilmiah lain yang relevan sehingga dapat menjadi dasar dalam penyusunan dan pelaksanaan penelitian.

2. **Pengambilan Data**

   Pengambilan data dilakukan untuk memperoleh data yang digunakan selama proses pelatihan, pengujian, dan evaluasi model. Data yang digunakan dalam penelitian ini terdiri atas data sekunder, data sintetik, dan data primer.

   (a) **Data Sekunder (Rain100L dan Rain100H)**
   Data sekunder merupakan dataset *benchmark* Rain100L dan Rain100H yang diperoleh melalui repositori publik *JRDR - Deraining Dataset* pada platform Kaggle. Kedua dataset tersebut merupakan data berpasangan (*paired dataset*), yaitu setiap citra hujan (*rainy image*) memiliki pasangan citra bersih (*clean image*) sebagai *ground truth*. Pasangan citra tersebut digunakan selama proses pelatihan agar model dapat mempelajari pemetaan dari citra hujan menuju citra bersih, serta digunakan kembali pada tahap pengujian untuk menghitung metrik evaluasi berbasis referensi berupa PSNR dan SSIM.

   (b) **Data Sintetik**
   Data sintetik terdiri atas 1.500 pasang citra yang diperoleh melalui platform Kaggle. Data ini dikategorikan sebagai data sintetik karena efek guratan hujan (*rain streaks*) dibangkitkan secara komputasional sehingga bukan berasal dari kondisi hujan nyata. Data sintetik hanya digunakan pada tahap pengujian (*testing*) untuk mengevaluasi



Gambar 3.1 Tahapan Penelitian

kemampuan generalisasi model (*zero-shot*) dan tidak digunakan selama proses pelatihan.

(c) **Data Primer**
Data primer merupakan data yang dikumpulkan secara langsung oleh penulis menggunakan kamera *smartphone*. Sebanyak 487 citra hujan nyata diperoleh melalui proses pengambilan gambar pada berbagai kondisi hujan. Karena tidak memiliki pasangan citra bersih (*ground truth*), data primer hanya digunakan pada tahap pengujian melalui evaluasi kualitatif dan evaluasi kuantitatif *no-reference* menggunakan metrik BRISQUE (*Blind/Referenceless Image Spatial Quality Evaluator*).

3. **Persiapan Data**

Tahap persiapan data dilakukan agar data siap digunakan dalam proses pelatihan dan pengujian model. Tahapan ini meliputi standarisasi data, augmentasi citra, serta pembagian data.

(a) **Standarisasi Ukuran dan Konversi Tipe Data**
Nilai intensitas piksel hasil pembacaan citra yang semula bertipe `uint8` dikonversi menjadi tipe `float32` agar kompatibel dengan proses komputasi pada jaringan saraf. Nilai piksel tetap dipertahankan pada rentang $[0, 255]$ tanpa dilakukan normalisasi ke rentang $[0, 1]$.

(b) **Augmentasi Citra**
Karena Rain100L dan Rain100H merupakan *paired dataset*, proses augmentasi dilakukan terhadap pasangan citra (*rainy image*, *clean image*) secara bersamaan menggunakan transformasi yang sama. Setiap pasangan citra dipotong secara acak menjadi *patch* berukuran 64×64 piksel menggunakan teknik *random crop*. Selanjutnya dilakukan *horizontal flip* secara acak selama proses pelatihan. Penerapan transformasi yang identik pada kedua citra pasangan bertujuan mempertahankan korespondensi spasial antara citra hujan dan citra bersih sehingga setiap piksel pada citra masukan tetap memiliki pasangan *ground truth* yang sesuai.

(c) **Pembagian Data**
Data sekunder Rain100L dan Rain100H dibagi menjadi data latih (*training set*) dan data uji (*test set*) sesuai pembagian resmi dataset. Penelitian ini tidak menggunakan *validation set* terpisah karena mengikuti protokol eksperimen pada RCDNet. Data sintetik digunakan sepenuhnya sebagai data uji untuk mengevaluasi kemampuan generalisasi model, sedangkan seluruh data primer digunakan sebagai data uji *no-reference*.

4. **Pelatihan RCDNet**

Data latih yang telah dipersiapkan selanjutnya digunakan untuk melatih model RCDNet yang telah diintegrasikan dengan *FrequencyHint*. Seluruh proses pelatihan dilakukan menggunakan pasangan citra hujan dan citra bersih secara *end-to-end*. Pada tahap ini, algoritma *Proximal Gradient Descent* (PGD) tidak dijalankan sebagai algoritma optimasi terpisah, melainkan telah di-*unfold* menjadi arsitektur RCDNet sehingga setiap pembaruan *rain map* dan *background layer* direpresentasikan sebagai satu *stage*. Parameter-parameter pada setiap *stage* dipelajari secara otomatis menggunakan proses *backpropagation* dengan optimizer Adam.

(a) **Model Rain Convolutional Dictionary (RCD)**
Citra hujan O dimodelkan sebagai

$$O = B + M * C + N,$$

dengan B menyatakan *background layer*, M menyatakan *rain map*, C merupakan *rain convolutional dictionary* yang merepresentasikan pola guratan hujan, sedangkan N merupakan komponen *noise*. Formulasi ini menjadi dasar matematis dalam pembentukan arsitektur RCDNet.

(b) **Algoritma Proximal Gradient Descent (PGD)**
Permasalahan optimasi pada model RCD diselesaikan menggunakan pendekatan *Proximal Gradient Descent* (PGD). Dalam implementasi RCDNet, setiap iterasi PGD di-*unfold* menjadi satu *stage* jaringan sehingga pembaruan *rain map* (M) dan *background layer* (B) dilakukan secara bertahap di dalam arsitektur jaringan. Parameter-parameter yang berkaitan dengan proses PGD, seperti ukuran langkah pembaruan dan nilai *threshold*, dipelajari secara otomatis selama pelatihan melalui proses *backpropagation* menggunakan optimizer Adam.

(c) ***Deep Unfolding* menjadi RCDNet**
Iterasi-iterasi PGD kemudian di-*unfold* menjadi arsitektur jaringan RCDNet. Setiap satu iterasi direpresentasikan sebagai satu *stage* yang terdiri atas M-net untuk memperbarui *rain map* dan B-net untuk memperbarui *background layer*. Dengan demikian proses optimasi iteratif dapat dipelajari secara langsung melalui jaringan saraf. Pada penelitian ini digunakan konfigurasi sebanyak $S = 17$ *stage* sesuai konfigurasi bawaan RCDNet.

(d) **Integrasi *FrequencyHint***
Blok *FrequencyHint* disisipkan pada jalur M-net di setiap *stage* RCDNet. Blok ini mengubah fitur spasial ke domain frekuensi menggunakan `rfft2`, mengekstraksi informasi spektral melalui magnitudo frekuensi, kemudian menerapkan *spectral gate* berbasis arsitektur *bottleneck* (Conv $32 \rightarrow 8 \rightarrow 8 \rightarrow 32$) yang dilengkapi *Batch Normalization* dan fungsi aktivasi *Sigmoid*. Hasil penyaringan frekuensi kemudian dikembalikan ke domain spasial menggunakan `irfft2` dan digabungkan melalui *residual connection*. Dengan mekanisme tersebut, informasi frekuensi dimanfaatkan untuk membantu M-net membedakan pola *rain streaks* dan tekstur latar belakang tanpa mengubah formulasi dasar RCDNet.

Seluruh varian model dilatih menggunakan konfigurasi yang sama, yaitu optimizer Adam dengan *learning rate* sebesar 0,001, fungsi *loss* Mean Squared Error (MSE), selama 100 *epoch*, serta *learning rate decay* sebesar 0,2 pada *epoch* ke-25, ke-50, dan ke-75.

5. **Pemilihan Model RCDNet Terbaik**

Setelah proses pelatihan selesai selama 100 *epoch*, model pada *epoch* terakhir dipilih sebagai model terbaik sesuai protokol eksperimen RCDNet (H. Wang, Xie, & Zhao, 2020). Selama proses pelatihan, bobot model disimpan menggunakan mekanisme *checkpoint* pada setiap *epoch* untuk mengantisipasi kehilangan data akibat gangguan yang tidak terduga.

6. **Pengujian RCDNet (*Deraining*)**

   Tahap pengujian dilakukan menggunakan data uji yang tidak pernah digunakan selama proses pelatihan. Pada tahap ini model hanya melakukan *forward pass* melalui seluruh *stage* RCDNet yang telah dipelajari pada proses pelatihan untuk menghasilkan citra hasil *deraining*. Hasil rekonstruksi kemudian disimpan dalam format PNG sebagai bahan evaluasi kuantitatif maupun analisis visual.

7. **Evaluasi Model**

   Evaluasi dilakukan berdasarkan ketersediaan pasangan *ground truth* pada masing-masing jenis data.

   (a) **Evaluasi Data Berpasangan (*Reference-Based*)**
   Evaluasi pada data sekunder Rain100L, Rain100H, dan data sintetik dilakukan menggunakan metrik PSNR dan SSIM yang dihitung terhadap pasangan citra *ground truth* pada kanal Y ruang warna YCbCr. Semakin tinggi nilai PSNR dan semakin mendekati satu nilai SSIM menunjukkan kualitas hasil *deraining* yang semakin baik.

   (b) **Evaluasi Data Tanpa Ground Truth (*No-Reference*)**
   Karena data primer tidak memiliki pasangan citra bersih, evaluasi dilakukan menggunakan metrik BRISQUE. Nilai BRISQUE yang lebih rendah menunjukkan kualitas visual citra yang semakin baik.

8. **Analisis Hasil**

   Analisis dilakukan berdasarkan hasil evaluasi kuantitatif dan kualitatif. Analisis meliputi perbandingan performa antar varian model pada Rain100L dan Rain100H, analisis ablasi jumlah *stage* PGD (S = 10, 15, 17, dan 20), evaluasi kemampuan generalisasi menggunakan data sintetik, serta evaluasi pada citra hujan nyata menggunakan data primer. Selain itu dilakukan analisis visual terhadap hasil *deraining* dan visualisasi *rain map* untuk memahami pengaruh integrasi *FrequencyHint* terhadap proses pemisahan guratan hujan.

9. **Penarikan Kesimpulan dan Saran**

   Tahap terakhir dilakukan dengan menyusun kesimpulan berdasarkan hasil penelitian untuk menjawab rumusan masalah dan tujuan penelitian. Selanjutnya diberikan saran sebagai rekomendasi pengembangan penelitian di masa mendatang serta dilakukan penyusunan laporan Tugas Akhir secara keseluruhan.

BAB IV
PERANCANGAN DAN IMPLEMENTASI

Pada bab ini dijelaskan mengenai perancangan dan implementasi model RCDNet-FH v2 untuk menghilangkan noise hujan pada citra digital. Proses perancangan dan implementasi dijelaskan secara terperinci mulai dari tahap persiapan data, perancangan model, perancangan sistem, hingga implementasi program yang telah dibuat.

4.1 Perancangan

Tahap perancangan merupakan tahapan untuk mendeskripsikan rancangan sistem sebelum diimplementasikan ke dalam program. Pada penelitian ini, proses perancangan meliputi persiapan data, perancangan tahapan pra-pemrosesan, perancangan arsitektur RCDNet-FH v2, perancangan modul *FrequencyHint* v2 sebagai kontribusi utama penelitian, serta perancangan skenario pelatihan dan pengujian model. Setiap tahapan dirancang agar membentuk alur pemrosesan yang sistematis sehingga implementasi yang dilakukan sesuai dengan tujuan penelitian.

4.1.1 Pengambilan Data

Pengambilan data merupakan tahap awal dalam proses perancangan sistem yang bertujuan untuk menentukan sumber data yang akan digunakan selama proses pelatihan dan pengujian model. Dataset yang digunakan pada penelitian ini terdiri atas tiga jenis, yaitu dataset sekunder, dataset sintetik, dan dataset primer. Ketiga dataset tersebut memiliki karakteristik serta tujuan penggunaan yang berbeda sehingga mampu mendukung evaluasi model secara komprehensif, baik pada data *benchmark*, data sintetik, maupun citra hujan nyata.

Dataset sekunder digunakan sebagai data utama untuk proses pelatihan dan pengujian kuantitatif model. Dataset sintetik digunakan untuk mengevaluasi kemampuan generalisasi model terhadap data yang tidak pernah dilihat selama pelatihan (*zero-shot testing*), sedangkan dataset primer digunakan untuk mengevaluasi performa model pada kondisi hujan nyata yang tidak memiliki citra *ground truth*. Ringkasan jenis dataset yang digunakan dalam penelitian ini disajikan pada Tabel 4.1.

Tabel 4.1 Ringkasan Dataset Penelitian

Jenis Dataset	**Jumlah Data**	**Ground Truth**	**Tujuan Penggunaan**
Sekunder (Rain100L)	1.800 latih + 100 uji	Ada	Pelatihan dan Pengujian
Sekunder (Rain100H)	1.800 latih + 100 uji	Ada	Pelatihan dan Pengujian
Sintetik	1.500 pasang	Ada	Uji Generalisasi (*Zero-shot*)
Primer	487 citra	Tidak Ada	Evaluasi Data Nyata

Penjelasan masing-masing dataset yang digunakan dalam penelitian ini dijelaskan sebagai berikut.

1. **Dataset Sekunder**

   Dataset sekunder merupakan dataset yang diperoleh dari sumber publik dan digunakan sebagai dataset utama dalam penelitian ini. Dataset tersebut terdiri atas Rain100L dan Rain100H yang diperkenalkan oleh Yang *et al.* dan telah digunakan secara luas sebagai *benchmark* pada penelitian *single image deraining*. Kedua dataset menyediakan pasangan citra berhujan dan citra bersih (*ground truth*) sehingga memungkinkan evaluasi kuantitatif menggunakan metrik PSNR dan SSIM.

   Rain100L merepresentasikan kondisi hujan ringan (*light rain*), sedangkan Rain100H merepresentasikan kondisi hujan lebat (*heavy rain*). Masing-masing dataset terdiri atas 1.800 pasangan citra untuk proses pelatihan dan 100 pasangan citra untuk proses pengujian. Rincian dataset sekunder disajikan pada Tabel 4.2.

Tabel 4.2 Rincian Dataset Sekunder

Dataset	Data Latih	Data Uji	Karakteristik
Rain100L	1.800 pasang	100 pasang	Hujan ringan (*light rain*)
Rain100H	1.800 pasang	100 pasang	Hujan lebat (*heavy rain*)

Contoh pasangan citra pada dataset sekunder ditunjukkan pada Gambar 4.1. Dataset ini digunakan sebagai acuan utama dalam proses pelatihan model serta evaluasi kuantitatif menggunakan metrik PSNR dan SSIM.



Gambar 4.1 Contoh dataset sekunder (Rain100L dan Rain100H)

2. **Dataset Sintetik**

   Selain menggunakan dataset *benchmark*, penelitian ini juga membangun sebuah dataset sintetik yang terdiri atas 1.500 pasangan citra. Dataset ini dikonstruksi secara mandiri oleh penulis sehingga tidak tersedia secara publik. Tujuan utama penyusunan dataset sintetik adalah untuk mengevaluasi kemampuan generalisasi model melalui skenario *zero-shot testing*, yaitu

pengujian terhadap data yang sama sekali tidak digunakan selama proses pelatihan.

Dataset sintetik dirancang agar memiliki variasi intensitas hujan, mulai dari hujan ringan hingga hujan lebat, sehingga dapat digunakan untuk mengukur kemampuan model dalam melakukan restorasi citra pada distribusi data yang berbeda dari dataset pelatihan.



Gambar 4.2 Contoh dataset sintetik

3. **Dataset Primer**

Dataset primer terdiri atas 487 citra hujan nyata yang diperoleh secara langsung menggunakan kamera *smartphone* pada berbagai kondisi lingkungan dan intensitas hujan. Berbeda dengan dataset sekunder maupun dataset sintetik, dataset primer tidak memiliki pasangan citra bersih (*ground truth*), sehingga tidak memungkinkan dilakukan evaluasi menggunakan metrik berbasis referensi seperti PSNR maupun SSIM.

Oleh karena itu, evaluasi kualitas hasil *deraining* pada dataset primer dilakukan menggunakan metrik *no-reference*, yaitu BRISQUE dan Laplacian Variance. Kedua metrik tersebut digunakan untuk menilai peningkatan kualitas visual serta tingkat ketajaman citra setelah diproses oleh model RCDNet-FH v2.



Gambar 4.3 Contoh dataset primer

4.1.2 Pra-pemrosesan Data

Secara umum, tahapan pra-pemrosesan yang diterapkan pada penelitian ini meliputi pembacaan pasangan citra hujan dan citra bersih, perubahan ukuran citra, konversi representasi data, augmentasi data latih, serta pembentukan *mini-batch* menggunakan *DataLoader*. Setiap tahapan pada proses pra-pemrosesan dirancang agar pasangan citra masukan dan citra target tetap memiliki korespondensi piksel yang sama. Tahapan pra-pemrosesan yang dilakukan terdiri atas beberapa proses sebagai berikut.

1. Pembacaan Pasangan Citra

   Tahap pertama pada proses pra-pemrosesan adalah membaca pasangan citra hujan (*rainy image*) dan citra bersih (*ground truth*) dari direktori dataset. Kedua citra dibaca secara berpasangan berdasarkan nama berkas sehingga setiap citra hujan selalu memiliki pasangan citra target yang sesuai. Mekanisme ini penting karena proses pelatihan RCDNet-FH v2 menggunakan pendekatan *supervised learning* yang membutuhkan korespondensi piksel antara citra masukan dan citra target.

   Pada tahap ini belum dilakukan perubahan terhadap isi citra. Data hanya dimuat ke dalam memori sebagai matriks tiga dimensi yang terdiri atas tinggi (H), lebar (W), dan kanal warna (C). Struktur tersebut menjadi masukan awal untuk tahapan pra-pemrosesan berikutnya.

2. Normalisasi Nilai Piksel

   Setelah citra berhasil dibaca, setiap nilai intensitas piksel dinormalisasi ke dalam rentang $[0, 1]$. Normalisasi bertujuan menyamakan skala data sehingga proses optimisasi selama pelatihan menjadi lebih stabil serta mempercepat proses konvergensi model.

   Nilai normalisasi dihitung menggunakan Persamaan berikut.

$$I_{norm} = \frac{I}{255} \tag{4.1}$$

   dengan

   I = nilai piksel awal (0–255)
   I_{norm} = nilai piksel hasil normalisasi.

   Berikut merupakan contoh normalisasi nilai piksel dengan memisalkan sebuah piksel mempunyai nilai

$$I = 128$$

   maka

$$I_{norm} = \frac{128}{255} = 0.50196$$

   Dengan demikian nilai piksel 128 berubah menjadi 0,50196 sehingga seluruh piksel berada pada rentang 0 sampai 1.

3. Konversi ke Tensor

Setelah proses normalisasi selesai, citra diubah menjadi tensor agar dapat diproses menggunakan framework PyTorch. Selain perubahan tipe data menjadi *floating point*, urutan dimensi citra juga diubah dari format Height × Width × Channel (HWC) menjadi Channel × Height × Width (CHW). Bentuk tersebut merupakan format standar yang digunakan pada operasi konvolusi dalam jaringan saraf.Berikut merupakan contoh konversi ke tensor dengan memisalkan ukuran citra

$$256 \times 256 \times 3$$

maka setelah konversi menjadi tensor akan berubah menjadi

$$3 \times 256 \times 256$$

Perubahan ini tidak mengubah informasi visual citra, tetapi hanya mengubah susunan penyimpanan data di dalam memori.

4. *Random Crop*

   Teknik *random crop* digunakan untuk menghasilkan variasi data latih dengan mengambil sebagian area citra secara acak. Teknik ini bertujuan meningkatkan keragaman sampel pelatihan sehingga model tidak hanya mempelajari lokasi objek tertentu.

   Pada penelitian ini ukuran hasil *crop* ditetapkan sebesar 64×64 piksel. Berikut merupakan contoh *random crop* dengan memisalkan ukuran citra awal

   $$256 \times 256$$

   dipilih titik awal

   $$(x, y) = (80, 45)$$

   dengan ukuran *crop*

   $$64 \times 64$$

   maka area yang diambil adalah

   $$x = 80 \text{ s.d. } 143$$

   $$y = 45 \text{ s.d. } 108$$

   Sehingga diperoleh citra baru berukuran

   $$64 \times 64.$$

   Karena proses ini dilakukan secara acak pada setiap *epoch*, model memperoleh variasi area pelatihan yang berbeda-beda meskipun berasal dari citra yang sama.

5. *Horizontal Flip*

   Selain *random crop*, diterapkan pula augmentasi berupa *horizontal flip*. Teknik ini membalik citra terhadap sumbu vertikal sehingga orientasi objek berubah dari kiri ke kanan tanpa mengubah karakteristik visual citra. Secara matematis transformasi tersebut dinyatakan sebagai

$$I'(x, y) = I(W - 1 - x, y)$$

   dengan
   W = lebar citra,
   I = citra sebelum pembalikan,
   I' = citra setelah pembalikan.
   Misalkan terdapat satu baris piksel

$$[25,\ 80,\ 120,\ 200]$$

   maka setelah dilakukan *horizontal flip* menjadi

$$[200,\ 120,\ 80,\ 25].$$

   Transformasi ini diterapkan secara bersamaan pada citra hujan dan citra bersih sehingga korespondensi pasangan citra tetap terjaga.

6. Pembentukan *Mini-Batch*

   Tahap terakhir pada proses pra-pemrosesan adalah membentuk data menjadi beberapa *mini-batch*. Pembentukan *mini-batch* bertujuan meningkatkan efisiensi komputasi selama proses pelatihan serta mengoptimalkan penggunaan memori GPU. Berikut merupakan contoh *mini-batch* dengan jumlah data latih

$$N = 1800$$

   dengan ukuran

$$batch\ size = 18$$

   maka jumlah *batch* pada setiap *epoch* adalah

$$\frac{1800}{18} = 100$$

   Artinya, pada setiap *epoch* model melakukan proses pembaruan parameter sebanyak 100 kali hingga seluruh data selesai diproses.

4.1.3 Pembentukan Model

Pada subbab ini dijelaskan tahapan pembentukan model RCDNet-FH v2 beserta seluruh komponen pendukungnya. Model yang dibentuk merupakan modifikasi terhadap arsitektur RCDNet (H. Wang, Xie, & Zhao, 2020) dengan penambahan modul *FrequencyHint* v2 pada setiap Mnet. Pembentukan model

mencakup landasan matematis, arsitektur Mnet yang dimodifikasi, arsitektur Bnet, modul FH v2 sebagai *novelty* utama, perhitungan parameter tambahan, dan fungsi *loss* yang digunakan.

a. Landasan Matematis: Model Degradasi dan *Unrolled Proximal Gradient Descent*

RCDNet dibangun di atas model degradasi citra berhujan sebagaimana ditunjukkan pada Persamaan (4.2).

$$O = B + R, \qquad R = \mathbf{C} * M, \tag{4.2}$$

dengan:

- O : citra berhujan (*observed image*),
- B : latar belakang bersih (*background*),
- R : lapisan hujan (*rain layer*),
- $\mathbf{C}$: *rain kernel*,
- M : *rain map*.

Estimasi B dan M diformulasikan sebagai masalah optimasi pada Persamaan (4.3).

$$\min_{M,\,B} \frac{1}{2}\|O - B - \mathbf{C} * M\|_F^2 + \lambda_M \phi_M(M) + \lambda_B \phi_B(B), \tag{4.3}$$

dengan ϕ_M dan ϕ_B masing-masing merupakan regularisasi *sparsity* pada M dan regularisasi *structure prior* pada B. Masalah pada Persamaan (4.3) di-*unroll* menjadi jaringan dengan $S = 17$ *stage* yang dilatih *end-to-end* melalui algoritma *Proximal Gradient Descent* (PGD).

Pembaruan untuk M pada setiap *stage* s mengikuti langkah PGD pada Persamaan (4.4), sedangkan pembaruan B menggunakan *weighted update* pada Persamaan (4.5) dan (4.6).

$$M^{(s)} = \mathrm{Mnet}_s\left(M^{(s-1)} - \frac{\eta_M^{(s)}}{10}\,\mathbf{C}^\top * \left(R^{(s-1)} - \hat{R}^{(s-1)}\right)\right), \tag{4.4}$$

$$B_{\mathrm{mid}}^{(s)} = \left(1 - \frac{\eta_B^{(s)}}{10}\right)B^{(s-1)} + \frac{\eta_B^{(s)}}{10}\,\hat{B}^{(s)}, \tag{4.5}$$

$$B^{(s)} = \mathrm{Bnet}_s\left(B_{\mathrm{mid}}^{(s)}\right), \tag{4.6}$$

dengan:

- $\eta_M^{(s)}, \eta_B^{(s)}$: *step size* pada *stage* s,
- $\hat{R}^{(s)} = O - B^{(s)}$: estimasi lapisan hujan,
- $\hat{B}^{(s)} = O - R^{(s)}$: estimasi latar belakang.

Sebagai ilustrasi, dimisalkan pada *stage* $s = 2$ diberikan nilai skalar sederhana (satu elemen): $M^{(1)} = 0{,}6$, $R^{(1)} = 0{,}5$, $\hat{R}^{(1)} = O - B^{(1)} = 0{,}7$, $\eta_M^{(1)} = 1$, dan $\mathbf{C}^\top = 1$

(penyederhanaan skalar). Langkah *gradient step* menghasilkan:

$$M_{\text{pre}}^{(2)} = 0{,}6 - \frac{1}{10}\,(0{,}5 - 0{,}7) = 0{,}6 + 0{,}02 = 0{,}62.$$

Nilai ini menjadi masukan Mnet_2 yang selanjutnya diproses oleh $T = 4$ ResBlock, FH v2, dan *sparse thresholding* untuk menghasilkan $M^{(2)}$.

b. Pembentukan Arsitektur Mnet dengan *FrequencyHint* v2

Mnet (`proxNet_M`) adalah jaringan proksimal yang mengimplementasikan operator proksimal untuk *rain map* M pada setiap *stage* iterasi PGD. Pada penelitian ini, Mnet dibentuk dengan menambahkan satu modul FH v2 yang disisipkan setelah empat ResBlock dan sebelum operasi *sparse thresholding*. Arsitektur lengkap Mnet yang telah dimodifikasi ditunjukkan pada Gambar 4.4.

Alur pemrosesan Mnet dibentuk melalui tiga tahap berurutan sebagai berikut.

1. $T = 4$ **ResBlock berangkai**, setiap ResBlock terdiri dari dua konvolusi 3×3 dengan *Batch Normalization* dan ReLU, dengan koneksi residual sebagaimana pada Persamaan (4.7).

$$M_{\text{out}} = \text{ReLU}\Big(M + f(M)\Big), \tag{4.7}$$

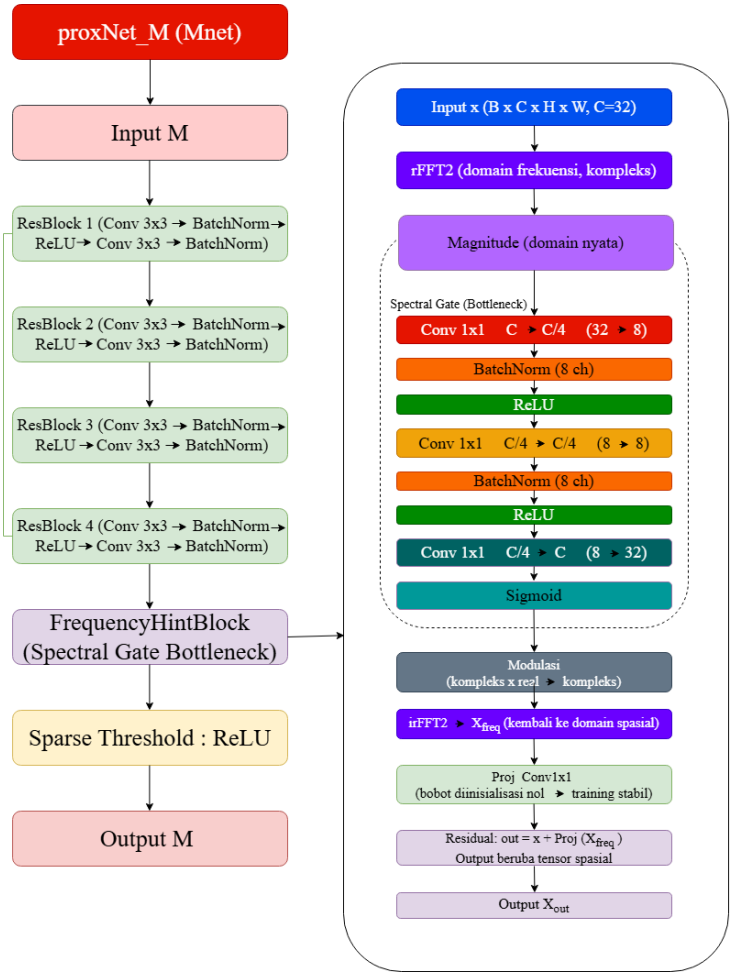
   dengan $f(\cdot)$ menyatakan fungsi Conv–BN–ReLU–Conv–BN.

2. ***FrequencyHint* v2**, memanfaatkan informasi domain frekuensi untuk memodulasi fitur secara adaptif (dijelaskan pada Subbab c).

3. ***Sparse Thresholding***, dirumuskan pada Persamaan (4.8).

$$M_{\text{out}} = \text{ReLU}(M - \boldsymbol{\tau}), \tag{4.8}$$

   dengan $\boldsymbol{\tau}$ adalah ambang batas per-*channel* yang dapat dipelajari.



Gambar 4.4 Arsitektur Mnet dengan *FrequencyHint*

Sebagai ilustrasi, dimisalkan input fitur satu *channel* berukuran 3×3 pada satu ResBlock adalah:

$$M_{\text{in}} = \begin{pmatrix} 0{,}2 & 0{,}4 & 0{,}1 \\ 0{,}5 & 0{,}3 & 0{,}6 \\ 0{,}1 & 0{,}7 & 0{,}2 \end{pmatrix},$$

dengan fungsi f (Conv–BN–ReLU–Conv–BN) menghasilkan output residual:

$$f(M_{\text{in}}) = \begin{pmatrix} 0{,}05 & 0{,}10 & 0{,}02 \\ 0{,}12 & 0{,}08 & 0{,}15 \\ 0{,}03 & 0{,}18 & 0{,}05 \end{pmatrix}.$$

Berdasarkan Persamaan (4.7), diperoleh output ResBlock:

$$M_{\text{out}} = \text{ReLU}\Big(M_{\text{in}} + f(M_{\text{in}})\Big) = \begin{pmatrix} 0{,}25 & 0{,}50 & 0{,}12 \\ 0{,}62 & 0{,}38 & 0{,}75 \\ 0{,}13 & 0{,}88 & 0{,}25 \end{pmatrix}.$$

Karena seluruh nilai bernilai non-negatif, ReLU tidak mengubah nilai apapun pada contoh ini.

Selanjutnya, pada tahap *Sparse Thresholding*, dimisalkan output FH v2 untuk

satu *channel* adalah matriks di atas dengan parameter $\tau = 0{,}5$. Berdasarkan Persamaan (4.8), diperoleh:

$$M_{\text{thresh}} = \text{ReLU}(M_{\text{out}} - 0{,}5) = \begin{pmatrix} 0 & 0 & 0 \\ 0{,}12 & 0 & 0{,}25 \\ 0 & 0{,}38 & 0 \end{pmatrix}.$$

Komponen dengan nilai di bawah ambang batas ditekan menjadi nol, yang secara fisik berarti hanya komponen *rain map* yang signifikan yang dipertahankan.

c. Pembentukan Modul *FrequencyHint* (FH) v2: *Bottleneck Spectral Gate*

FrequencyHint merupakan *novelty* utama penelitian ini. Modul ini dibentuk berdasarkan observasi bahwa pola hujan memiliki karakteristik spektral yang khas di domain frekuensi, yaitu *rain streak* dengan orientasi tertentu menghasilkan komponen frekuensi yang terkonsentrasi dan dapat dibedakan dari frekuensi konten alami citra.

1. Arsitektur *Spectral Gate* v2

FH v2 dibentuk menggunakan arsitektur *bottleneck* yang terinspirasi dari SE-Net (Hu, Shen, & Sun, 2018) dengan tiga tahap sebagai berikut.

(a) **Compress**: Conv($C \to C/4$)–BN–ReLU, memaksa jaringan mempelajari representasi frekuensi yang kompak,

(b) **Refine**: Conv($C/4 \to C/4$)–BN–ReLU, interaksi non-linear di ruang laten yang lebih kecil,

(c) **Expand**: Conv($C/4 \to C$)–Sigmoid, mengembalikan *gate* ke dimensi *channel* asli.

Faktor reduksi yang digunakan adalah 4, dengan dimensi laten dihitung pada Persamaan (4.9).

$$C_{\text{mid}} = \max\left(\frac{C}{4},\, 8\right). \tag{4.9}$$

Untuk $C = 32$, diperoleh $C_{\text{mid}} = \max(8,\, 8) = 8$.

2. Alur *Forward Pass* FH v2

Diberikan input fitur $x \in \mathbb{R}^{B\times C\times H\times W}$, alur FH v2 dibentuk melalui enam langkah berikut.

(a) Transformasi ke domain frekuensi: $\hat{x} = \texttt{rfft2}(x, \texttt{norm='ortho'}) \in \mathbb{C}^{B\times C\times H\times (W/2+1)}$.

(b) Ekstraksi magnitudo: $m = |\hat{x}|$.

(c) *Spectral gate*: $g = \text{Sigmoid}(\text{Conv3}(\text{ReLU}(\text{Conv2}(\text{ReLU}(\text{Conv1}(m))))))$, dengan $g \in [0,1]^{B\times C\times H\times (W/2+1)}$.

(d) Modulasi spektrum: $\hat{x}_g = \hat{x} \odot g$.

(e) Kembali ke domain spasial: $x_{\text{freq}} = \texttt{irfft2}(\hat{x}_g,\, s{=}(H, W))$.

(f) Koneksi residual dengan proyeksi nol: out $= x + \texttt{proj}(x_{\text{freq}})$.

Sebagai ilustrasi, dihitung `rfft2` sederhana dengan input satu *channel* berukuran $1 \times 1 \times 2 \times 4$ (*batch* 1, *channel* 1, H=2, W=4):

$$x = \begin{pmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \end{pmatrix}.$$

Setelah `rfft2` dengan `norm='ortho'`, diperoleh representasi spektrum kompleks berukuran 2×3 karena simetri Hermitian mengompres $W = 4$ menjadi $W/2+1 = 3$. Magnitudo spektrum $m = |\hat{x}|$ selanjutnya menjadi masukan *spectral gate*. Nilai *gate* g yang dihasilkan Sigmoid berada pada rentang $(0, 1)$, sehingga spektrum $\hat{x}$ dimodulasi secara selektif untuk menekan atau memperkuat komponen frekuensi tertentu sebelum dikembalikan ke domain spasial melalui `irfft2`.

3. Inisialisasi Nol pada Bobot Proyeksi

Detail implementasi yang krusial dalam pembentukan FH v2 adalah inisialisasi bobot konvolusi proyeksi (`proj`) dengan nilai nol, sebagaimana ditunjukkan pada Persamaan (4.10).

$$\texttt{nn.init.zeros_(self.proj.weight)} \;\Rightarrow\; \text{out}_{t=0} = x + \texttt{proj}(x_{\text{freq}}) = x + 0 = x. \tag{4.10}$$

Inisialisasi ini memastikan bahwa pada awal pelatihan, FH berperilaku identik dengan *identity function*, setara dengan *baseline* tanpa FH, kemudian secara bertahap mempelajari kontribusi frekuensi yang optimal.

d. Pembentukan Arsitektur Bnet (*Proximal Net* untuk *Background*)

Bnet dibentuk untuk mengimplementasikan operator proksimal bagi estimasi latar belakang B, dan berbagi arsitektur dasar berupa $T = 4$ ResBlock dengan Mnet. Perbedaan utama Bnet dari Mnet terletak pada jumlah *channel* masukan, jenis keluaran, dan ketiadaan FH maupun *sparse thresholding*. Masukan Bnet merupakan gabungan antara estimasi latar belakang B_{mid} (3 *channel* RGB) dan *dual variable* Z (32 *channel*), sehingga total *channel* masukan adalah $3 + 32 = 35$ *channel*. Keluaran Bnet berupa *tensor* 35-*channel* yang dipisah menjadi 3 *channel* pertama sebagai estimasi baru B dan 32 *channel* sisanya sebagai estimasi baru Z.

Perbandingan arsitektur Mnet dan Bnet yang telah dibentuk disajikan pada Tabel 4.3.

Tabel 4.3 Perbandingan Arsitektur Mnet dan Bnet

Aspek	**Mnet**	**Bnet**
Jumlah channel	32 (`num_M`)	35 (`num_Z`+3)
Jumlah ResBlock (T)	4	4
Kernel konvolusi	3×3	3×3
Sparse thresholding	Ya ($\boldsymbol{\tau}$)	Tidak
Keluaran	Rain map M	Background B + dual Z
Instance per model	$S = 17$	$S + 2 = 19$
FH (modifikasi)	Ya	Tidak

e. Perhitungan Jumlah Parameter Tambahan FH v2

Penambahan FH v2 pada pembentukan model hanya menambahkan parameter yang relatif kecil. Untuk $C = 32$ dan $C_{\text{mid}} = 8$, parameter tambahan per Mnet dihitung sebagaimana pada Persamaan (4.11).

$$\underbrace{C \times C_{\text{mid}}}_{\text{Conv1}} + \underbrace{C_{\text{mid}}^2}_{\text{Conv2}} + \underbrace{C_{\text{mid}} \times C}_{\text{Conv3}} + \underbrace{C^2}_{\texttt{proj}} = 32{\times}8{+}8^2{+}8{\times}32{+}32^2 = 256{+}64{+}256{+}1.024 = 1.600. \tag{4.11}$$

Dengan $S = 17$ *instance* Mnet, total tambahan parameter FH v2 dihitung sebagai:

$$17 \times 1.600 = 27.200 \text{ parameter.}$$

Jumlah ini sangat kecil dibandingkan total parameter jaringan secara keseluruhan, sehingga peningkatan biaya komputasi dan memori GPU minimal.

f. Pembentukan Fungsi *Loss*: *Multi-Stage Supervision*

Fungsi *loss* yang dibentuk pada penelitian ini adalah *multi-stage supervision loss* yang mengawasi estimasi pada setiap *stage* secara simultan untuk mencegah *vanishing gradient*. Formulasi lengkapnya ditunjukkan pada Persamaan (4.12).

$$\begin{aligned}\mathcal{L} = \underbrace{0{,}1\,\|B^{(0)} - B^*\|_F^2}_{\mathcal{L}_{B_0}} + \underbrace{\sum_{s=1}^{S} 0{,}1\,\|B^{(s)} - B^*\|_F^2}_{\mathcal{L}_{B_s}} + \underbrace{\|B^{(S+1)} - B^*\|_F^2}_{\mathcal{L}_B} \\ + \underbrace{\sum_{s=1}^{S} 0{,}1\,\|R^{(s)} - R^*\|_F^2}_{\mathcal{L}_{R_s}} + \underbrace{0{,}9\,\|R^{(S)} - R^*\|_F^2}_{\mathcal{L}_R},\end{aligned} \tag{4.12}$$

dengan $B^* =$ *ground truth* latar belakang dan $R^* = O - B^*$.

Sebagai ilustrasi, dimisalkan pada *stage* terakhir ($s = S + 1$) terdapat citra berukuran 2×2 (untuk sederhananya, satu *channel*):

$$B^{(S+1)} = \begin{pmatrix} 200 & 180 \\ 190 & 210 \end{pmatrix}, \quad B^* = \begin{pmatrix} 205 & 175 \\ 192 & 208 \end{pmatrix}.$$

Selisih piksel: $B^{(S+1)} - B^* = \left(\begin{smallmatrix} -5 & 5 \\ -2 & 2 \end{smallmatrix}\right)$, sehingga norma Frobenius kuadrat dihitung sebagai:

$$\|B^{(S+1)} - B^*\|_F^2 = (-5)^2 + 5^2 + (-2)^2 + 2^2 = 25 + 25 + 4 + 4 = 58.$$

Jika sebuah *stage* intermediat menghasilkan $\|B^{(s)} - B^*\|_F^2 = 120$, maka kontribusinya terhadap *loss* total adalah $0{,}1 \times 120 = 12$.

4.1.4 Perancangan Pelatihan Model

Pelatihan model dilakukan pada perangkat lokal menggunakan GPU NVIDIA yang mendukung CUDA. Seluruh konfigurasi *hyperparameter* pelatihan mengikuti implementasi resmi RCDNet agar perbandingan antar varian model bersifat adil dan perbedaan performa yang terukur dapat dikaitkan langsung dengan kontribusi

FH, bukan perbedaan prosedur pelatihan. Terdapat tiga varian model yang dilatih dalam penelitian ini, yaitu *Baseline* (tanpa FH), RCDNet-FH v1, dan RCDNet-FH v2. Perbedaan antar varian hanya terletak pada komponen Mnet, sementara seluruh aspek lain identik. Rincian varian yang dieksperimenkan disajikan pada Tabel 4.4.

Tabel 4.4 Varian Model yang Dilatih

Varian	**Berkas**	**Komponen Mnet**	***Spectral Gate***
Baseline	`rcdnet_baseline.py`	T ResBlocks + Sparse Threshold	—
RCDNet-FH v1	`rcdnet_v1.py`	T ResBlocks + FH v1 + Sparse Threshold	2 Conv (*flat*)
RCDNet-FH v2	`rcdnet.py`	T ResBlocks + FH v2 + Sparse Threshold	3 Conv (*bottleneck*)

Dataset yang digunakan untuk pelatihan adalah Rain100L dan Rain100H (dataset sekunder). RCDNet-FH v1 dan RCDNet-FH v2 masing-masing dilatih secara terpisah pada Rain100L dan Rain100H, sehingga diperoleh empat model hasil pelatihan. Selain itu, dilakukan satu eksperimen tambahan berupa pelatihan RCDNet-FH v2 pada dataset gabungan (*Mixed*) yang mengombinasikan Rain100L dan Rain100H, dengan tujuan menghasilkan model yang mampu menangani variasi intensitas hujan secara sekaligus. Ringkasan dataset pelatihan seluruh eksperimen disajikan pada Tabel 4.5.

Tabel 4.5 Dataset Pelatihan Seluruh Eksperimen

Model	**Dataset Pelatihan**	**Jumlah Pasang**
FH v1 Rain100L	Rain100L	1.800
FH v1 Rain100H	Rain100H	1.800
FH v2 Rain100L	Rain100L	1.800
FH v2 Rain100H	Rain100H	1.800
FH v2 Mixed	Rain100L dan Rain100H	3.600

Optimizer yang digunakan adalah Adam dengan *learning rate* awal $\eta_0 = 10^{-3}$. Penjadwalan *learning rate* menggunakan `MultiStepLR` dengan *milestone* pada epoch ke-25, 50, dan 75. Pada setiap *milestone*, nilai *learning rate* dikalikan dengan faktor reduksi $\gamma = 0{,}2$ sebagaimana ditunjukkan pada Persamaan (4.13).

$$\eta_{\text{baru}} = \eta_{\text{lama}} \times \gamma = \eta_{\text{lama}} \times 0{,}2. \tag{4.13}$$

Sebagai ilustrasi, dengan nilai awal $\eta_0 = 10^{-3}$, penurunan *learning rate* pada setiap *milestone* berdasarkan Persamaan (4.13) adalah sebagai berikut:

$$\begin{aligned}
\eta_{\text{epoch }25} &= 10^{-3} \times 0{,}2 = 2{,}0 \times 10^{-4}, \\
\eta_{\text{epoch }50} &= 2{,}0 \times 10^{-4} \times 0{,}2 = 4{,}0 \times 10^{-5}, \\
\eta_{\text{epoch }75} &= 4{,}0 \times 10^{-5} \times 0{,}2 = 8{,}0 \times 10^{-6}.
\end{aligned}$$

Skema penurunan bertahap ini dilakukan untuk mencegah model terlalu cepat konvergen di awal pelatihan. Seluruh konfigurasi *hyperparameter* yang berlaku identik untuk semua varian dan semua dataset disajikan pada Tabel 4.6.

Tabel 4.6 Konfigurasi *Hyperparameter* Pelatihan

Hyperparameter	**Argumen CLI**	**Nilai**	**Keterangan**
Learning rate awal	`--lr`	0,001	Optimizer Adam
Optimizer	—	Adam	`optim.Adam`
Penjadwal LR	`--milestone`	[25, 50, 75]	`MultiStepLR`, γ=0,2
Batch size	`--batchSize`	16	Jumlah *patch* per iterasi
Patch size	`--patchSize`	64	Ukuran *random crop*
Jumlah *epoch*	`--niter`	100	Total epoch pelatihan
Batch per *epoch* (Rain100L/H)	`--batchnum`	1.500	$\Rightarrow$ 24.000 *patch*/*epoch*
Batch per *epoch* (Mixed)	`--batchnum`	3.000	$\Rightarrow$ 48.000 *patch*/*epoch*
Jumlah *stage*	`--S`	17	Iterasi *unrolling* PGD
ResBlock per ProxNet	`--T`	4	ResBlock di Mnet & Bnet
Rain map channel	`--num_M`	32	Channel Mnet
Dual variable channel	`--num_Z`	32	Channel Z dalam Bnet
FH *reduction factor*	—	4	$C_{\text{mid}} = C/4 = 8$
GPU	`--gpu_id`	`"0"`	`CUDA_VISIBLE_DEVICES`
Workers	`--workers`	4	Proses paralel *data loader*

Proses penyimpanan bobot model menggunakan sistem *checkpoint*, di mana bobot pelatihan disimpan pada setiap akhir *epoch* dalam dua format, yaitu berkas metadata *epoch* (`model_{epoch}`) dan berkas *state dict* PyTorch (`DerainNet_state_{epoch}.pt`). Hal ini dilakukan untuk memungkinkan pemulihan pelatihan dari *checkpoint* mana pun apabila proses terhenti karena suatu kendala, sekaligus memudahkan pemilihan model terbaik berdasarkan metrik evaluasi pada akhir pelatihan.

Skenario Pelatihan

Skenario pelatihan dirancang untuk membandingkan performa RCDNet-FH v1 dan RCDNet-FH v2 secara sistematis pada berbagai kondisi intensitas hujan. Terdapat dua skenario pelatihan yang dilakukan.

1. **Skenario 1: Pelatihan RCDNet-FH v1**
   RCDNet-FH v1 mengintegrasikan modul FH dengan *spectral gate flat* berupa dua konvolusi 1×1 berangkai (Conv$C\to C$–BN–ReLU–Conv$C\to C$–Sigmoid) tanpa kompresi dimensi. Setelah pelatihan 100 epoch selesai, model dievaluasi menggunakan 100 citra uji dari masing-masing dataset menggunakan metrik PSNR dan SSIM. Rincian eksperimen skenario 1 disajikan pada Tabel 4.7.

Tabel 4.7 Rancangan Skenario 1: Pelatihan RCDNet-FH v1

No.	**Varian**	**Dataset Pelatihan**	**Dataset Uji**	**Metrik Evaluasi**
1	RCDNet-FH v1	Rain100L (1.800 pasang)	Rain100L (100 citra)	PSNR, SSIM
2	RCDNet-FH v1	Rain100H (1.800 pasang)	Rain100H (100 citra)	PSNR, SSIM

2. **Skenario 2: Pelatihan RCDNet-FH v2**

   RCDNet-FH v2 menggantikan *flat gate* FH v1 dengan arsitektur *bottleneck* tiga konvolusi (Conv$C \to C/4$–BN–ReLU–Conv$C/4 \to C/4$–BN–ReLU–Conv$C/4 \to C$–Sigmoid) yang memaksa jaringan mempelajari representasi frekuensi yang lebih kompak dan diskriminatif. Pelatihan pada Rain100L dan Rain100H bertujuan untuk membandingkan langsung performa FH v2 dengan FH v1 pada kondisi dataset yang sama, sedangkan pelatihan pada dataset Mixed bertujuan menghasilkan model yang mampu menangani berbagai intensitas hujan sekaligus, yang selanjutnya diuji pada dataset primer. Rincian eksperimen skenario 2 disajikan pada Tabel 4.8.

Tabel 4.8 Rancangan Skenario 2: Pelatihan RCDNet-FH v2

No.	Varian	Dataset Pelatihan	Dataset Uji	Metrik Evaluasi
1	RCDNet-FH v2	Rain100L (1.800 pasang)	Rain100L (100 citra)	PSNR, SSIM
2	RCDNet-FH v2	Rain100H (1.800 pasang)	Rain100H (100 citra)	PSNR, SSIM
3	RCDNet-FH v2	Rain100H (1.800 pasang)	Primer (487 foto)	BRISQUE, Laplacian Variance
4	RCDNet-FH v2	Mixed (3.600 pasang)	Primer (487 foto)	BRISQUE, Laplacian Variance

Total seluruh eksperimen pelatihan berjumlah 6 eksperimen. Ringkasan penggunaan dataset secara keseluruhan, mencakup pelatihan maupun pengujian, disajikan pada Tabel 4.9.

Tabel 4.9 Ringkasan Penggunaan Dataset

Dataset	Digunakan untuk Pelatihan	Digunakan untuk Pengujian
Rain100L	Ya (FH v1 & FH v2)	Ya
Rain100H	Ya (FH v1 & FH v2)	Ya
Sintetik	Tidak	Ya
Mixed	Ya (FH v2)	Ya
Primer	Tidak	Ya

4.1.5 Perancangan Evaluasi

Hasil pelatihan berupa *trained weight* selanjutnya digunakan untuk evaluasi model. Evaluasi dirancang melalui dua jalur yang disesuaikan dengan ketersediaan *ground truth* pada masing-masing jenis dataset, yaitu evaluasi pada dataset sekunder menggunakan metrik *full-reference* dan evaluasi pada dataset primer menggunakan metrik *no-reference*.

1. Evaluasi Dataset Sekunder (Rain100L dan Rain100H)

   Evaluasi pada dataset sintetik menggunakan metrik berbasis referensi (*full-reference*) karena tersedia pasangan citra berhujan dan citra bersih (*ground truth*). Dua metrik yang digunakan adalah PSNR (*Peak Signal-to-Noise Ratio*) dan SSIM (*Structural Similarity Index Measure*). Evaluasi dilakukan pada channel Y dari ruang warna YCbCr, bukan pada ruang warna RGB, karena sistem penglihatan manusia lebih sensitif terhadap perubahan luminansi (channel Y) dibandingkan komponen krominans. Konversi dilakukan

menggunakan `cv2.COLOR_BGR2YCrCb` dari OpenCV. Seluruh 100 citra data uji diproses secara penuh (*full image*, tanpa *patching*) dan nilai PSNR serta SSIM rata-rata dihitung sebagai metrik akhir menggunakan *library* scikit-image.

PSNR mengukur rasio antara nilai piksel maksimum dan *mean squared error* (MSE) antar citra, sebagaimana dirumuskan pada Persamaan (4.14) dan (4.15).

$$\mathrm{PSNR}(\hat{B}, B^*) = 10 \log_{10}\left(\frac{L^2}{\mathrm{MSE}(\hat{B}, B^*)}\right) \text{ [dB]}, \tag{4.14}$$

$$\mathrm{MSE} = \frac{1}{MN}\sum_{i=1}^{M}\sum_{j=1}^{N}\left(\hat{B}_{ij} - B^*_{ij}\right)^2, \tag{4.15}$$

dengan:

- $\hat{B}$: citra hasil *deraining*,
- B^* : citra *ground truth* (latar belakang bersih),
- $L = 255$: nilai intensitas piksel maksimum untuk citra 8-bit,
- M, N : dimensi tinggi dan lebar citra.

Semakin tinggi nilai PSNR, semakin baik kualitas rekonstruksi.

Sebagai ilustrasi, dimisalkan citra *ground truth* dan hasil *deraining* pada channel Y berukuran 4×4 piksel adalah:

$$B^* = \begin{pmatrix} 210 & 200 & 190 & 185 \\ 220 & 205 & 195 & 180 \\ 215 & 200 & 188 & 182 \\ 218 & 202 & 192 & 179 \end{pmatrix}, \quad \hat{B} = \begin{pmatrix} 212 & 198 & 191 & 183 \\ 219 & 207 & 196 & 181 \\ 213 & 202 & 187 & 184 \\ 220 & 200 & 193 & 178 \end{pmatrix}.$$

Selisih piksel $(\hat{B} - B^*)$ dan kuadratnya:

$$(\hat{B} - B^*)^2 = \begin{pmatrix} 4 & 4 & 1 & 4 \\ 1 & 4 & 1 & 1 \\ 4 & 4 & 1 & 4 \\ 4 & 4 & 1 & 1 \end{pmatrix}.$$

Berdasarkan Persamaan (4.15), diperoleh:

$$\mathrm{MSE} = \frac{1}{16}(4{+}4{+}1{+}4{+}1{+}4{+}1{+}1{+}4{+}4{+}1{+}4{+}4{+}4{+}1{+}1) = \frac{43}{16} = 2{,}6875.$$

Berdasarkan Persamaan (4.14), diperoleh:

$$\mathrm{PSNR} = 10 \log_{10}\left(\frac{255^2}{2{,}6875}\right) = 10 \log_{10}(24.186{,}0) = 10 \times 4{,}384 = 43{,}84 \text{ dB}.$$

SSIM mengukur kemiripan struktural antara dua citra berdasarkan luminansi, kontras, dan struktur secara lokal, sebagaimana dirumuskan pada

Persamaan (4.16).

$$\mathrm{SSIM}(\hat{B}, B^*) = \frac{(2\mu_{\hat{B}}\mu_{B^*} + C_1)(2\sigma_{\hat{B}B^*} + C_2)}{(\mu_{\hat{B}}^2 + \mu_{B^*}^2 + C_1)(\sigma_{\hat{B}}^2 + \sigma_{B^*}^2 + C_2)}, \tag{4.16}$$

dengan konstanta stabilisasi $C_1 = (0{,}01 \times 255)^2 = 6{,}5025$ dan $C_2 = (0{,}03 \times 255)^2 = 58{,}5225$. Nilai SSIM berada pada rentang $[0, 1]$; semakin mendekati 1, semakin mirip struktur kedua citra.

Sebagai ilustrasi lanjutan, menggunakan *patch* 4×4 di atas, diperoleh nilai rata-rata luminansi:

$$\mu_{B^*} = \frac{1}{16}\sum_{i,j} B^*_{ij} = \frac{3.165}{16} = 197{,}81, \quad \mu_{\hat{B}} = \frac{1}{16}\sum_{i,j} \hat{B}_{ij} = \frac{3.168}{16} = 198{,}00.$$

Variansi dan kovariansi:

$$\sigma_{B^*}^2 \approx 170{,}91, \quad \sigma_{\hat{B}}^2 \approx 168{,}50, \quad \sigma_{\hat{B}B^*} \approx 169{,}50.$$

Berdasarkan Persamaan (4.16), diperoleh:

$$\mathrm{SSIM} = \frac{(2 \times 197{,}81 \times 198{,}00 + 6{,}5025)(2 \times 169{,}50 + 58{,}5225)}{(197{,}81^2 + 198{,}00^2 + 6{,}5025)(170{,}91 + 168{,}50 + 58{,}5225)} \approx 0{,}9989.$$

Nilai SSIM yang mendekati 1 menunjukkan kemiripan struktural yang sangat tinggi antara hasil *deraining* dan *ground truth*.

Model terbaik pada setiap skenario pelatihan dipilih berdasarkan nilai PSNR dan SSIM tertinggi pada data uji di akhir epoch ke-100.

2. Evaluasi Dataset Primer

   Evaluasi pada 487 foto dataset primer dan dataset sintetik Kaggle menggunakan metrik tanpa referensi (*no-reference*) karena tidak tersedia *ground truth*. Dua metrik yang digunakan adalah sebagai berikut.

   (a) **BRISQUE** (*Blind/Referenceless Image Spatial Quality Evaluator*)
   Mengukur *naturalness* statistik citra berdasarkan deviasi dari model distribusi piksel citra alami. Nilai BRISQUE yang lebih rendah menandakan kualitas citra yang lebih baik. Implementasi menggunakan `piq.brisque` dari *library* piq versi 0.8.0.

   (b) **Laplacian Variance**
   Mengukur ketajaman (*sharpness*) citra berdasarkan variansi respons operator Laplacian, sebagaimana dirumuskan pada Persamaan (4.17).

$$\mathrm{LapVar}(I) = \mathrm{Var}\Big(\nabla^2 I\Big), \tag{4.17}$$

   dengan ∇^2 adalah operator Laplacian diskret 3×3. Nilai yang lebih tinggi menandakan citra yang lebih tajam.

Evaluasi dilakukan pada setiap gambar secara individual sebelum dan sesudah *deraining*, kemudian dirata-ratakan. Model yang digunakan adalah RCDNet-FH v2 yang dilatih pada dataset Rain100H.

Sebagai ilustrasi perhitungan Laplacian Variance, dimisalkan *patch* citra berukuran 3×3 (satu *channel*) beserta kernel Laplacian K sebagai berikut:

$$I = \begin{pmatrix} 100 & 120 & 110 \\ 130 & 200 & 140 \\ 105 & 115 & 108 \end{pmatrix}, \quad K = \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}.$$

Respons Laplacian pada piksel pusat:

$$(\nabla^2 I)_{1,1} = 120 + 130 + 140 + 115 - 4 \times 200 = 505 - 800 = -295.$$

Nilai absolut yang besar menandakan tepi (*edge*) yang tajam. Variansi dari seluruh respons Laplacian pada semua piksel menjadi nilai Laplacian Variance; semakin banyak tepi yang tajam pada citra, semakin besar variansinya.

4.1.6 Perancangan Pengujian

Model hasil pelatihan diuji performansinya terhadap tiga jenis dataset uji sesuai dengan skenario berikut.

1. **Skenario Pengujian pada Dataset Sintetik Rain100L dan Rain100H**
   Setiap model yang dilatih diuji pada 100 citra uji dari dataset yang bersesuaian: model yang dilatih pada Rain100L diuji pada data uji Rain100L, dan model yang dilatih pada Rain100H diuji pada data uji Rain100H. Pengujian ini melibatkan keempat model (FH v1 Rain100L, FH v1 Rain100H, FH v2 Rain100L, FH v2 Rain100H) dan bertujuan untuk membandingkan performa FH v1 dan FH v2 secara langsung menggunakan metrik PSNR dan SSIM.
2. **Skenario Pengujian Generalisasi pada Dataset Sintetik**
   Model RCDNet-FH v2 Rain100H diuji pada dataset sintetik dari Kaggle sebagai uji generalisasi terhadap distribusi data hujan yang berbeda dari data pelatihan. Evaluasi dilakukan menggunakan metrik PSNR dan SSIM.
3. **Skenario Pengujian pada Dataset Primer (487 Foto)**
   Model RCDNet-FH v2 Rain100H diuji pada 487 foto dataset primer dunia nyata yang diambil langsung oleh penulis. Pengujian ini bertujuan untuk mengukur kemampuan generalisasi model pada kondisi hujan nyata. Keluarannya berupa citra hasil *deraining* yang dievaluasi menggunakan BRISQUE dan Laplacian Variance secara kuantitatif, serta inspeksi visual perbandingan citra sebelum dan sesudah *deraining* secara kualitatif.

Dengan seluruh rancangan skenario pelatihan, evaluasi, dan pengujian yang telah ditetapkan pada subbab ini, subbab berikutnya membahas implementasi program dari rancangan tersebut, meliputi implementasi arsitektur model, prosedur pelatihan, serta evaluasi pada dataset sintetik dan dataset primer.

4.2 Implementasi

Pada subbab ini dijelaskan implementasi program untuk proses pelatihan, evaluasi, dan pengujian model berdasarkan rancangan yang telah dibuat pada Subbab *Perancangan Sistem*. Seluruh implementasi ditulis menggunakan bahasa

pemrograman Python dengan *framework* PyTorch. Implementasi mencakup arsitektur model (termasuk modul *FrequencyHint* v2), prosedur pelatihan per *epoch*, evaluasi pada dataset sintetik menggunakan metrik *full-reference*, serta evaluasi pada dataset primer menggunakan metrik *no-reference*.

4.2.1 Ruang Lingkup Perangkat Lunak

Ruang lingkup perangkat lunak adalah perangkat-perangkat yang digunakan pada penelitian ini untuk membantu proses pelatihan model hingga pengujian. Seluruh implementasi dikembangkan menggunakan bahasa Python 3.13 dengan *framework* PyTorch 2.6.0 dan dijalankan secara lokal menggunakan GPU NVIDIA GeForce RTX 4090. Rincian spesifikasi perangkat keras yang digunakan disajikan pada Tabel 4.10.

Tabel 4.10 Spesifikasi Perangkat yang Digunakan

Komponen	**Spesifikasi**
Sistem Operasi	Windows 11
GPU	NVIDIA GeForce RTX 4090 (24 GB VRAM)
CUDA	13.2
Python	3.13
PyTorch	2.6.0+cu124
Framework	RCDNet_simple (H. Wang, Xie, & Zhao, 2020)

Kebutuhan *library* Python yang digunakan selama proses pelatihan dan evaluasi model disajikan pada Tabel 4.11.

Tabel 4.11 Kebutuhan *Library* Python yang Digunakan

Kategori	**Nama *Library***	**Tujuan**
Deep learning & komputasi	PyTorch 2.6.0+cu124	*Framework* utama pelatihan dan inferensi
	CUDA 13.2 + cuDNN	Akselerasi GPU
	NumPy	Operasi array dan matriks
Pengolahan citra	OpenCV (cv2)	Baca/tulis gambar, konversi BGR↔RGB↔YCbCr
	Pillow (PIL)	*Preprocessing* gambar
Evaluasi	scikit-image	PSNR dan SSIM (channel Y YCbCr)
	piq 0.8.0	BRISQUE (*no-reference metric*)
Visualisasi	Matplotlib	Grafik dan visualisasi hasil
	TensorBoard	Pemantauan *training loss*
Pengembangan	Visual Studio Code	IDE utama
	PowerShell	Eksekusi perintah pelatihan dan pengujian
	Virtual environment (venv)	Isolasi dependensi

Dengan ruang lingkup perangkat lunak yang telah ditetapkan tersebut, subbab berikutnya membahas perancangan proses pelatihan model, meliputi varian model yang dilatih, dataset yang digunakan, serta konfigurasi *hyperparameter* yang diterapkan.

4.2.2 Implementasi Arsitektur Model

Kelas utama `RCDNet` beserta seluruh sub-modulnya diimplementasikan dalam berkas `rcdnet.py`. Modul FH v2 diinstansiasi sebagai `self.freq_hint = FrequencyHint(channels=32, reduction=4)` pada setiap Mnet dan dipanggil dalam *forward pass* setelah loop ResBlock selesai.

```
class FrequencyHint(nn.Module):
    def __init__(self, channels, reduction=4):
        super(FrequencyHint, self).__init__()
        mid = max(channels // reduction, 8)

        self.spectral_gate = nn.Sequential(
            nn.Conv2d(channels, mid, kernel_size=1, bias=
    False),
            nn.BatchNorm2d(mid),
            nn.ReLU(inplace=True),
            nn.Conv2d(mid, mid, kernel_size=1, bias=False),
            nn.BatchNorm2d(mid),
            nn.ReLU(inplace=True),
            nn.Conv2d(mid, channels, kernel_size=1, bias=
    False),
            nn.Sigmoid()
        )
        self.proj = nn.Conv2d(channels, channels,
                              kernel_size=1, bias=False)
        nn.init.zeros_(self.proj.weight)

    def forward(self, x):
        B, C, H, W = x.shape
        x_fft = torch.fft.rfft2(x, norm='ortho')
        magnitude = torch.abs(x_fft)
        gate = self.spectral_gate(magnitude)
        x_fft_gated = x_fft * gate
        x_freq = torch.fft.irfft2(x_fft_gated,
                                  s=(H, W), norm='ortho')
        return x + self.proj(x_freq)
```

Kode Program IV.1 Implementasi `FrequencyHint` v2 dalam `rcdnet.py`

Kode Program IV.1 mengimplementasikan modul `FrequencyHint` v2 sebagai subkelas `nn.Module`. Pada konstruktor, variabel `mid` menentukan ukuran *bottleneck* sebesar $\lfloor \texttt{channels}/\texttt{reduction} \rfloor$ dengan batas bawah 8. Komponen `spectral_gate` terdiri atas tiga lapisan `Conv2d` berukuran 1×1 yang diapit `BatchNorm2d` dan `ReLU`, diakhiri `Sigmoid` sehingga menghasilkan bobot *gate* bernilai $[0, 1]$. Layer proyeksi `proj` diinisialisasi dengan bobot nol agar pada awal pelatihan modul ini bertindak sebagai identitas (*residual learning*).

Pada metode `forward`, masukan x ditransformasi ke domain frekuensi menggunakan `torch.fft.rfft2` dengan normalisasi *ortho*. Besaran spektrum (`magnitude`) dihitung menggunakan `torch.abs`, kemudian diumpankan ke `spectral_gate` untuk memperoleh bobot perhatian per kanal di domain frekuensi. Spektrum hasil *gating*

(`x_fft_gated`) dikembalikan ke domain spasial melalui `irfft2`, lalu diproyeksikan dan ditambahkan ke masukan asli sebagai koneksi residual, sehingga informasi frekuensi memperkaya representasi spasial tanpa merusak sinyal awal.

4.2.3 Implementasi Pelatihan

Prosedur pelatihan diimplementasikan dalam berkas `train_main_syn.py`. Tahapan pelatihan meliputi inisialisasi model, *optimizer*, dan penjadwal *learning rate*, dilanjutkan dengan loop pelatihan per *epoch*.

```
netDerain = RCDNet(opt).cuda()
optimizerDerain = optim.Adam(netDerain.parameters(), lr=opt.
   lr)
schedulerDerain = optim.lr_scheduler.MultiStepLR(
    optimizerDerain,
    milestones=opt.milestone,  # [25, 50, 75]
    gamma=0.2
)
```

Kode Program IV.2 Inisialisasi optimizer dan penjadwal LR dalam `train_main_syn.py`

Kode Program IV.2 menampilkan inisialisasi model, *optimizer*, dan penjadwal *learning rate*. Model `RCDNet` diinstansiasi dengan konfigurasi `opt` dan dipindahkan ke GPU menggunakan `.cuda()`. *Optimizer* Adam dipilih dengan *learning rate* awal sesuai `opt.lr`. Penjadwal `MultiStepLR` menurunkan *learning rate* dengan faktor $\gamma = 0{,}2$ pada setiap *epoch* yang tercantum dalam `opt.milestone` (epoch ke-25, 50, dan 75), sehingga *learning rate* berkurang menjadi 20% dari nilai sebelumnya di setiap *milestone* untuk menstabilkan konvergensi pada tahap akhir pelatihan.

Pada setiap iterasi pelatihan, dilakukan *forward pass*, perhitungan *multi-stage supervision loss*, *backpropagation*, dan pembaruan parameter. Implementasi *loss* disajikan pada Kode Program IV.3.

```
B0, ListB, ListR = net(im_rain)

loss_Bs = 0
loss_Rs = 0
for j in range(opt.S):
    loss_Bs += 0.1 * F.mse_loss(ListB[j], im_gt)
    loss_Rs += 0.1 * F.mse_loss(ListR[j], im_rain - im_gt)

lossB = F.mse_loss(ListB[-1], im_gt)
lossR = 0.9 * F.mse_loss(ListR[-1], im_rain - im_gt)
lossB0 = 0.1 * F.mse_loss(B0, im_gt)

loss = lossB0 + loss_Bs + lossB + loss_Rs + lossR
loss.backward()
```

Kode Program IV.3 Implementasi *multi-stage supervision loss* dalam `train_main_syn.py`

Kode Program IV.3 mengimplementasikan perhitungan *multi-stage supervision loss*. *Forward pass* menghasilkan estimasi latar awal `B0`, daftar estimasi latar

belakang `ListB`, dan daftar estimasi lapisan hujan `ListR` untuk setiap tahap $s \in \{1, \ldots, S\}$. Komponen `loss_Bs` dan `loss_Rs` menjumlahkan *loss* MSE seluruh tahap *intermediate* dengan bobot 0,1 sebagai supervisi bertahap yang membantu kestabilan pelatihan. Komponen `lossB` dan `lossR` menghitung *loss* MSE untuk keluaran tahap akhir (`ListB[-1]` dan `ListR[-1]`) dengan bobot berturut-turut 1,0 dan 0,9. Komponen `lossB0` memberikan supervisi tambahan pada estimasi awal `B0` dengan bobot 0,1. *Loss* total merupakan penjumlahan seluruh komponen tersebut, kemudian `loss.backward()` menghitung gradien melalui *backpropagation* untuk memperbarui seluruh parameter model.

Pada setiap 300 iterasi, nilai *loss* saat ini dicatat ke TensorBoardX melalui `writer.add_scalar` untuk pemantauan pelatihan secara *real-time*. Di akhir setiap *epoch*, model disimpan dalam dua format, yaitu berkas metadata *epoch* (`model_{epoch}`) dan berkas *state dict* PyTorch (`DerainNet_state_{epoch}.pt`).

4.2.4 Implementasi Evaluasi Dataset Sintetik

Evaluasi kuantitatif pada dataset sintetik diimplementasikan dalam berkas `evaluate_ycbcr.py`. Citra diproses secara penuh tanpa *patching*, kemudian PSNR dan SSIM dihitung pada channel Y dari ruang warna YCbCr. Konversi ke YCbCr menggunakan `cv2.COLOR_BGR2YCrCb`, dan metrik dihitung dengan fungsi `peak_signal_noise_ratio` dan `structural_similarity` dari *library* scikit-image dengan `data_range=255`.

```
# Konversi ke YCbCr dan ambil channel Y
pred_ycbcr = cv2.cvtColor(pred_bgr, cv2.COLOR_BGR2YCrCb)
gt_ycbcr = cv2.cvtColor(gt_bgr, cv2.COLOR_BGR2YCrCb)
pred_y = pred_ycbcr[:, :, 0].astype(np.float64)
gt_y = gt_ycbcr[:, :, 0].astype(np.float64)

# Hitung metrik
psnr_val = peak_signal_noise_ratio(gt_y, pred_y, data_range
    =255)
ssim_val = structural_similarity(gt_y, pred_y, data_range
    =255)
```

Kode Program IV.4 Inti implementasi evaluasi PSNR dan SSIM dalam `evaluate_ycbcr.py`

Kode Program IV.4 menampilkan inti perhitungan metrik evaluasi. Citra prediksi dan citra *ground truth* dikonversi dari ruang warna BGR ke YCbCr menggunakan `cv2.cvtColor`. Channel Y (*luminance*) diekstrak melalui pengindeksan `[:, :, 0]` karena channel ini paling sensitif terhadap perubahan kualitas visual dan lazim digunakan sebagai basis evaluasi pada tugas *image restoration*. Konversi ke tipe `float64` dilakukan untuk menjaga presisi numerik pada perhitungan metrik. Nilai PSNR dihitung menggunakan fungsi `peak_signal_noise_ratio` dengan `data_range=255` sesuai skala citra 8-bit, sedangkan nilai SSIM dihitung menggunakan `structural_similarity` untuk mengukur kemiripan struktural antara citra prediksi dan citra *ground truth*.

4.2.5 Implementasi Evaluasi Dataset Primer

Evaluasi pada dataset primer digunakan untuk menilai kualitas hasil *deraining* pada 487 citra primer yang diproses menggunakan model RCDNet-FH v2 hasil pelatihan pada dataset Rain100H. Karena dataset primer tidak memiliki pasangan *ground truth*, evaluasi dilakukan menggunakan metrik *no-reference image quality assessment*, yaitu BRISQUE (*Blind/Referenceless Image Spatial Quality Evaluator*) dan Laplacian Variance.

```
def calc_brisque(img_bgr):
    img_rgb = cv2.cvtColor(img_bgr, cv2.COLOR_BGR2RGB)
    img_tensor = torch.tensor(img_rgb).permute(2, 0, 1)
    img_tensor = img_tensor.unsqueeze(0).float() / 255.0
    score = piq.brisque(img_tensor)
    return score.item()


def laplacian_variance(img_bgr):
    gray = cv2.cvtColor(img_bgr, cv2.COLOR_BGR2GRAY)
    return cv2.Laplacian(gray, cv2.CV_64F).var()
```

Kode Program IV.5 Implementasi perhitungan BRISQUE dan Laplacian Variance

Pada fungsi `calc_brisque()`, citra masukan yang semula berada dalam format BGR terlebih dahulu dikonversi ke format RGB agar sesuai dengan format masukan yang digunakan oleh *library* `piq`. Selanjutnya citra diubah menjadi *tensor* dengan susunan dimensi *channel-height-width* (CHW), ditambahkan dimensi *batch*, kemudian dinormalisasi ke rentang nilai $[0, 1]$. *Tensor* yang telah diproses digunakan sebagai masukan fungsi `piq.brisque()` untuk memperoleh nilai BRISQUE. Nilai BRISQUE yang lebih rendah menandakan kualitas citra yang lebih baik.

Fungsi `laplacian_variance()` mengubah citra menjadi citra keabuan sebelum menerapkan operator Laplacian menggunakan fungsi `cv2.Laplacian()`. Nilai Laplacian Variance dihitung berdasarkan variansi hasil operator Laplacian sebagaimana dirumuskan pada Persamaan (4.18).

$$\mathrm{LapVar}(I) = \mathrm{Var}\Big(\nabla^2 I\Big), \tag{4.18}$$

dengan ∇^2 menyatakan operator Laplacian diskret dan $\mathrm{Var}(\cdot)$ menyatakan variansi. Pada implementasinya, variansi tersebut dihitung menggunakan fungsi `var()` pada hasil `cv2.Laplacian()`. Nilai variansi yang lebih besar menunjukkan bahwa citra memiliki tingkat ketajaman (*sharpness*) yang lebih tinggi.

Setelah kedua fungsi metrik didefinisikan, program melakukan evaluasi terhadap seluruh pasangan citra masukan dan citra hasil *deraining*, sebagaimana ditunjukkan pada Kode Program IV.6.

```
for fname in files:
    img_in = cv2.imread(os.path.join(INPUT_DIR, fname))
    img_out = cv2.imread(os.path.join(OUTPUT_DIR, fname))

    input_brisque.append(calc_brisque(img_in))
    output_brisque.append(calc_brisque(img_out))
```

```
7
8       input_lap.append(laplacian_variance(img_in))
9       output_lap.append(laplacian_variance(img_out))
10
11  avg_in_b = np.mean(input_brisque)
12  avg_out_b = np.mean(output_brisque)
13
14  avg_in_l = np.mean(input_lap)
15  avg_out_l = np.mean(output_lap)
```

Kode Program IV.6 Implementasi evaluasi dataset primer

Kode Program IV.6 menunjukkan proses evaluasi terhadap seluruh citra pada dataset primer. Program membaca setiap pasangan citra masukan dan citra hasil *deraining* menggunakan fungsi `cv2.imread()`, kemudian menghitung nilai BRISQUE dan Laplacian Variance menggunakan fungsi `calc_brisque()` dan `laplacian_variance()` yang telah didefinisikan sebelumnya. Nilai yang diperoleh dari setiap citra disimpan ke dalam daftar (*list*) sesuai metrik yang digunakan, yaitu `input_brisque`, `output_brisque`, `input_lap`, dan `output_lap`. Setelah seluruh citra selesai diproses, fungsi `np.mean()` digunakan untuk menghitung nilai rata-rata BRISQUE dan Laplacian Variance pada citra masukan maupun citra hasil *deraining*, sehingga diperoleh perbandingan kualitas citra sebelum dan sesudah proses *deraining* secara kuantitatif.

BAB V
HASIL DAN PEMBAHASAN

Pada bab ini dijelaskan mengenai hasil dari penelitian sesuai dengan perancangan dan implementasi program pada bab sebelumnya. Hasil yang diperoleh selanjutnya dianalisa secara rinci sehingga dapat memberikan kesimpulan penelitian yang sesuai dengan tujuan penelitian. Pembahasan hasil penelitian antara lain hasil pelatihan dan evaluasi model, analisa model terbaik berdasarkan skenario pelatihan, dan hasil pengujian sesuai skenario yang telah ditentukan.

5.1 Hasil Pelatihan dan Evaluasi Model

Pada subbab ini membahas hasil pelatihan dan evaluasi model yang menggunakan data latih dan data uji yang telah ditentukan. Analisa hasil pelatihan dan evaluasi model dibagi menjadi dua skenario yakni skenario menggunakan RCDNet-FH v1 dan skenario menggunakan RCDNet-FH v2.

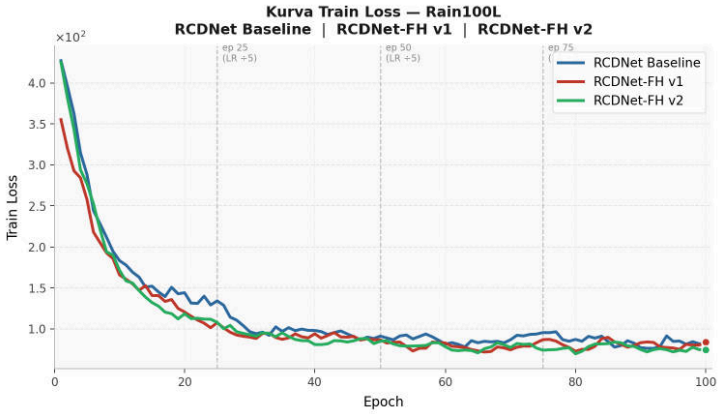
5.1.1 Hasil Pelatihan Skenario 1: RCDNet-FH v1

Tahap pertama eksperimen dilakukan dengan melatih ulang model RCDNet *Baseline* pada dataset Rain100L dan Rain100H selama 100 *epoch* dengan jumlah *stage* $S = 17$, dan hasilnya digunakan sebagai acuan pembanding bagi varian RCDNet-FH v1 pada skenario pertama. Tabel Tabel 5.1 menyajikan hasil evaluasi PSNR dan SSIM pada channel Y dari ruang warna YCbCr. Hasil reproduksi ini menunjukkan selisih terhadap nilai yang dilaporkan pada *paper* asli, yaitu 39,73 dB untuk Rain100L dan 31,28 dB untuk Rain100H, yang disebabkan oleh perbedaan versi *framework*, jumlah data latih, dan prosedur evaluasi yang digunakan. Meskipun demikian, karena seluruh kondisi implementasi pada penelitian ini bersifat identik untuk setiap varian model yang dibandingkan, perbandingan performa secara relatif antar model tetap dapat dipertanggungjawabkan.

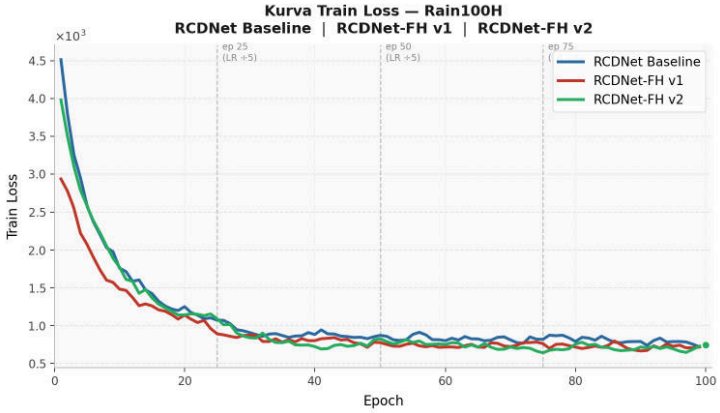
Tabel 5.1 Hasil Evaluasi Model RCDNet *Baseline* (channel Y, YCbCr)

Dataset	**PSNR (dB)**	**SSIM**
Rain100L	38,9044	0,9854
Rain100H	29,5389	0,9021

Untuk melihat bagaimana proses pelatihan berlangsung, Gambar 5.1 dan Gambar 5.2 menampilkan kurva *train loss* per-*epoch* dari model *Baseline* pada Rain100L dan Rain100H. Pada kedua kurva tersebut, penurunan *loss* terlihat jelas pada *epoch* ke-25, 50, dan 75, sesuai dengan *milestone* penjadwalan *learning rate* yang diterapkan selama pelatihan. Secara keseluruhan, *loss* menurun secara stabil tanpa lonjakan berarti hingga *epoch* ke-100 pada kedua dataset, yang menandakan bahwa proses pelatihan *baseline* berjalan dengan baik dan dapat dijadikan acuan yang andal.



Gambar 5.1 Kurva *train loss* per-*epoch* model RCDNet *Baseline* pada dataset Rain100L.



Gambar 5.2 Kurva *train loss* per-*epoch* model RCDNet *Baseline* pada dataset Rain100H.

Pada skenario pertama, model RCDNet-FH v1 kemudian dilatih dengan menambahkan modul *FrequencyHint* sederhana berupa *spectral gate* dua lapis konvolusi pada Mnet. Hasil evaluasi menunjukkan bahwa RCDNet-FH v1 meningkatkan PSNR menjadi 39,1711 dB pada Rain100L dan SSIM menjadi 30,0052 dB pada Rain100H, sehingga menunjukkan bahwa penambahan informasi frekuensi sudah memberikan peningkatan dibandingkan model *Baseline*. Hasil RCDNet-FH v1 ini menjadi pembanding langsung bagi skenario kedua yang menggunakan RCDNet-FH v2.

5.1.2 Hasil Pelatihan Skenario 2: RCDNet-FH v2

Setelah skenario pertama menghasilkan peningkatan melalui integrasi *FrequencyHint* pada RCDNet-FH v1, skenario kedua difokuskan pada evaluasi RCDNet-FH v2 yang menggunakan arsitektur *bottleneck* tiga lapis konvolusi. Seluruh evaluasi dilakukan menggunakan metrik PSNR dan SSIM pada channel Y (YCbCr) agar konsisten dengan penelitian terdahulu. Selain mengevaluasi peningkatan performa terhadap model *Baseline*, skenario ini juga mencakup studi ablasi jumlah *stage* serta pengujian kemampuan generalisasi menggunakan dataset campuran.

Eksperimen Utama

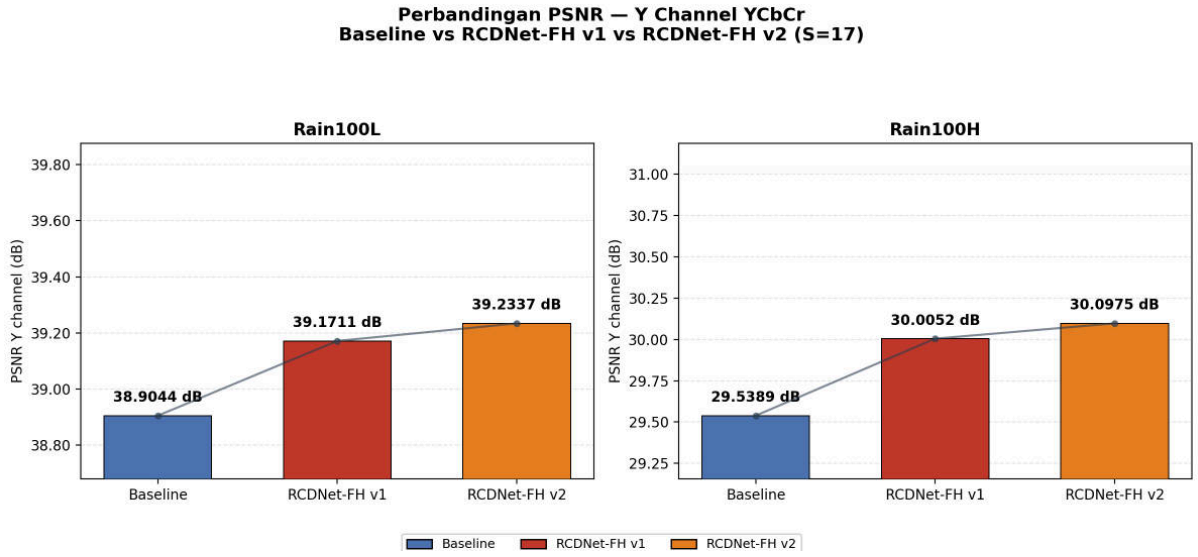
Tabel Tabel 5.2 menyajikan hasil evaluasi kuantitatif terhadap RCDNet *Baseline*, RCDNet-FH v1, dan RCDNet-FH v2 pada dataset Rain100L dan Rain100H. Performa masing-masing model dianalisis berdasarkan nilai PSNR dan SSIM sebagai indikator kualitas citra hasil restorasi. Berdasarkan hasil pengujian tersebut, RCDNet-FH v2 memperoleh nilai evaluasi tertinggi pada kedua dataset.

Tabel 5.2 Eksperimen Utama ($S = 17$)

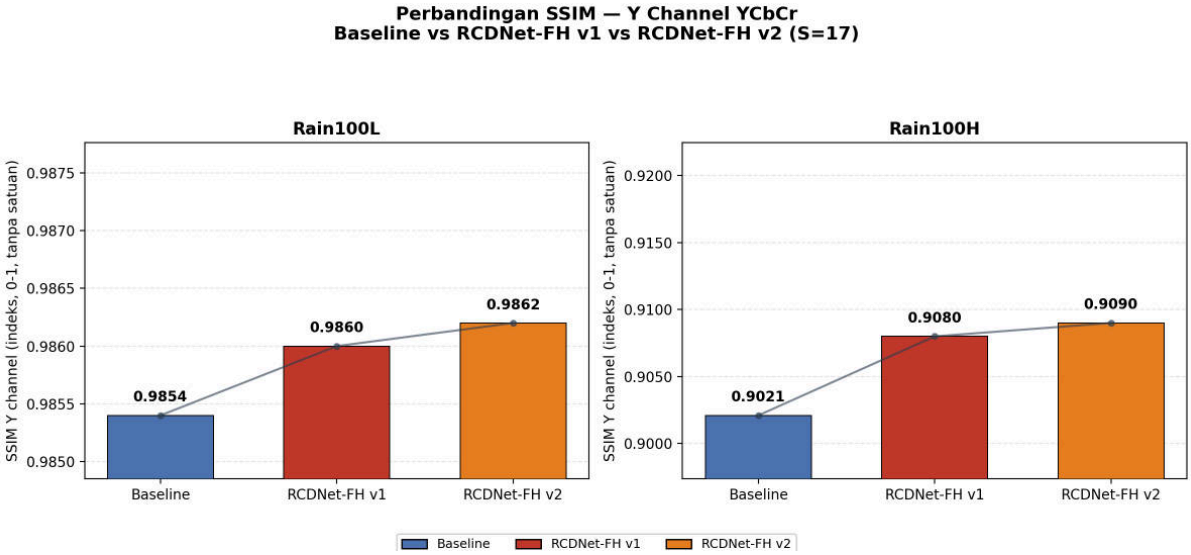
Model	PSNR L (dB)	SSIM L	PSNR H (dB)	SSIM H
Baseline	38,9044	0,9854	29,5389	0,9021
RCDNet-FH v1	39,1711	0,9860	30,0052	0,9080
RCDNet-FH v2	**39,2337**	**0,9862**	**30,0975**	**0,9090**

Berdasarkan Tabel 5.2, integrasi FrequencyHint v2 mampu meningkatkan kualitas hasil *deraining* secara konsisten dibandingkan model *Baseline*. Pada dataset Rain100L diperoleh peningkatan sebesar $+0,3293$ dB, sedangkan pada Rain100H peningkatan mencapai $+0,5586$ dB. Selain menghasilkan PSNR tertinggi, RCDNet-FH v2 juga memperoleh nilai SSIM tertinggi pada kedua dataset. Peningkatan yang lebih besar pada Rain100H menunjukkan bahwa informasi frekuensi yang diberikan oleh FrequencyHint v2 lebih efektif ketika citra mengandung hujan dengan tingkat kepadatan yang lebih tinggi.

Untuk memperjelas tren tersebut, Gambar 5.3 dan Gambar 5.4 menyajikan visualisasi perbandingan PSNR dan SSIM ketiga model.

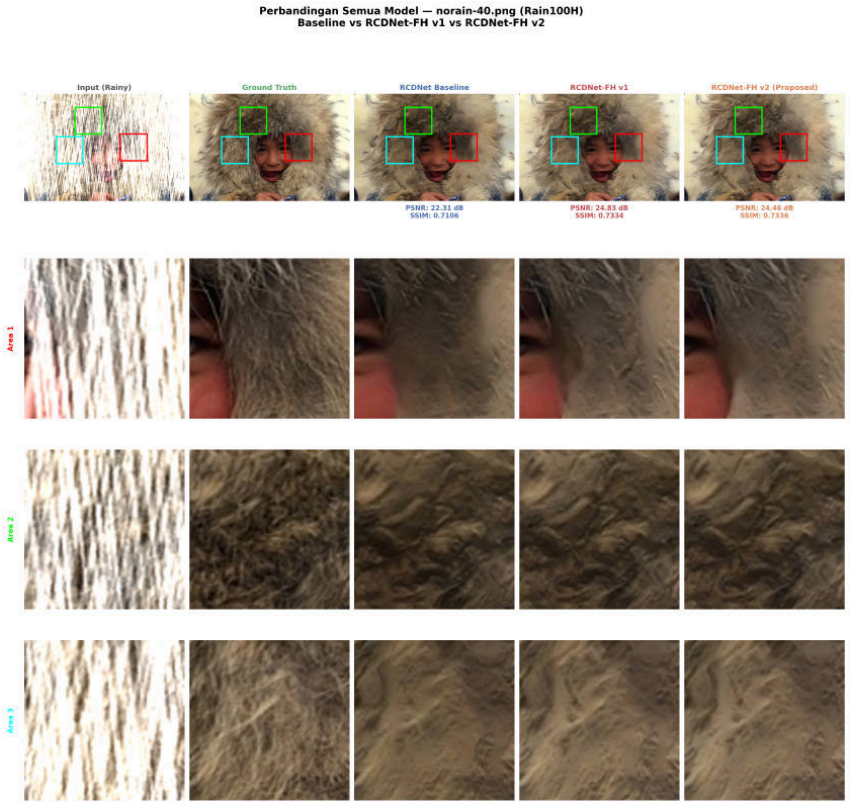


Gambar 5.3 Perbandingan nilai PSNR.



Gambar 5.4 Perbandingan nilai SSIM.

Selain evaluasi kuantitatif, kualitas visual hasil *deraining* dibandingkan menggunakan sampel Rain100H pada Gambar 5.5. Secara visual, RCDNet-FH v2 menghasilkan citra yang lebih bersih dengan detail latar belakang yang lebih terjaga dibandingkan *Baseline* maupun FH v1.



Gambar 5.5 Perbandingan hasil *deraining* pada sampel Rain100H (*norain-40*).

Analisis lebih rinci ditunjukkan pada Gambar 5.5. Pada area yang diperbesar

(*close-up*), RCDNet-FH v2 mampu mempertahankan detail tepi dan tekstur objek dengan lebih baik, sehingga peningkatan nilai PSNR dan SSIM juga tercermin pada kualitas visual citra.

Studi Ablasi Jumlah *Stage*

Selain mengevaluasi arsitektur FrequencyHint v2, dilakukan pula studi ablasi terhadap jumlah *stage* ($S = \{10, 15, 17, 20\}$). Tujuannya adalah untuk mengetahui pengaruh kedalaman iterasi *proximal gradient descent* terhadap performa model dan waktu pelatihan.

Tabel 5.3 Hasil *Ablation Study* terhadap Jumlah *Stage* (S) pada RCDNet-FH v2

Model	S	**PSNR L (dB)**	**SSIM L**	**PSNR H (dB)**	**SSIM H**	**Waktu/Epoch**
Baseline	17	38,9044	0,9854	29,5389	0,9021	≈230 detik
FH v2	10	38,9994	0,9854	29,7151	0,9032	≈152 detik
FH v2	15	39,1251	0,9859	29,9665	0,9069	≈210 detik
FH v2	**17**	**39,2337**	**0,9862**	**30,0975**	**0,9090**	**≈230 detik**
FH v2	20	39,2432	0,9862	30,2301	0,9113	≈250 detik

Berdasarkan hasil pada Tabel 5.3, peningkatan jumlah *stage* menghasilkan kenaikan performa yang konsisten. Menariknya, konfigurasi $S = 10$ telah mampu melampaui model *Baseline* dengan waktu pelatihan sekitar 33% lebih cepat. Nilai PSNR terus meningkat hingga mencapai performa terbaik pada $S = 20$, meskipun peningkatannya mulai menunjukkan pola *diminishing returns*. Oleh karena itu, konfigurasi $S = 17$ dipilih sebagai konfigurasi utama karena memberikan keseimbangan terbaik antara performa dan efisiensi komputasi.

Evaluasi Dataset Campuran dan Generalisasi

Untuk mengetahui kemampuan generalisasi model, dilakukan pelatihan menggunakan dataset campuran (Rain100L dan Rain100H) dan dibandingkan dengan model spesialis pada masing-masing dataset. Hasil pengujian ditunjukkan pada Tabel 5.4.

Tabel 5.4 Evaluasi Model pada Dataset Campuran dan Generalisasi

Model	**PSNR L (dB)**	**SSIM L**	**PSNR H (dB)**	**SSIM H**	**Tipe Model**
Baseline	38,9044	0,9854	29,5389	0,9021	Referensi
FH v2 (L)	**39,2337**	**0,9862**	–	–	Spesialis Rain100L
FH v2 (H)	–	–	30,0975	0,9090	Spesialis Rain100H
FH v2 Mixed	38,8634	0,9845	**30,1944**	**0,9100**	Generalis

Hasil menunjukkan bahwa model spesialis tetap menghasilkan performa terbaik pada dataset yang sesuai, sedangkan model FH v2 Mixed mampu mempertahankan performa yang kompetitif pada kedua dataset secara bersamaan. Pada Rain100L diperoleh PSNR sebesar 38,8634 dB dan SSIM 0,9845, sedangkan pada Rain100H diperoleh PSNR sebesar 30,1944 dB dan SSIM 0,9100. Meskipun sedikit

lebih rendah dibandingkan model spesialis pada Rain100L, model campuran justru memberikan performa terbaik pada Rain100H. Temuan ini menunjukkan bahwa RCDNet-FH v2 memiliki kemampuan generalisasi yang baik ketika dilatih menggunakan distribusi data yang lebih beragam sehingga lebih sesuai untuk diaplikasikan pada kondisi nyata yang memiliki karakteristik hujan yang bervariasi.

5.2 Analisis Model Terbaik

Berdasarkan rangkaian hasil pelatihan dan evaluasi sebelumnya, model RCDNet-FH v2 dipilih sebagai konfigurasi utama penelitian karena memberikan peningkatan performa paling konsisten dibandingkan *Baseline* dan FH v1. Meskipun konfigurasi RCDNet-FH v2 dengan $S = 20$ menghasilkan PSNR tertinggi, konfigurasi $S = 17$ tetap digunakan sebagai model utama karena peningkatan dari $S = 17$ ke $S = 20$ relatif kecil dibandingkan tambahan waktu pelatihan yang dibutuhkan. Dengan demikian, RCDNet-FH v2 dengan $S = 17$ digunakan sebagai dasar untuk pengujian generalisasi pada bagian selanjutnya.

5.3 Hasil Pengujian

Model terbaik hasil analisis sebelumnya kemudian diuji pada beberapa skenario untuk melihat kemampuan generalisasi model. Pengujian dilakukan melalui perbandingan model spesialis dan model generalis, evaluasi *zero-shot* pada dataset sintetik tambahan, evaluasi pada data primer tanpa *ground truth*, serta perbandingan dengan hasil yang dilaporkan pada *paper* asli RCDNet.

5.3.1 Hasil Pengujian Skenario 1

Setelah model terbaik diperoleh pada tahap pelatihan, pengujian selanjutnya dilakukan untuk mengevaluasi kemampuan generalisasi model pada data uji yang masih berada pada distribusi yang sama dengan data pelatihannya. Berbeda dengan tahap sebelumnya yang berfokus pada pemilihan arsitektur *FrequencyHint* terbaik, pada skenario ini dilakukan perbandingan antara model spesialis yang dilatih secara terpisah pada dataset Rain100L dan Rain100H dengan model generalis RCDNet-FH v2 *Mixed* yang dilatih menggunakan gabungan kedua dataset tersebut. Pengujian ini bertujuan untuk mengetahui apakah penggunaan data pelatihan yang lebih beragam mampu menghasilkan satu model yang tetap memiliki performa tinggi pada kedua karakteristik hujan tanpa harus melatih model yang berbeda untuk setiap dataset. Seluruh evaluasi dilakukan menggunakan metrik PSNR dan SSIM pada channel Y dari ruang warna YCbCr. Tabel 5.5 menyajikan hasil perbandingan antara model *Baseline*, model spesialis, dan model generalis *Mixed*.

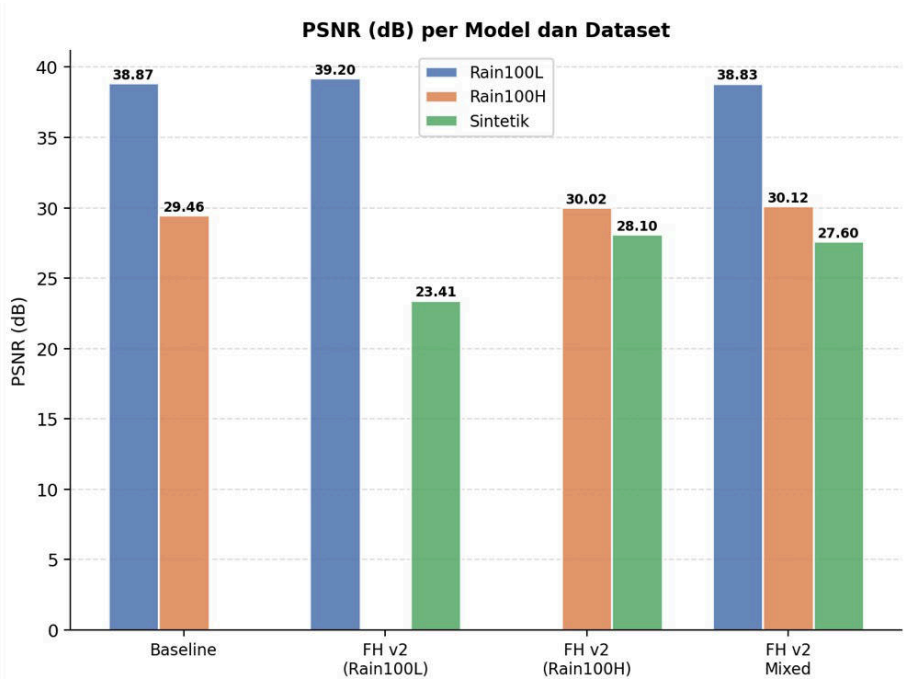
Tabel 5.5 Perbandingan Model Spesialis dan Model Generalis *Mixed* (channel Y, YCbCr)

Model	Data Latih	PSNR L (dB)	SSIM L	PSNR H (dB)
RCDNet *Baseline*	Rain100L	38,9044	0,9854	–
RCDNet *Baseline*	Rain100H	–	–	29,5389
RCDNet-FH v2 (Spesialis L)	Rain100L	**39,2337**	**0,9862**	–
RCDNet-FH v2 (Spesialis H)	Rain100H	–	–	30,0975
RCDNet-FH v2 Mixed	Gabungan Rain100L dan Rain100H	38,8634	0,9845	**30,1944**

Berdasarkan Tabel 5.5, terlihat bahwa model spesialis masih memberikan performa terbaik pada dataset yang sesuai dengan data pelatihannya. Model spesialis Rain100L memperoleh nilai PSNR sebesar 39,2337 dB dengan SSIM 0,9862, sedangkan model spesialis Rain100H memperoleh PSNR sebesar 30,0975 dB. Hasil tersebut menunjukkan bahwa pelatihan secara khusus pada satu jenis distribusi hujan mampu mengoptimalkan performa model pada kondisi yang serupa.

Di sisi lain, model RCDNet-FH v2 *Mixed* menunjukkan kemampuan generalisasi yang sangat baik. Pada dataset Rain100L model ini memperoleh nilai PSNR sebesar 38,8634 dB, hanya sekitar 0,37 dB lebih rendah dibandingkan model spesialis Rain100L. Selisih tersebut relatif kecil sehingga menunjukkan bahwa penggunaan data pelatihan gabungan tidak menyebabkan penurunan performa yang signifikan pada kondisi hujan ringan hingga sedang. Menariknya, pada dataset Rain100H model *Mixed* justru menghasilkan nilai PSNR sebesar 30,1944 dB, sedikit lebih tinggi dibandingkan model spesialis Rain100H. Hasil tersebut mengindikasikan bahwa penggunaan variasi data pelatihan yang lebih beragam membantu model mempelajari karakteristik hujan yang lebih luas sehingga meningkatkan kemampuan generalisasi pada kondisi hujan dengan intensitas tinggi.

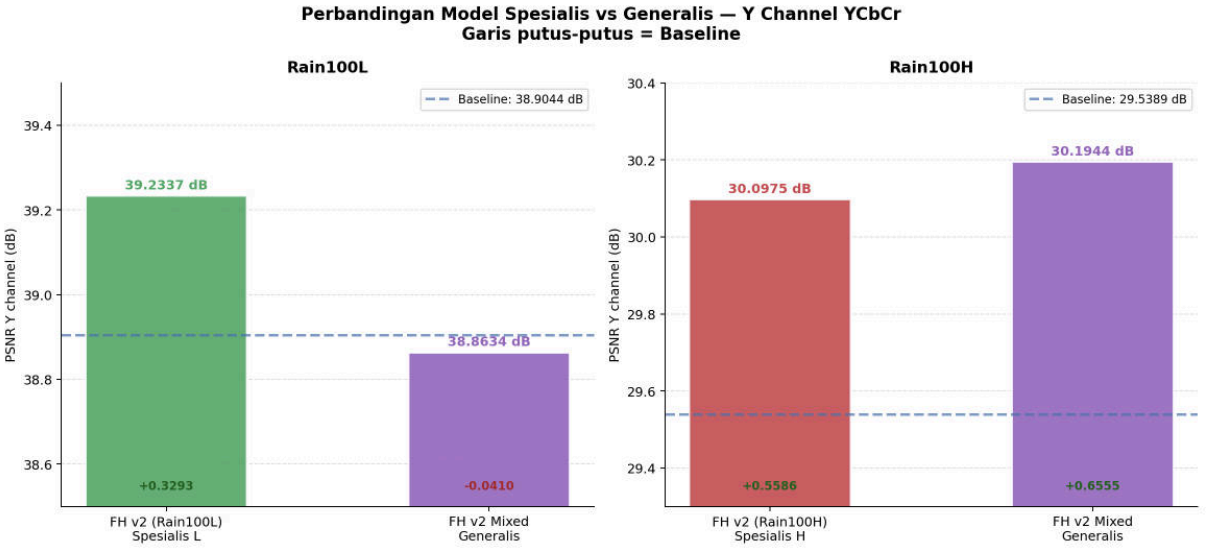
Untuk memperjelas perbandingan performa tersebut, Gambar 5.6 menampilkan nilai PSNR model *Baseline*, model spesialis, dan model *Mixed* pada kedua dataset pengujian.



Gambar 5.6 Perbandingan performa *Baseline*, model spesialis, dan model generalis RCDNet-FH v2 Mixed pada Rain100L dan Rain100H.

Pada Gambar 5.6 memperlihatkan bahwa seluruh model yang menggunakan modul *FrequencyHint* menghasilkan performa yang lebih tinggi dibandingkan model *Baseline*. Pada Rain100L, model spesialis memberikan nilai PSNR tertinggi,

sedangkan pada Rain100H model *Mixed* menjadi model dengan performa terbaik. Pola tersebut menunjukkan bahwa model *Mixed* mampu mempertahankan kualitas rekonstruksi citra pada dua distribusi hujan yang berbeda tanpa mengalami penurunan performa yang berarti. Selanjutnya, Gambar 5.7 memperlihatkan selisih PSNR antara model spesialis dan model *Mixed* secara lebih rinci.



Gambar 5.7 Perbandingan PSNR model spesialis dan model generalis (*Mixed*) pada Rain100L dan Rain100H. Garis putus-putus menunjukkan nilai PSNR *Baseline*.

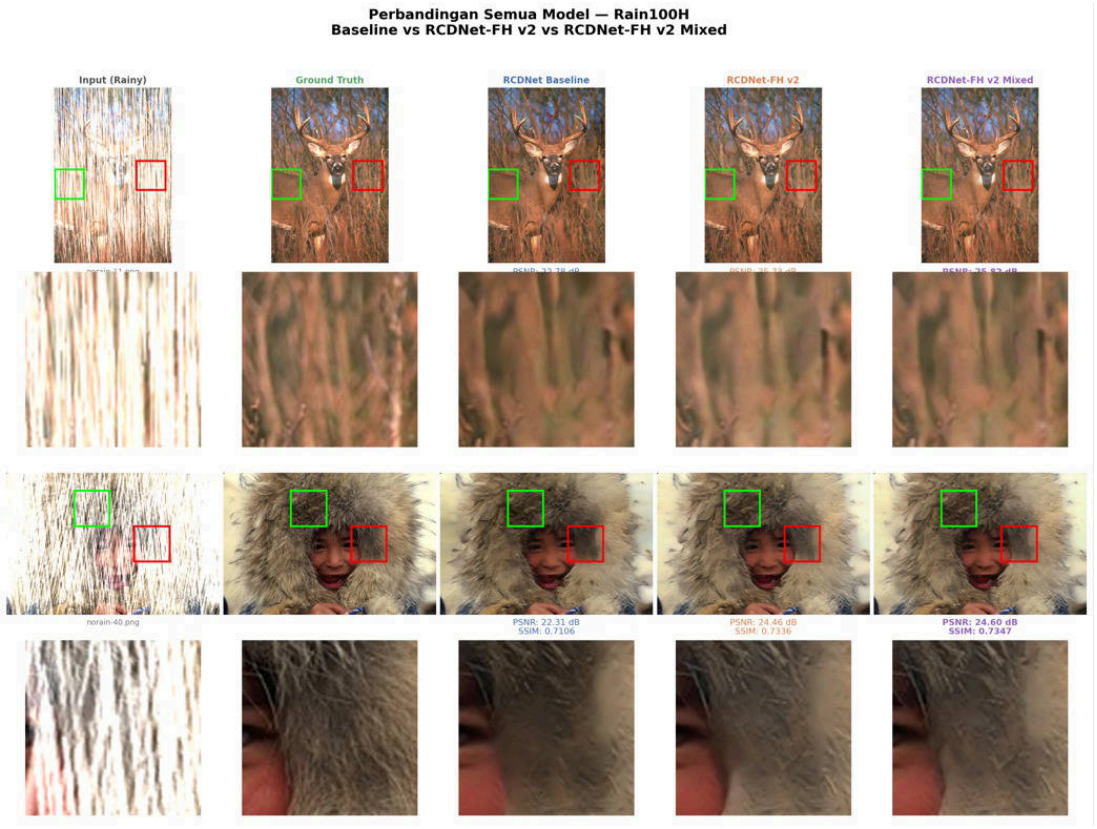
Pada Gambar 5.7 terlihat bahwa selisih performa antara model spesialis dan model *Mixed* pada Rain100L relatif kecil, sedangkan pada Rain100H model *Mixed* sedikit melampaui model spesialis. Temuan ini menunjukkan bahwa penggunaan gabungan data pelatihan mampu meningkatkan kemampuan model dalam mengenali karakteristik hujan yang lebih beragam tanpa mengurangi kualitas hasil pada kondisi hujan lainnya.

Selain melalui evaluasi kuantitatif, kualitas hasil *deraining* juga diamati secara visual menggunakan beberapa sampel citra pada Rain100H dan Rain100L yang ditampilkan pada Gambar 5.8 dan Gambar 5.9.

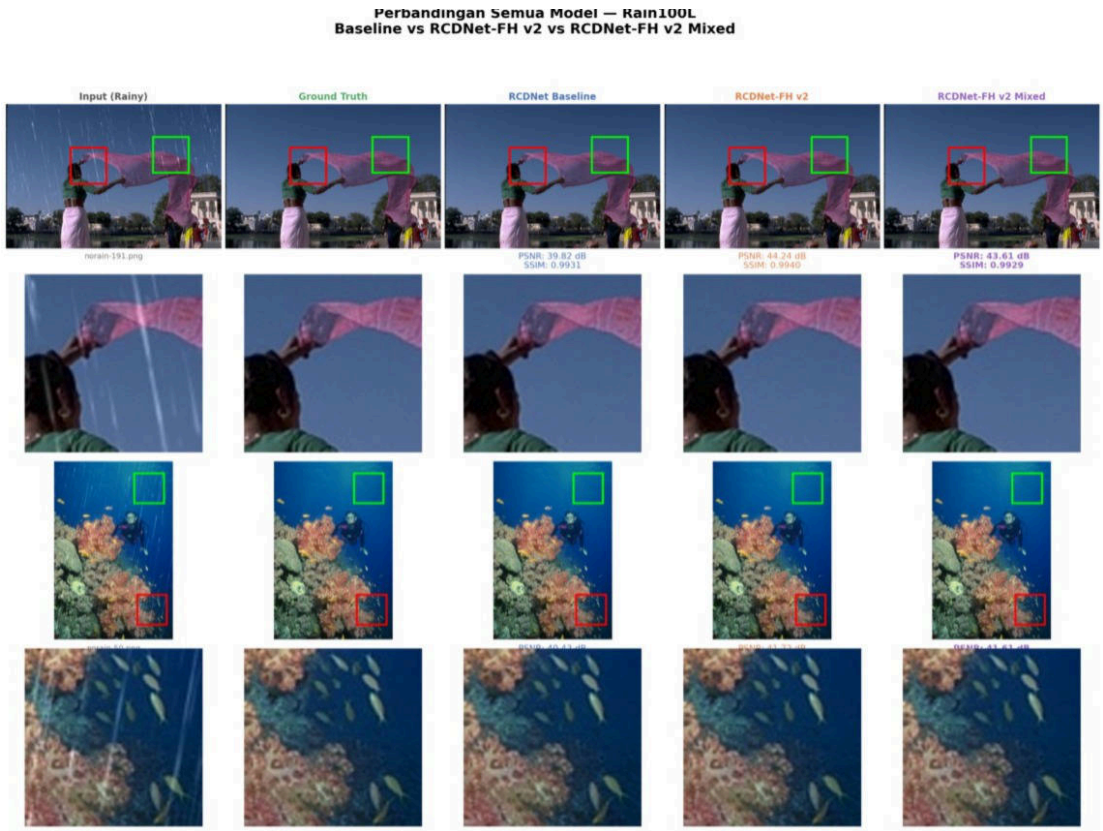
Secara visual, Gambar 5.8 menunjukkan bahwa model RCDNet-FH v2 *Mixed* mampu menghilangkan sebagian besar *rain streak* pada citra Rain100H tanpa menghilangkan struktur utama objek. Detail seperti tepi bangunan, kendaraan, serta vegetasi masih dapat dipertahankan dengan baik sehingga hasil *deraining* tampak lebih alami. Hasil tersebut sejalan dengan peningkatan nilai PSNR yang diperoleh pada pengujian kuantitatif.

Hasil pada Gambar 5.9 memperlihatkan bahwa model *Mixed* juga mampu mereduksi *rain streak* pada dataset Rain100L secara konsisten. Meskipun nilai PSNR sedikit berada di bawah model spesialis Rain100L, secara visual perbedaan kualitas citra yang dihasilkan relatif kecil. Detail tekstur dan tepi objek tetap terjaga sehingga tidak terlihat efek *over-smoothing* yang berlebihan.

Berdasarkan keseluruhan hasil pengujian pada skenario pertama dapat disimpulkan bahwa model RCDNet-FH v2 *Mixed* mampu mempertahankan



Gambar 5.8 Grid sampel hasil *deraining* model RCDNet-FH v2 Mixed pada Rain100H.



Gambar 5.9 Grid sampel hasil *deraining* model RCDNet-FH v2 Mixed pada Rain100L.

performa yang kompetitif pada kedua dataset sekaligus. Meskipun tidak selalu menghasilkan nilai PSNR tertinggi pada setiap dataset, selisih performa terhadap model spesialis relatif kecil, bahkan mampu melampaui model spesialis pada Rain100H. Hasil ini menunjukkan bahwa penggunaan data pelatihan yang lebih beragam dapat meningkatkan kemampuan generalisasi model sehingga lebih sesuai untuk diterapkan pada kondisi hujan yang bervariasi.

5.3.2 Hasil Pengujian Skenario 2

Pengujian skenario kedua dilakukan untuk mengevaluasi kemampuan generalisasi model pada distribusi data yang lebih beragam dibandingkan data pelatihannya. Berbeda dengan skenario pertama yang menggunakan dataset Rain100L dan Rain100H sebagai data uji yang masih berada pada distribusi pelatihan, pada skenario ini model diuji menggunakan dataset sintetik tambahan serta data primer berupa foto hujan nyata yang tidak memiliki pasangan *ground truth*. Pengujian ini bertujuan untuk mengetahui sejauh mana model mampu mempertahankan performanya ketika dihadapkan pada karakteristik hujan yang belum pernah dipelajari sebelumnya.

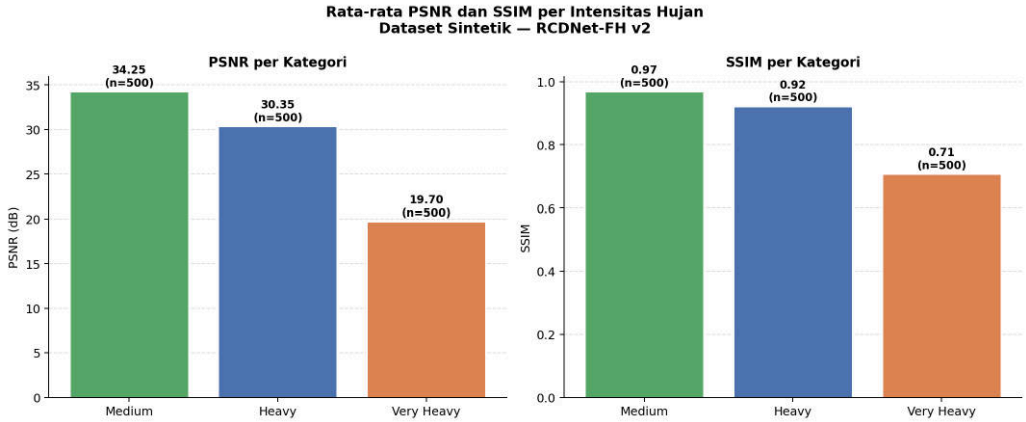
Evaluasi pertama dilakukan menggunakan dataset sintetik tambahan yang terdiri dari 1.500 citra dengan variasi intensitas hujan mulai dari kategori *light*, *medium*, *heavy*, hingga *very heavy*. Pengujian dilakukan secara *zero-shot*, sehingga seluruh citra yang digunakan tidak pernah dilibatkan selama proses pelatihan model. Hasil evaluasi menggunakan metrik PSNR dan SSIM disajikan pada Tabel 5.6.

Tabel 5.6 Hasil Pengujian pada Dataset Sintetik Tambahan (1.500 Gambar)

Model	**Data Latih**	**PSNR (dB)**	**SSIM**
RCDNet-FH v2	Rain100L	23,41	0,7095
RCDNet-FH v2	Rain100H	**28,10**	**0,8657**
RCDNet-FH v2	Mixed L+H	27,60	0,8401

Berdasarkan Tabel 5.6, terlihat bahwa model yang dilatih menggunakan dataset Rain100H memperoleh performa terbaik dengan nilai PSNR sebesar 28,10 dB dan SSIM sebesar 0,8657. Nilai tersebut lebih tinggi sekitar 4,69 dB dibandingkan model yang hanya dilatih menggunakan Rain100L. Hasil ini menunjukkan bahwa proses pelatihan menggunakan dataset dengan karakteristik hujan yang lebih kompleks mampu meningkatkan kemampuan model dalam menghadapi distribusi data yang belum pernah ditemui sebelumnya. Sementara itu, model RCDNet-FH v2 *Mixed* memperoleh nilai PSNR sebesar 27,60 dB dan SSIM sebesar 0,8401. Walaupun sedikit berada di bawah model Rain100H, performa tersebut masih jauh lebih baik dibandingkan model Rain100L. Temuan ini menunjukkan bahwa penggunaan data pelatihan yang lebih beragam mampu menghasilkan model yang memiliki kemampuan generalisasi yang baik pada berbagai karakteristik hujan.

Untuk melihat performa ketiga model pada setiap kategori intensitas hujan secara lebih rinci, Gambar 5.10 menyajikan perubahan nilai PSNR mulai dari kategori *light* hingga *very heavy*.



Gambar 5.10 Perbandingan PSNR per kategori intensitas hujan pada dataset sintetik tambahan untuk model yang dilatih pada Rain100L, Rain100H, dan Mixed.

Pada Gambar 5.10 menunjukkan bahwa model yang dilatih menggunakan Rain100L menghasilkan performa yang cukup baik pada kategori hujan ringan hingga sedang, namun mengalami penurunan PSNR yang cukup tajam ketika intensitas hujan meningkat menuju kategori *heavy* dan *very heavy*. Hal ini menunjukkan bahwa model memiliki keterbatasan ketika dihadapkan pada distribusi hujan yang lebih kompleks dibandingkan data pelatihannya. Sebaliknya, model Rain100H mempertahankan nilai PSNR yang relatif stabil pada seluruh kategori intensitas hujan. Model *Mixed* juga memperlihatkan pola yang serupa meskipun sedikit berada di bawah model Rain100H. Temuan ini mengindikasikan bahwa pelatihan menggunakan data dengan tingkat kompleksitas hujan yang lebih tinggi memberikan kemampuan generalisasi yang lebih baik terhadap variasi kondisi hujan.

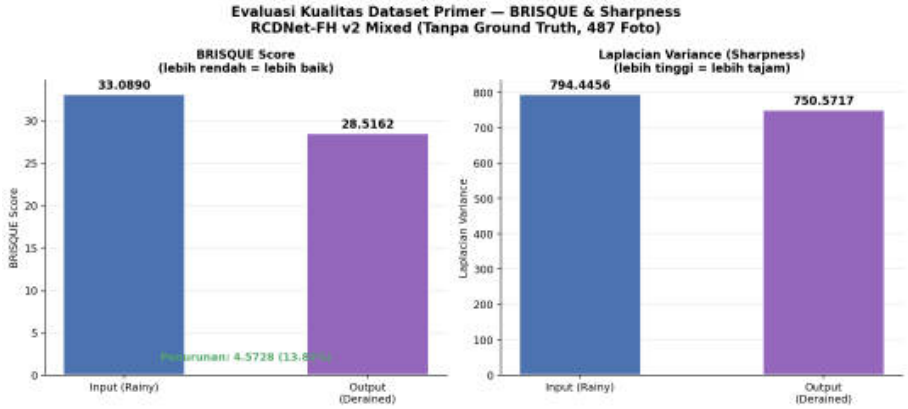
Setelah dievaluasi pada dataset sintetik tambahan, pengujian dilanjutkan menggunakan data primer berupa 487 foto hujan nyata yang diperoleh melalui proses pengambilan gambar secara langsung. Berbeda dengan dataset sintetik, data primer tidak memiliki pasangan *ground truth*, sehingga evaluasi dilakukan menggunakan metrik *no-reference*, yaitu BRISQUE dan Laplacian Variance. Model yang digunakan pada tahap ini adalah RCDNet-FH v2 yang dilatih menggunakan dataset Rain100H karena pada pengujian sebelumnya menunjukkan kemampuan generalisasi terbaik. Hasil evaluasi pada data primer disajikan pada Tabel 5.7.

Tabel 5.7 Hasil Evaluasi *No-Reference* pada Data Primer (487 Foto)

Metrik	**Input**	**Output**	**Perubahan**
BRISQUE	33,0890	**28,5162**	$-13,82\%$
Laplacian Variance	794,4456	750,5717	$-5,52\%$

Berdasarkan Tabel 5.7, skor BRISQUE mengalami penurunan rata-rata sebesar 13,82% setelah proses *deraining*. Karena nilai BRISQUE yang lebih rendah menunjukkan kualitas citra yang lebih natural, hasil tersebut mengindikasikan bahwa model mampu meningkatkan kualitas visual citra hujan nyata secara konsisten.

Di sisi lain, nilai Laplacian Variance hanya mengalami penurunan sebesar 5,52%. Penurunan yang relatif kecil tersebut menunjukkan bahwa proses penghilangan *rain streak* tidak menyebabkan hilangnya ketajaman citra secara signifikan. Dengan demikian, model tidak hanya mampu mengurangi gangguan hujan, tetapi juga tetap mempertahankan detail spasial pada objek-objek di dalam citra. Distribusi nilai BRISQUE dan Laplacian Variance sebelum dan sesudah proses *deraining* divisualisasikan pada Gambar 5.11.



Gambar 5.11 Evaluasi *no-reference* pada dataset primer (487 foto). Kiri: skor BRISQUE sebelum dan sesudah *deraining*. Kanan: Laplacian Variance sebagai indikator ketajaman.

Pada Gambar 5.11 terlihat bahwa sebagian besar sampel mengalami penurunan skor BRISQUE setelah proses *deraining*. Pola tersebut menunjukkan bahwa hasil keluaran model memiliki kualitas visual yang lebih natural dibandingkan citra masukan. Sementara itu, distribusi nilai Laplacian Variance sebelum dan sesudah proses *deraining* masih berada pada rentang yang relatif serupa. Hal ini menunjukkan bahwa proses penghilangan hujan lebih dominan dibandingkan pengurangan detail citra sehingga ketajaman objek tetap dapat dipertahankan.

Untuk memberikan gambaran secara visual mengenai hasil *deraining* pada kondisi nyata, beberapa contoh hasil keluaran model ditampilkan pada Gambar 5.12.

Secara visual, Gambar 5.12 menunjukkan bahwa model mampu mengurangi *rain streak* pada berbagai kondisi lingkungan, seperti jalan raya, kawasan permukiman, maupun area vegetasi. Setelah proses *deraining*, objek utama tampak lebih jelas sehingga kualitas visual citra meningkat dan detail objek menjadi lebih mudah diamati. Meskipun demikian, pada beberapa sampel dengan kondisi hujan yang sangat lebat disertai kabut atau pencahayaan rendah masih terlihat sisa gangguan visual yang belum sepenuhnya dapat dihilangkan. Kondisi tersebut menunjukkan bahwa distribusi hujan nyata memiliki kompleksitas yang lebih tinggi dibandingkan dataset sintetik yang digunakan selama proses pelatihan sehingga masih menjadi tantangan bagi model dalam melakukan generalisasi pada kondisi ekstrem.

Berdasarkan keseluruhan hasil pengujian pada skenario kedua dapat disimpulkan bahwa model RCDNet-FH v2 yang dilatih menggunakan dataset



Gambar 5.12 Contoh hasil *deraining* pada beberapa sampel foto data primer. Kiri: citra masukan berhujan; kanan: citra keluaran setelah *deraining*.

Rain100H memiliki kemampuan generalisasi terbaik dibandingkan model lainnya. Model mampu mempertahankan performa yang tinggi pada dataset sintetik tambahan maupun data primer, baik berdasarkan evaluasi kuantitatif maupun pengamatan visual. Hasil tersebut menunjukkan bahwa pelatihan menggunakan dataset dengan karakteristik hujan yang lebih kompleks memberikan kemampuan adaptasi yang lebih baik terhadap berbagai kondisi hujan yang ditemui pada lingkungan nyata.

5.4 Pembahasan

Berdasarkan keseluruhan rangkaian eksperimen yang telah dilakukan, penelitian ini menunjukkan bahwa integrasi modul *FrequencyHint* pada arsitektur RCDNet mampu meningkatkan performa *Single Image Deraining* secara konsisten. Peningkatan tersebut tidak hanya terlihat pada metrik kuantitatif berupa PSNR dan SSIM, tetapi juga didukung oleh hasil pengamatan visual pada citra keluaran model. Dibandingkan dengan RCDNet *Baseline*, kedua varian yang diusulkan, yaitu RCDNet-FH v1 dan RCDNet-FH v2, mampu menghasilkan citra yang lebih bersih dengan detail objek yang tetap terjaga. Hasil tersebut menunjukkan bahwa informasi yang diperoleh dari domain frekuensi memberikan kontribusi nyata terhadap proses pemisahan antara pola hujan dan struktur latar belakang citra.

Pada model RCDNet *Baseline*, proses ekstraksi fitur sepenuhnya dilakukan pada domain spasial. Pendekatan tersebut efektif untuk mempelajari pola lokal, namun memiliki keterbatasan ketika rain streak memiliki orientasi, ukuran, dan intensitas yang sangat beragam. Dalam kondisi tersebut, karakteristik hujan sering kali memiliki kemiripan dengan tekstur latar belakang sehingga proses pemisahan menjadi lebih sulit. Akibatnya, model berpotensi menghilangkan sebagian detail citra atau masih menyisakan rain streak setelah proses *deraining*.

Integrasi *FrequencyHint* bertujuan untuk mengatasi keterbatasan tersebut dengan menyediakan informasi tambahan dari domain frekuensi yang kemudian digunakan sebagai petunjuk (*hint*) untuk memperkuat proses ekstraksi fitur pada domain spasial.

Transformasi Fourier yang digunakan pada modul *FrequencyHint* memungkinkan representasi citra dianalisis berdasarkan distribusi komponen frekuensinya. Rain streak umumnya membentuk pola dengan orientasi tertentu sehingga menghasilkan karakteristik frekuensi yang berbeda dibandingkan struktur objek alami pada citra. Dengan memanfaatkan informasi tersebut, modul *FrequencyHint* dapat memberikan perhatian yang lebih besar pada komponen yang berkaitan dengan pola hujan sekaligus menekan respons terhadap fitur latar belakang yang tidak relevan. Mekanisme ini membantu jaringan menghasilkan representasi fitur yang lebih diskriminatif sehingga proses rekonstruksi citra menjadi lebih akurat.

Hasil eksperimen pada Subbab 5.1 memperlihatkan bahwa penambahan modul *FrequencyHint* menghasilkan peningkatan performa pada kedua dataset pengujian. Pada dataset Rain100L, peningkatan nilai PSNR dan SSIM memang relatif kecil karena karakteristik hujan pada dataset tersebut masih tergolong ringan hingga sedang. Sebaliknya, peningkatan performa menjadi lebih signifikan pada Rain100H yang memiliki distribusi hujan lebih rapat, lebih panjang, dan saling bertumpuk. Kondisi tersebut menunjukkan bahwa informasi frekuensi menjadi semakin penting ketika kompleksitas pola hujan meningkat. Semakin kompleks pola hujan yang harus dipisahkan dari latar belakang, semakin besar pula manfaat informasi global yang diperoleh dari domain frekuensi.

Temuan tersebut juga diperkuat oleh hasil visual yang ditunjukkan pada Gambar 5.5 dan Gambar 5.5. Pada beberapa sampel Rain100H, model RCDNet *Baseline* masih memperlihatkan sisa rain streak pada area tertentu atau mengurangi ketajaman beberapa detail objek. Sebaliknya, RCDNet-FH v2 mampu menghasilkan citra yang tampak lebih bersih tanpa menghilangkan struktur penting seperti tepi bangunan, kendaraan, maupun tekstur vegetasi. Kesesuaian antara peningkatan metrik kuantitatif dan kualitas visual menunjukkan bahwa peningkatan PSNR dan SSIM yang diperoleh bukan hanya bersifat numerik, tetapi benar-benar merepresentasikan peningkatan kualitas hasil *deraining*.

Selain membuktikan efektivitas penggunaan informasi frekuensi, hasil penelitian ini juga menunjukkan bahwa desain arsitektur modul *FrequencyHint* memberikan pengaruh yang signifikan terhadap performa model. Perbandingan antara FH v1 dan FH v2 menunjukkan bahwa kedua arsitektur sama-sama mampu meningkatkan performa dibandingkan model *Baseline*, namun FH v2 secara konsisten memberikan hasil yang lebih baik pada seluruh dataset pengujian. Hal tersebut menunjukkan bahwa peningkatan performa tidak hanya dipengaruhi oleh keberadaan modul *FrequencyHint*, tetapi juga oleh bagaimana informasi frekuensi tersebut diproses sebelum diintegrasikan kembali ke dalam jaringan utama.

Perbedaan utama antara FH v1 dan FH v2 terletak pada penggunaan struktur *bottleneck*. Pada FH v1, proses pemrosesan spektrum dilakukan menggunakan dua lapis konvolusi secara langsung sehingga seluruh channel diproses dengan dimensi yang sama. Pendekatan tersebut memang mampu memperbaiki

representasi frekuensi, tetapi masih menghasilkan redundansi informasi karena setiap channel diperlakukan secara seragam. Sebaliknya, FH v2 menggunakan mekanisme *compress–refine–expand*, yaitu mengurangi dimensi channel terlebih dahulu, melakukan proses penyaringan pada ruang representasi yang lebih ringkas, kemudian mengembalikan dimensi fitur ke ukuran semula. Strategi ini memungkinkan jaringan memusatkan perhatian pada informasi frekuensi yang paling relevan sehingga proses pembelajaran menjadi lebih efisien.

Selain mekanisme *bottleneck*, FH v2 juga memanfaatkan inisialisasi residual dengan bobot awal bernilai nol sehingga modul tambahan tidak langsung mengubah perilaku jaringan pada awal pelatihan. Pada tahap awal, model masih bekerja menyerupai RCDNet *Baseline*, kemudian secara bertahap mempelajari seberapa besar kontribusi informasi frekuensi yang diperlukan selama proses optimasi. Pendekatan tersebut menghasilkan proses pelatihan yang lebih stabil karena perubahan distribusi fitur tidak terjadi secara tiba-tiba. Stabilitas tersebut juga terlihat pada kurva *train loss* yang menurun secara konsisten hingga akhir proses pelatihan tanpa menunjukkan fluktuasi yang berlebihan.

Keunggulan FH v2 semakin diperkuat oleh hasil studi ablasi terhadap jumlah *stage*. Eksperimen menunjukkan bahwa peningkatan jumlah *stage* secara umum diikuti oleh peningkatan nilai PSNR dan SSIM pada kedua dataset. Hal ini sejalan dengan prinsip dasar RCDNet yang memodelkan proses *deraining* sebagai rangkaian iterasi *proximal gradient descent*. Semakin banyak *stage* yang digunakan, semakin banyak pula kesempatan bagi model untuk memperbaiki estimasi citra bersih secara bertahap. Akan tetapi, hasil eksperimen juga menunjukkan bahwa peningkatan tersebut tidak berlangsung secara linier. Setelah jumlah *stage* tertentu, tambahan performa yang diperoleh menjadi semakin kecil meskipun biaya komputasi terus meningkat.

Temuan yang paling menarik dari studi ablasi adalah bahwa RCDNet-FH v2 dengan hanya menggunakan 10 *stage* telah mampu melampaui performa RCDNet *Baseline* yang menggunakan 17 *stage*. Hasil ini menunjukkan bahwa informasi tambahan yang diberikan oleh modul *FrequencyHint* membuat setiap iterasi optimasi menjadi lebih efektif. Dengan kata lain, jaringan memperoleh representasi fitur yang lebih informatif sejak awal sehingga jumlah iterasi yang diperlukan untuk mencapai kualitas rekonstruksi tertentu menjadi lebih sedikit. Temuan ini mengindikasikan bahwa peningkatan performa model tidak hanya berasal dari penambahan kapasitas jaringan, tetapi juga dari peningkatan kualitas informasi yang digunakan pada setiap tahap rekonstruksi.

Meskipun konfigurasi dengan 20 *stage* menghasilkan nilai PSNR tertinggi, peningkatan yang diperoleh dibandingkan konfigurasi 17 *stage* relatif kecil apabila dibandingkan dengan tambahan waktu komputasi yang dibutuhkan. Fenomena tersebut menunjukkan adanya kondisi *diminishing returns*, yaitu ketika penambahan kompleksitas model tidak lagi menghasilkan peningkatan performa yang sebanding. Oleh karena itu, konfigurasi RCDNet-FH v2 dengan 17 *stage* dipilih sebagai model utama dalam penelitian ini karena memberikan keseimbangan terbaik antara akurasi, stabilitas pelatihan, dan efisiensi komputasi. Pemilihan konfigurasi ini juga menjadi dasar dalam seluruh pengujian generalisasi yang dibahas pada subbab berikutnya.

BAB VI
KESIMPULAN DAN SARAN

Pada bab ini berisikan kesimpulan yang dihasilkan dari penelitian tugas akhir yang telah dibahas pada bab-bab sebelumnya. Selain kesimpulan, terdapat saran-saran yang dituangkan penulis sebagai bahan untuk pengembangan penelitian selanjutnya.

6.1 Kesimpulan

Berdasarkan hasil penelitian diperoleh kesimpulan dari penelitian Tugas Akhir ini dirangkum sebagai berikut,

1. Penelitian ini berhasil menerapkan pengembangan model *Rain Convolutional Dictionary Network* (RCDNet) melalui integrasi modul *FrequencyHint* pada bagian M-Net untuk menghilangkan *rain streaks* pada citra tunggal (*Single Image Deraining*). Modul *FrequencyHint* memanfaatkan transformasi Fourier untuk mengekstraksi informasi pada domain frekuensi dan memberikan petunjuk frekuensi global (*global frequency hints*) yang membantu proses estimasi *rain map*. Selain itu, penggunaan mekanisme *spectral gate bottleneck* memungkinkan penyaringan komponen frekuensi secara adaptif sehingga integrasi modul tetap efisien tanpa mengubah struktur utama RCDNet.
2. Hasil analisis menunjukkan bahwa integrasi *FrequencyHint* mampu meningkatkan kinerja model dibandingkan RCDNet *baseline*. Pada dataset Rain100L diperoleh peningkatan sebesar 0,3293 dB pada metrik PSNR dan 0,0008 pada SSIM, sedangkan pada dataset Rain100H diperoleh peningkatan sebesar 0,5586 dB pada PSNR dan 0,0069 pada SSIM. Peningkatan yang lebih besar pada Rain100H menunjukkan bahwa informasi domain frekuensi memberikan kontribusi lebih signifikan ketika citra memiliki intensitas hujan yang lebih kompleks. Pengujian pada dataset sintetik tambahan juga memperlihatkan bahwa model generalis yang dilatih menggunakan data gabungan mampu mempertahankan performa pada berbagai tingkat intensitas hujan. Sementara itu, evaluasi pada 487 citra hujan nyata menggunakan metrik BRISQUE menunjukkan penurunan skor sebesar 13,82%, yang mengindikasikan peningkatan kualitas visual tanpa mengurangi ketajaman detail citra. Secara keseluruhan, hasil penelitian membuktikan bahwa penambahan *FrequencyHint* mampu meningkatkan kemampuan RCDNet dalam memisahkan karakteristik hujan dari tekstur latar belakang sehingga menghasilkan proses *deraining* yang lebih baik dibandingkan model *baseline*.

6.2 Saran

Adapun saran bagi penelitian selanjutnya sebagai berikut,

1. Mengeksplorasi bentuk representasi domain frekuensi yang lebih adaptif, seperti *wavelet transform*, *learnable frequency decomposition*, atau mekanisme perhatian (*frequency attention*) sehingga informasi spektral yang diperoleh menjadi lebih diskriminatif terhadap karakteristik hujan.
2. Mengintegrasikan proses *deraining* dengan tugas *high-level computer vision*, seperti deteksi objek atau pelacakan kendaraan pada kondisi hujan, sehingga manfaat peningkatan kualitas citra terhadap performa sistem visi komputer dapat dievaluasi secara langsung.
3. Evaluasi model dapat diperluas menggunakan dataset nyata yang lebih beragam, baik dari sisi kondisi pencahayaan, kepadatan hujan, maupun variasi lingkungan, sehingga kemampuan generalisasi model pada skenario dunia nyata dapat dianalisis secara lebih komprehensif.

DAFTAR PUSTAKA

Akbar, S. A., & Verma, A. (2024). *Analyzing noise models and advanced filtering algorithms for image enhancement.* Retrieved 2024-01-01, from `https://arxiv.org/abs/2410.21946` doi: 10.48550/arXiv.2410.21946

Barnum, P. C., Narasimhan, S., & Kanade, T. (2009). Analysis of rain and snow in frequency space. *International Journal of Computer Vision*, *76*(3), 309–336. doi: 10.1007/s11263-008-0200-2

Beck, A., & Teboulle, M. (2009). A fast iterative shrinkage-thresholding algorithm for linear inverse problems. *SIAM Journal on Imaging Sciences*, *2*(1), 183–202.

Chang, C.-C., & Lin, C.-J. (2011). LIBSVM: A library for support vector machines. *ACM Transactions on Intelligent Systems and Technology*, *2*(3), 27:1–27:27.

Chen, Y., et al. (2014). Real-time video deraining via non-local patch-based modeling. *IEEE International Conference on Image Processing (ICIP).* doi: 10.1109/ICIP.2014.7024820

Fu, X., Huang, J., Zeng, D., Huang, Y., Ding, X., & Paisley, J. (2017). Removing rain from single images via a deep detail network. In *Proceedings of the ieee conference on computer vision and pattern recognition (cvpr)* (pp. 3855–3863).

Gao, N., Jiang, X., Zhang, X., & Deng, Y. (2025). Efficient frequency-domain image deraining with contrastive regularization. In *Computer vision – eccv 2024* (Vol. 15099, pp. 240–257). Springer. doi: 10.1007/978-3-031-72940-9_14

Gonzalez, R. C., & Woods, R. E. (2020). Digital image processing concepts. In *Advances in signal processing* (pp. 15–40). Springer. doi: 10.1007/978-981-13-3244-9_2

Gregor, K., & LeCun, Y. (2010). Learning fast approximations of sparse coding. *Proceedings of the 27th International Conference on Machine Learning (ICML).*

Guo, Q., et al. (2019). *Comparative performance analysis of image denoising techniques.* Retrieved 2024-01-01, from `https://arxiv.org/abs/1901.06529`

He, Z., & Patel, V. M. (2017). Convolutional sparse and low-rank coding-based rain streak removal. In *Ieee winter conference on applications of computer vision (wacv).*

Horé, A., & Ziou, D. (2010). Image quality metrics: Psnr vs. ssim. In *2010 20th international conference on pattern recognition (icpr)* (pp. 2366–2369). doi: 10.1109/ICPR.2010.579

Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. In *Proceedings of the ieee conference on computer vision and pattern recognition (cvpr)* (pp. 7132–7141). doi: 10.1109/CVPR.2018.00745

Jiang, K., Jiang, J., Liu, X., Xu, X., & Ma, X. (2024). Fmrnet: Image deraining via frequency mutual revision. In *Thirty-eighth aaai conference on artificial*

intelligence (aaai 2024) (pp. 12892–12900). AAAI Press. doi: 10.1609/AAAI.V38I11.29186

Joshi, K., & Joshi, R. C. (2015). *A review paper: Noise models in digital image processing.* Retrieved 2024-01-01, from https://arxiv.org/abs/1505.03489

Kang, L., et al. (2010). Automatic removal of rain streaks from videos. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR).* doi: 10.1109/CVPR.2010.5540130

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. In *Advances in neural information processing systems (neurips)* (Vol. 25). Retrieved 2024-01-01, from https://papers.nips.cc/paper_files/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html

Lasmar, N.-E., Stitou, Y., & Berthoumieu, Y. (2009). Multiscale skewed heavy tailed model for texture analysis. In *Proceedings of the 16th ieee international conference on image processing (icip)* (pp. 2281–2284).

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, *521*(7553), 436–444. doi: 10.1038/nature14539

Li, B., Liu, X., Hu, P., Wu, Z., Lv, J., & Peng, X. (2022). All-in-one image restoration for unknown corruption. In *Proceedings of the ieee/cvf conference on computer vision and pattern recognition (cvpr)* (pp. 17452–17462). doi: 10.1109/CVPR52688.2022.01693

Li, D., Liu, Y., Fu, X., Xu, S., & Zha, Z.-J. (2024). *Fouriermamba: Fourier learning integration with state space models for image deraining.* Retrieved 2024-01-01, from https://arxiv.org/abs/2405.19450

Li, H., et al. (2023). Noise estimation and type identification in natural scene and medical images using deep learning approaches. *Computational and Mathematical Methods in Medicine.*

Li, M., Yang, J., & Tan, R. T. (2018). Video rain streak removal by multiscale convolutional sparse coding. In *Ieee conference on computer vision and pattern recognition (cvpr).*

Li, R., Tan, R. T., & Cheong, L.-F. (2019). *Single image deraining: From model-based to data-driven and beyond.* Retrieved 2024-01-01, from https://arxiv.org/abs/1912.07150

Li, X., et al. (2024). A survey on all-in-one image restoration: Taxonomy, evaluation and future trends. *IEEE Transactions on Pattern Analysis and Machine Intelligence.*

Li, Y., Tan, R. T., Guo, X., Lu, J., & Brown, M. S. (2016). Rain streak removal using layer priors. In *Proceedings of the ieee conference on computer vision and pattern recognition (cvpr)* (pp. 2736–2744). doi: 10.1109/CVPR.2016.299

Luo, Y., Xu, Y., & Ji, H. (2015). Removing rain from a single image via discriminative sparse coding. In *Proceedings of the ieee international conference on computer vision (iccv).*

Lv, T., et al. (2022). Iterative deep neural networks based on proximal gradient descent for image restoration. *PLOS One*, *17*(11), e0276373.

Ma, Y., et al. (2020). Rain or snow removal from single images. *IEEE Transactions on Image Processing.* doi: 10.1109/TIP.2020.2978456

Mao, J., Sun, L., Chen, J., & Yu, S. (2025). Overview of research on digital image denoising methods. *Sensors*, *25*(8), 2615.

Mittal, A., Moorthy, A. K., & Bovik, A. C. (2012). No-reference image quality assessment in the spatial domain. *IEEE Transactions on Image Processing*, *21*(12), 4695–4708. doi: 10.1109/TIP.2012.2214050

Monga, V., Li, Y., & Eldar, Y. (2021). Algorithm unrolling: Interpretable, efficient deep learning for signal and image processing. *IEEE Signal Processing Magazine*.

Ndajah, P., Kikuchi, H., Yukawa, M., Watanabe, H., & Muramatsu, S. (2011). An investigation on the quality of denoised images. *International Journal of Circuits, Systems and Signal Processing*, *5*(4), 423–434. Retrieved 2024-01-01, from `https://www.naun.org/main/NAUN/circuitssystemssignal/20-611.pdf`

Qin, X., et al. (2024). Rain streak removal using structure-aware median filtering. *Journal of Computer Vision*. (Cited in proposal TA)

Rakesh, K., et al. (2015). *A review paper: Noise models in digital image processing.* Retrieved 2024-01-01, from `https://arxiv.org/abs/1505.03489`

Ren, D., Shang, W., Zhu, P., Hu, Q., Meng, D., & Zuo, W. (2020). Single image deraining using bilateral recurrent network. *IEEE Transactions on Image Processing*, *29*, 6852–6863. doi: 10.1109/tip.2020.2994443

Ruderman, D. L. (1994). The statistics of natural images. *Network: Computation in Neural Systems*, *5*(4), 517–548.

Sharifi, K., & Leon-Garcia, A. (1995). Estimation of shape parameter for generalized Gaussian distributions in subband decompositions of video. *IEEE Transactions on Circuits and Systems for Video Technology*, *5*(1), 52–56.

Sharma, P. K., Basavaraju, S., & Sur, A. (2021). Deep learning-based image de-raining using discrete fourier transformation. *The Visual Computer*, *37*, 2083–2096. doi: 10.1007/s00371-020-01971-w

Son, C.-H., & Zhang, X.-P. (2020). Rain removal via shrinkage-based sparse coding and learned rain dictionary. *Journal of Imaging Science and Technology*, *64*(3).

Swaminathan, R., & Korupolu, P. (2023). Mobilederaingan: An efficient semi-supervised approach to single image rain removal for task-driven applications. In *Proceedings of the ieee/cvf conference on computer vision and pattern recognition (cvpr) workshops* (pp. 192–201).

Szeliski, R. (2022). *Computer vision: Algorithms and applications* (2nd ed.). Springer. Retrieved 2024-01-01, from `https://szeliski.org/Book/`

Voulodimos, A., Doulamis, N., Doulamis, A., & Protopapadakis, E. (2018). Deep learning for computer vision: A brief review. *Computational Intelligence and Neuroscience*, *2018*, 7068349. doi: 10.1155/2018/7068349

Wang, H., & Patel, V. M. (2022). Rcdnet: An interpretable rain convolutional dictionary network for single image deraining. *IEEE Transactions on Neural Networks and Learning Systems*.

Wang, H., Wu, Y., Li, M., Zhao, Q., & Meng, D. (2021, December). Survey on rain removal from videos or a single image. *Science China Information Sciences*, *65*(1). doi: 10.1007/s11432-020-3225-9

Wang, H., Wu, Y., & Zhang, F. (2022). A survey on rain removal from videos or a

single image. *Science China Information Sciences*.

Wang, H., Xie, Q., & Zhao, Q. (2020). A model-driven deep neural network for single image rain removal. In *Proceedings of the ieee conference on computer vision and pattern recognition (cvpr)*.

Wang, H., Xie, Q., Zhao, Q., & Meng, D. (2020). A model-driven deep neural network for single image rain removal. In *Proceedings of the ieee/cvf conference on computer vision and pattern recognition (cvpr)* (pp. 3103–3112). doi: 10.1109/CVPR42600.2020.00317

Wang, H., Yue, H., & Yin, W. (2020). Single image rain streaks removal: A review and an exploration. *International Journal of Machine Learning and Cybernetics*.

Wang, Q., Jiang, K., Wang, Z., Ren, W., Zhang, J., & Lin, C. (2024). Multi-scale fusion and decomposition network for single image deraining. *IEEE Transactions on Image Processing*, *33*, 191–204. doi: 10.1109/tip.2023.3334556

Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, *13*(4), 600–612. doi: 10.1109/TIP.2003.819861

Wang, Z., Luo, L., & Xie, Y. (2018). Weighted median guided filtering for single image rain removal. *EURASIP Journal on Image and Video Processing*.

Yamashita, S., & Ikehara, M. (2025). Image deraining with frequency-enhanced state space model. In *Computer vision – accv 2024: 17th asian conference on computer vision* (Vol. 15475, pp. 318–334). Springer. doi: 10.1007/978-981-96-0911-6_19

Yang, W., Tan, R. T., & Feng, J. (2019). Joint rain detection and removal from a single image with contextualized deep networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*.

Yu, C., Chang, Y., Li, Y., Zhao, X., & Yan, L. (2022). *Unsupervised image deraining: Optimization model driven deep cnn.* Retrieved 2024-01-01, from `https://arxiv.org/abs/2203.13699`

Zhang, M., Wang, S., & Yin, S. (2025). Rain-resilient image restoration for reliable and sustainable visual monitoring in industrial inspection and quality control. *Processes*, *13*(6), 1628. doi: 10.3390/pr13061628

Zhang, Z., Li, Y., & Guo, X. (2023). Data-driven single image deraining: A comprehensive review. *Pattern Recognition*.

Zheng, C., Yao, Y., Ying, W., & Wu, S. (2025). Single image de-raining by multi-scale fourier transform network. *PLOS ONE*, *20*(3), e0315146. doi: 10.1371/journal.pone.0315146

Zou, Z., Chen, K., Shi, Z., Guo, Y., & Ye, J. (2023). Object detection in 20 years: A survey. *Proceedings of the IEEE*, *111*(3), 257–276. doi: 10.1109/JPROC.2023.3238524

UCAPAN TERIMA KASIH

Penyelesaian penulisan tugas akhir ini tidak lepas dari orang-orang terdekat penulis yang telah mendukung, mengkritisi, mendorong dan memotivasi penulis sehingga penyusunan Tugas Akhir ini dapat terselesaikan. Oleh sebab itu, penulis mengucapkan terima kasih kepada:

1. Diri sendiri selaku penulis, atas perjuangan dan dedikasi hingga dapat menyelesaikan Tugas Akhir ini tepat waktu.
2. Kepada Mama tercinta, terima kasih atas segala doa, kasih sayang, dukungan, kesabaran, dan pengorbanan yang tiada henti. Terima kasih telah menjadi sumber kekuatan dan semangat bagi penulis hingga tugas akhir ini dapat diselesaikan.
3. Kepada almarhum Ayah tercinta, terima kasih atas segala kasih sayang, pengorbanan, dan doa yang telah diberikan semasa hidup. Walaupun Ayah tidak dapat menyaksikan secara langsung pencapaian ini, penulis berharap tugas akhir ini menjadi bukti bahwa penulis telah menyelesaikan pendidikan yang selalu Ayah perjuangkan dan harapkan.
4. Luvviana Hiba M. selaku kakak penulis tercinta yang senantiasa memberikan dukungan, motivasi, perhatian, serta bantuan dalam berbagai bentuk selama proses penyusunan tugas akhir ini. Kehadiran dan dukungan yang diberikan menjadi salah satu sumber semangat bagi penulis untuk terus menyelesaikan setiap tahapan penelitian.
5. Jino dan joni kucing kesayangan penulis yang telah memberikan hiburan, kenyamanan, dan suasana yang lebih menyenangkan di tengah berbagai tantangan dan tekanan selama penyusunan penelitian ini.
6. Alridho Tristan Satriawan atas segala perhatian dan waktu yang telah diberikan selama mendampingi penulis.
7. Kawan-kawan seperbimbingan ibu Dwi yang telah memotivasi pengerjaan Tugas Akhir ini.
8. Pihak lain yang berjasa dalam membantu penyelesaian Tugas Akhir yang belum dapat disebutkan.

Penulis juga mengharapkan kritik dan saran yang membangun dari berbagai pihak untuk penyempurnaan isi tugas akhir ini serta demi perkembangan ilmu pengetahuan. Akhir kata, semoga tugas akhir ini bermanfaat bagi semua pihak yang bersangkutan.

Surabaya, 29 Juli 2026

Merisa Anggi Anggraini

BIODATA PENULIS



Penulis memiliki nama lengkap Merisa Anggi Anggraini dan akrab dipanggil ”isa”, lahir di Kabupaten Jember pada 30 Maret 2003. Pada tahun 2022, penulis melanjutkan pendidikan jenjang Sarjana (S1) di Departemen Matematika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember (ITS), Surabaya. Selama menempuh pendidikan di ITS, penulis aktif dalam berbagai kegiatan organisasi dan kepanitiaan. Penulis pernah menjabat sebagai Staf *Student Welfare* Himpunan Mahasiswa Matematika (HIMATIKA) pada tahun 2024 serta Staf Pengembangan Sumber Daya Manusia (PSDM) UKM Robotika ITS pada periode 2023–2024. Selain itu, penulis juga berpartisipasi dalam berbagai kepanitiaan, di antaranya sebagai Kasubdiv *Accommodation and Consumption* (ATCOM) OMITS 17th pada tahun 2024 dan Mentor GERIGI ITS pada tahun 2024. Di luar kegiatan kampus, penulis juga aktif sebagai *Partnership Staff* pada komunitas DIGISTAR CLUB by Telkom Indonesia. Penulis memiliki minat pada bidang analisis data, pengolahan citra digital (*image processing*), *machine learning*, *deep learning*, serta pengembangan perangkat lunak. Adapun keterampilan yang dimiliki meliputi analisis data, pemrograman menggunakan Java dan Python, serta perancangan antarmuka pengguna (*user interface design*). Melalui penelitian ini, penulis berharap dapat memberikan kontribusi terhadap pengembangan metode restorasi citra berbasis *deep learning*. Demikian biodata penulis Tugas Akhir ini, apabila terdapat saran, kritik, dan diskusi mengenai Tugas Akhir ini dapat menghubungi penulis melalui merisaanggi30@gmail.com. Terima Kasih